ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN



MÔN HỌC: Nhập môn Học máy (CSC14005)

BÁO CÁO VỀ DỮ LIỆU

PHÂN LOẠI TÌNH TRẠNG CHẶN LỐI ĐI TRÊN VỈA HÈ TP.HCM TỪ ẢNH ĐƯỜNG PHỐ

Giảng viên: TS. Bùi Tiến Lên

Lớp: 24KHMT02

Thời gian: Học kỳ I, năm học 2026 - 2027

Nhóm: 11

Sinh viên:

Họ và tên	MSSV
Lê Nguyễn Quốc Học	24127044
Bùi Thị Bích Loan	24127072
Nguyễn Hữu Gia Minh	24127078
Nguyễn Lê Hoàng Khải	24127408
Trần Hoàng Phúc	24127505

Mục lục

1 Giới thiệu bài toán **1**
1.1 Bài toán học máy . . . 1
1.2 Tổng quan bộ dữ liệu . . . 1

2 Phương pháp và nguồn thu thập dữ liệu **3**
2.1 Nguồn dữ liệu . . . 3
2.2 Quy trình thu thập từng bước . . . 3
2.3 Gán nhãn . . . 5
2.4 Bổ sung mẫu dương cho train . . . 6
2.5 Công cụ và định dạng lưu trữ . . . 6

3 Quy trình làm sạch và tiền xử lý dữ liệu **8**

4 Đảm bảo chất lượng dữ liệu **10**
4.1 Tiêu chí dữ liệu tốt cho bài toán này . . . 10
4.2 Kiểm tra thủ công: đồng thuận và phân xử . . . 10
4.3 Kiểm tra tự động . . . 12

5 Lưu trữ và quản lý dữ liệu **13**

6 Phân tích khám phá dữ liệu (EDA) **14**
6.1 Thống kê mô tả . . . 14
6.2 Phân tích phân bố nhãn . . . 19
6.3 Phân tích mối quan hệ giữa các thuộc tính . . . 23
6.4 Kiểm tra chất lượng dữ liệu . . . 25
6.5 EDA cho dữ liệu ảnh . . . 32

7 Tổng kết và các hạn chế **36**
7.1 Các kết quả đã đo được . . . 36
7.2 Các nội dung chưa đo hoặc chưa thực hiện . . . 37
7.3 Hệ quả đối với bước xây dựng mô hình . . . 38

A Truy nguồn số liệu và cách tái lập **41**

Danh sách bảng

1 Ba phần của bộ dữ liệu và nhãn cuối (đơn vị: ảnh) . . . 2
2 Trả lời các câu hỏi về nguồn dữ liệu của khung báo cáo . . . 3
3 Các bước thu thập bộ chính và pilot . . . 4
4 Phân công gán nhãn . . . 5
5 Công cụ sử dụng và định dạng lưu trữ . . . 7
6 Các bước làm sạch và tiền xử lý, theo khung báo cáo . . . 8
7 Tiêu chí chất lượng và cách kiểm tra . . . 10
8 Đồng thuận giữa hai người gán trên bộ chính (Cohen κ) . . . 11

9 Nguồn của nhãn cuối . . . 12
10 Tổ chức thư mục dữ liệu . . . 13
11 Các bảng dữ liệu: số dòng, số cột, dữ liệu thiếu . . . 14
12 Thống kê mô tả hai biến số chính của metadata, theo nhóm . . . 16
13 Thống kê mô tả các biến số còn lại của metadata . . . 17
14 Số ảnh theo tháng chụp (theo dấu thời gian của Mapillary) . . . 18
15 Tỉ lệ Bị chặn và Không đủ thông tin theo nhóm, khoảng tin cậy 95% . . . 20
16 Liên hệ giữa thuộc tính và nhãn Bị chặn so với Còn lối đi (ảnh hợp lệ) . . . 24
17 Kết quả kiểm tra tính hợp lệ và nhất quán . . . 26
18 Số ảnh val/test nằm gần một ảnh phía train . . . 30
19 Mức phân biệt được giữa các nhóm ảnh (AUC của bộ phân loại miền) . . . 31
20 Thống kê chất lượng ảnh theo nhóm (trung vị; trong ngoặc là IQR) . . . 34
21 Các kết quả chính, kèm cỡ mẫu và khoảng tin cậy . . . 36
22 Các việc chưa thực hiện và ảnh hưởng tới báo cáo . . . 37
23 Nguồn gốc của các nhóm số liệu trong báo cáo . . . 41

Danh sách hình

1 Phân bố độ sáng ảnh 360° và khoảng cách tới tim đường theo nhóm . . . 16
2 Số ảnh theo năm chụp và tài khoản chụp . . . 18
3 Số ảnh theo nhãn trong từng nhóm . . . 19
4 Thành phần tập train trước và sau khi thêm pilot và ảnh bổ sung (chỉ tính ảnh hợp lệ) . . . 21
5 Thành phần nhãn của 17 đường thuộc bộ chính (không gồm pilot) . . . 21
6 Loại vật cản trên ảnh Bị chặn và lý do gán nhãn Không đủ thông tin, bộ chính so với ảnh bổ sung . . . 22
7 Tỉ lệ nhãn theo người gán; phần ảnh bổ sung dùng nhãn của từng người trước kiểm tra chéo . . . 23
8 Tương quan hạng Spearman giữa các thuộc tính số của metadata . . . 24
9 Phân bố độ tương đồng giữa các cặp ảnh: cùng vị trí khác ngày, cùng đường khác vị trí, khác đường . . . 28
10 Vị trí của mọi ảnh theo tập. Các đường val/test cắt đường train tại giao lộ . . . 29
11 Hình chiếu t-SNE của embedding DINOv2 cho 5.149 ảnh, tô theo nhóm và theo nhãn . . . 31
12 Ví dụ ảnh theo nhãn, lấy ngẫu nhiên từ train của bộ chính. © Mapillary contributors, CC BY-SA 4.0 . . . 32
13 Ví dụ ảnh bổ sung theo tầng lấy mẫu . . . 33
14 Độ sáng của ảnh cắt theo nhóm và theo nhãn . . . 34
15 Độ nét của ảnh cắt (thang log) theo nhóm và theo nhãn . . . 35

1. Giới thiệu bài toán

1.1. Bài toán học máy

Một vỉa hè có thể tồn tại về mặt vật lý nhưng không còn đóng vai trò lối đi bộ khi xe đậu, hàng hóa, bàn ghế hoặc rào chắn làm gián đoạn lối đi liên tục. Đồ án xây dựng một bộ phân loại ảnh nhằm sàng lọc tình trạng này trên ảnh đường phố tại TP.HCM.

- **Đầu vào:** một ảnh 640×640 điểm ảnh nhìn về một phía vỉa hè, được cắt từ ảnh toàn cảnh $360°$ chụp từ xe.
- **Đầu ra của mô hình:** phân loại nhị phân. 0 – Còn lối đi: người đi bộ có thể tiếp tục đi dọc vỉa hè gần. 1 – Bị chặn: người đi bộ buộc phải bước xuống lòng đường.
- **Ảnh không đủ bằng chứng** (không thấy vỉa hè gần, bị che khuất, ảnh hỏng) được gán nhãn riêng I – Không đủ thông tin; nhãn này chỉ dùng ở khâu gán nhãn và các ảnh mang nhãn I bị loại khỏi quá trình huấn luyện và đánh giá mô hình. Nhãn I vẫn được thống kê vì nó quyết định số ảnh hợp lệ thu được từ nguồn dữ liệu.
- **Câu hỏi nghiên cứu:** mô hình nào phân loại tốt nhất trên *các tuyến đường không xuất hiện trong tập huấn luyện*. Do đó, dữ liệu được chia theo nguyên tuyến đường, và mọi kiểm tra trong báo cáo đều chú trọng tới rò rỉ dữ liệu giữa các tập.

Với mỗi ảnh, người gán nhãn trả lời câu hỏi: *người đi bộ có phải bước xuống lòng đường để tiếp tục đi dọc vỉa hè gần không?*

Quy ước thuật ngữ. Báo cáo dùng tên viết tắt train, val và test cho tập huấn luyện, tập kiểm định và tập kiểm thử. *Ảnh hợp lệ* là ảnh có nhãn 0 hoặc 1; *mẫu dương* là ảnh có nhãn Bị chặn. *Metadata* (siêu dữ liệu) là các thuộc tính đi kèm mỗi ảnh như tọa độ, thời gian chụp và tài khoản chụp. EDA là viết tắt của phân tích khám phá dữ liệu (exploratory data analysis). Thành viên nhóm được gọi theo tên: Học (Lê Nguyễn Quốc Học), Loan (Bùi Thị Bích Loan), Minh (Nguyễn Hữu Gia Minh), Khải (Nguyễn Lê Hoàng Khải) và Phúc (Trần Hoàng Phúc).

1.2. Tổng quan bộ dữ liệu

Bộ dữ liệu gồm ba phần, được thu thập theo ba cách lấy mẫu khác nhau (bảng 1). Báo cáo luôn trình bày tách riêng ba phần này, vì chỉ phần thứ nhất phản ánh phân phối tự nhiên của ảnh trên các tuyến đường.

Bảng 1: Ba phần của bộ dữ liệu và nhãn cuối (đơn vị: ảnh)

Phần	Cách lấy mẫu	Ảnh	0	1	I
Bộ chính, train	Tự nhiên: mọi vị trí cách nhau 25 m trên 10 đường	1.839	939	106	794
Bộ chính, val	Tự nhiên, 3 đường	486	207	35	244
Bộ chính, test	Tự nhiên, 4 đường	674	412	47	215
Pilot, train	Theo tầng điểm của một mô hình thử, 3 đường train	150	73	14	63
Ảnh bổ sung, train	70% theo điểm của bộ chọn ảnh, 30% ngẫu nhiên, 75 đường mới	2.000	819	577	604
Tổng		**5.149**	**2.450**	**779**	**1.920**

Một số lưu ý khi đọc các phần tiếp theo:

- **Val và test chỉ gồm ảnh tự nhiên.** Ảnh pilot và ảnh bổ sung chỉ được đưa vào train. Nhãn val/test chỉ dùng để thống kê mô tả, không dùng để lựa chọn hay điều chỉnh bất kỳ thành phần nào.
- **Lớp Bị chặn hiếm trong ảnh tự nhiên:** 188 trên 1.746 ảnh hợp lệ của bộ chính (10,8%). Đây là lý do nhóm thực hiện đợt bổ sung ảnh cho train.
- **Khoảng 40% ảnh mang nhãn Không đủ thông tin**, do ảnh chụp từ xe thường không quan sát rõ vỉa hè gần.

2. Phương pháp và nguồn thu thập dữ liệu

2.1. Nguồn dữ liệu

Bảng 2 lần lượt trả lời các câu hỏi về nguồn dữ liệu trong khung báo cáo.

Bảng 2: Trả lời các câu hỏi về nguồn dữ liệu của khung báo cáo

Câu hỏi	Trả lời
Dựa trên dataset có sẵn?	Không. Nhóm tự xây dựng bộ dữ liệu từ ảnh gốc. Bộ dữ liệu gần nhất là Vietnamese Sidewalk Violation VQA [1], nhưng bộ này không có tọa độ và thời gian chụp nên không thể chia theo tuyến đường; nhóm không sử dụng ảnh hay nhãn của bộ này.
Từ API?	Có. Ảnh 360° và metadata được lấy qua Mapillary Graph API [2]; mạng lưới đường và các điểm ngữ cảnh (chợ, trường học) được lấy từ OpenStreetMap (OSM) [3] qua Overpass API.
Web scraping?	Không.
Khảo sát, biểu mẫu?	Không. Nhãn do 5 thành viên nhóm gán trên Label Studio [4] (mục 2.3).
Giấy phép	Ảnh Mapillary theo giấy phép CC BY-SA 4.0, ghi công © Mapillary contributors, CC BY-SA 4.0. Phần làm mờ khuôn mặt và biển số của Mapillary được giữ nguyên. Ảnh không được đưa lên git.
Ảnh nhóm tự chụp	**Chưa có** (đề cương dự kiến ít nhất 100 ảnh).

Khu vực nghiên cứu là trung tâm TP.HCM (Quận 1, 3, 5, 10, Phú Nhuận và Bình Thạnh cũ), trong khung tọa độ 10,745–10,815° Bắc, 106,650–106,725° Đông. Trong khung này, Mapillary có 652.159 ảnh 360° thuộc 1.234 chuỗi ảnh (quét ngày 22/10/2026), chủ yếu của ba tài khoản bemaps3_sg, phoenix_mapping_front và phoenixmap_front, chụp trong các năm 2016, 2023 và 2024.

2.2. Quy trình thu thập từng bước

Bảng 3 liệt kê chín bước thu thập và kết quả của từng bước. Mỗi bước do một script riêng của nhóm thực hiện và được ghi lại trong nhật ký thu thập.

Bảng 3: Các bước thu thập bộ chính và pilot

#	Công việc	Kết quả
1	Lấy các đường có tên và các điểm ngữ cảnh từ OSM	7.283 đoạn đường, 6.715 điểm
2	Quét metadata ảnh 360° theo các ô lưới 0,001°	652.159 ảnh; 2 ô nhỏ ở góc khung bị lỗi
3	Gắn ảnh vào đường: cách đường ≤ 20 m và hướng di chuyển lệch trục đường $\leq 30°$; loại hẻm	81,3% số ảnh gắn được vào một đường
4	Xem trước 56 đường, mỗi đường 20 vị trí, để chọn đường	Loại 7 đường ven kênh, cầu, đường hầm; chọn 17 đường
5	Chia 17 đường thành train/val/test *trước khi* gán nhãn	10 đường train, 3 đường val, 4 đường test
6	Pilot: 150 ảnh trên 3 đường train, cả 5 người cùng gán mỗi ảnh	Fleiss κ [5] 0,57; viết lại hướng dẫn gán nhãn (v1)
7	Thu thập bộ chính: các vị trí cách nhau 25 m, tối đa 2 ảnh mỗi vị trí từ hai ngày khác nhau, tối đa 420 ảnh mỗi đường, bỏ các vị trí của pilot	Chọn 3.057 ảnh, loại 58 ảnh chụp ban đêm, còn 2.999 ảnh
8	Gán nhãn bộ chính, đo đồng thuận, phân xử (mục 2.3)	Nhãn cuối cho 3.149 ảnh
9	Bổ sung ảnh cho train từ 75 đường mới (mục 2.4)	2.000 ảnh, trong đó 577 ảnh Bị chặn

Cắt ảnh. Mỗi ảnh 360° cho đúng một ảnh cắt: nhìn về bên phải xe, lệch 60° so với hướng di chuyển (góc yaw), nghiêng xuống 4° (góc pitch), trường nhìn 90°, kích thước 640×640 điểm ảnh, lưu dạng JPEG chất lượng 90. Hai quyết định dưới đây dựa trên phép đo thăm dò ngày 23/10/2026, không dựa trên nhãn:

- *Chỉ cắt ảnh bên phải.* Trên 1.166 ảnh 360°, một phép đo tự động (với tiêu chí chặt) phát hiện vỉa hè gần ở 38% ảnh bên phải và 7% ảnh bên trái. Ảnh bên trái phần lớn chỉ thấy lòng đường, dải phân cách hoặc vỉa hè phía đối diện. Hệ quả là vỉa hè bên trái của đường một chiều ít được quan sát.
- *Góc lệch* 60° *và góc nghiêng* 4° cho tỉ lệ quan sát được vỉa hè gần cao nhất trong 6 tổ hợp đã thử (góc lệch 60/75/90°, góc nghiêng 4/10°).

Chia tập theo tuyến đường. Mỗi đường thuộc trọn một tập, nhờ đó mô hình được đánh giá trên các đường chưa từng thấy. Bốn đường test nằm ở bốn khu vực khác nhau. Danh sách đường và tập được xác định ngày 23/10/2026, trước khi có bất kỳ nhãn nào của bộ chính. Hiện việc chia tập đã hoàn tất nhưng *chưa được khóa*, do nhóm còn chờ quyết định cách xử lý các ảnh train nằm gần giao lộ với val/test. Nhóm giữ nguyên các đường test đã định: việc test chỉ có 47 mẫu dương là một hạn chế về độ chính xác của đánh giá, không phải tiêu chí để thay đổi tập dựa trên nhãn đã quan sát.

2.3. Gán nhãn

Nhãn do người gán, theo hướng dẫn gán nhãn phiên bản v1 (bản đã được nhóm thống nhất nguyên văn). Mỗi ảnh được xét qua ba câu hỏi theo thứ tự:

1. Ảnh có quan sát được không? Ảnh mờ, tối hoặc cháy sáng đến mức không thể đánh giá thì gán l.
2. Có thấy vỉa hè gần không? Phải có một đoạn mép vỉa hè nằm dưới vạch 3/5 chiều cao ảnh; nếu không (chỉ thấy lòng đường, vỉa hè ở xa, giao lộ, đầu hẻm, hoặc bị che quá nửa) thì gán l.
3. Lối đi có liên tục không? Nếu không thể đi thẳng qua thì gán 1. Người và xe đang di chuyển không được tính là vật cản; chỉ xét vật cản trong phạm vi tới khoảng giữa ảnh.

Ngoài nhãn chính, người gán ghi lý do khi chọn l (4 lý do), có thể đánh dấu loại vật cản (6 loại, không bắt buộc), ô Khó / không chắc và ghi chú tự do. Giao diện gán nhãn trên Label Studio được cấu hình theo đúng ba câu hỏi trên.

Bảng 4: Phân công gán nhãn

Phần	Ảnh	Cách gán
Test	674	Hai người (Học, Loan) gán độc lập mọi ảnh
Val	486	Hai người (Minh, Khải) gán độc lập mọi ảnh
Train, bộ chính	1.839	Mỗi ảnh một người; 276 ảnh (15%) được người thứ hai gán chéo
Pilot	150	5 người gán theo hướng dẫn v0; sau đó cả 150 ảnh được xem lại theo v1
Ảnh bổ sung	2.000	Mỗi ảnh một người (5 người, mỗi người 400 ảnh được chia ngẫu nhiên); 203 ảnh được người thứ hai kiểm tra chéo

Bảng 4 cho biết phân công gán nhãn. Người gán không thấy tên đường, tập dữ liệu, điểm của mô hình hay phiếu của người khác. Ảnh của các tập được trộn lẫn trong cùng một dự án gán nhãn. Bộ chính có tổng cộng $5 \times 887 = 4.435$ lượt gán, không thiếu lượt nào. Kết quả đồng

thuận và phân xử được trình bày ở mục 4.

2.4. Bổ sung mẫu dương cho train

Sau đợt gán nhãn đầu tiên, train chỉ có 120 mẫu dương (gồm 14 ảnh pilot). Nhóm bổ sung ảnh *chỉ vào train*, theo hướng chủ động tìm mẫu dương của lớp hiếm [6]:

1. **Bộ chọn ảnh.** Hồi quy logistic trên vector đặc trưng (embedding) DINOv2 ViT-B/14 [7], huấn luyện trên 1.989 nhãn train (120 mẫu dương). Bộ chọn này được lựa chọn qua một phép so sánh chỉ dùng nhãn train, theo cách để riêng từng tuyến đường (leave-one-street-out): trong 20% ảnh có điểm cao nhất có 22,0% ảnh Bị chặn, so với 13,9% của bộ chấm điểm cũ (chênh lệch $+8{,}2$ điểm phần trăm, khoảng tin cậy 95% $[4{,}3;\ 11{,}7]$) và 5,8% nếu lấy mẫu ngẫu nhiên.
2. **Chọn đường.** Quét 150 đường chưa sử dụng (mỗi đường 30 ảnh), xếp hạng theo điểm trung bình và lấy 75 đường đứng đầu. Đường trùng tên với đường val/test bị loại, kể cả các đoạn khác của cùng đường.
3. **Chọn ảnh.** Kho ứng viên gồm 5.035 ảnh. Nhóm chọn 2.000 ảnh: 1.400 ảnh có điểm cao nhất (*tầng điểm cao*, điểm $\geq 0{,}61$) và 600 ảnh lấy ngẫu nhiên trong phần còn lại (*tầng ngẫu nhiên*). Các vị trí cách ảnh val/test dưới 40 m bị loại.
4. **Gán nhãn.** Giống phần train của bộ chính, mỗi ảnh do một người gán; người gán không biết ảnh thuộc tầng nào.

Điểm của bộ chọn ảnh *chỉ dùng để chọn ảnh cho người gán, không bao giờ được dùng làm nhãn*. Vì ảnh bổ sung được chọn có chủ đích, phân phối của chúng lệch khỏi phân phối tự nhiên [8]. Tầng ngẫu nhiên (30%) được lấy từ phần còn lại sau khi chọn tầng điểm cao, nên không phải là mẫu ngẫu nhiên vô điều kiện của toàn kho ứng viên; tầng này được giữ để so sánh hiệu suất thu được mẫu dương trên đường mới. Mọi thống kê trong báo cáo đều tách ảnh bổ sung khỏi bộ chính.

2.5. Công cụ và định dạng lưu trữ

Bảng 5 tóm tắt công cụ và định dạng lưu trữ ở từng bước; vị trí lưu từng loại dữ liệu được trình bày ở mục 5.

Bảng 5: Công cụ sử dụng và định dạng lưu trữ

Công việc	Công cụ	Định dạng lưu
Mạng lưới đường, điểm ngữ cảnh	Overpass API, shapely	JSON
Metadata ảnh	Mapillary Graph API, requests, pandas	Parquet
Ảnh 360° gốc	Mapillary (ảnh thu nhỏ 2.048 điểm ảnh)	JPEG
Cắt ảnh	py360convert, Pillow	JPEG 640×640
Danh mục ảnh (manifest)	pandas	CSV UTF-8, mỗi ảnh một dòng
Gán nhãn	Label Studio tự triển khai trên AWS (Docker, Caddy)	Export JSON trên server; bảng nhãn CSV trong repo
Đo đồng thuận, thống kê	pandas, SciPy, scikit-learn	CSV, Markdown
Bộ chọn ảnh, đo độ phủ vỉa hè (chỉ phục vụ chọn mẫu)	PyTorch, Transformers (DINOv2 [7], CLIP [9], SegFormer [10])	Embedding NPZ
Cấu hình đường và tập		YAML
EDA của báo cáo này	pandas, SciPy, Matplotlib	CSV, JSON, PDF, JPEG

Nội dung	Cách thực hiện	Kết quả

3. Quy trình làm sạch và tiền xử lý dữ liệu

Nguyên tắc chung của nhóm là *chỉ lọc dữ liệu bằng quy tắc, không lọc bằng mô hình*, và không chỉnh sửa dữ liệu gốc. Bảng 6 trình bày từng bước làm sạch, cách thực hiện và số lượng ảnh bị loại.

Bảng 6: Các bước làm sạch và tiền xử lý, theo khung báo cáo

Nội dung	Cách thực hiện	Kết quả
Ảnh chụp ban đêm	Loại ảnh có độ sáng trung bình nửa trên của ảnh 360° dưới 90 (thang 0–255). Không lọc theo giờ chụp vì giờ ghi trên Mapillary không đáng tin cậy (nhiều ảnh ghi 18–0 giờ vẫn sáng như ban ngày).	Bộ chính: loại 58/3.057. Kho ứng viên bổ sung: loại 38/5.074
Ảnh không thuộc tuyến đường	Chỉ giữ ảnh cách đường ≤ 20 m và có hướng di chuyển dọc trục đường ($\leq 30°$); loại hẻm.	81,3% ảnh trong khu vực gắn được vào đường
Ảnh không đủ thông tin	Không lọc tự động. Người gán đặt nhãn I kèm lý do; ảnh I bị loại khỏi mô hình nhưng vẫn được giữ trong bảng nhãn.	1.920/5.149 ảnh mang nhãn I
Trùng lặp tuyệt đối	Mỗi ảnh 360° chỉ được dùng một lần; so sánh mã băm MD5 của ảnh cắt.	Xem mục 6.4
Gần trùng	Lấy mẫu thưa: mỗi 25 m một vị trí, tối đa 2 ảnh mỗi vị trí và phải khác ngày chụp. Riêng kho ứng viên bổ sung có thêm bước so sánh mã băm sai phân (dHash) [11] giữa hai ngày chụp của cùng vị trí.	Kho ứng viên bổ sung: loại 1 cặp. Bộ chính: được đánh giá lần đầu trong báo cáo này (mục 6.4)
Dữ liệu thiếu	Metadata lấy từ API; ảnh thiếu tọa độ hoặc hướng di chuyển không gắn được vào đường nên đã bị loại ở bước gắn đường. Với nhãn, mọi lượt gán đều bắt buộc chọn nhãn chính.	Xem bảng 11

Nội dung	Cách thực hiện	Kết quả
Chuẩn hóa, biến đổi	Chiếu ảnh 360° về ảnh phối cảnh 640×640 điểm ảnh với cùng tham số cho mọi ảnh (mục 2.2). Chưa chuẩn hóa giá trị điểm ảnh; bước này thuộc giai đoạn huấn luyện.	Mọi ảnh có cùng kích thước và góc nhìn
Chuyển đổi kiểu dữ liệu	Nhãn Label Studio (chuỗi tiếng Việt) → mã 0/1/l. Mã ảnh 360° (số 64 bit) → mã ảnh 8 ký tự không để lộ nguồn cho người gán. Thời gian chụp được giữ dạng chuỗi ISO có múi giờ.	Áp dụng thống nhất cho mọi bảng nhãn của bộ chính, pilot và ảnh bổ sung
Kiểm tra nhất quán	Bước thu thập từ chối các đường đã thuộc tập khác; báo cáo này kiểm tra lại toàn bộ khóa, tập, đường và tọa độ.	Mục 6.4

Các việc chưa thực hiện: rà soát nội dung nhạy cảm trong ảnh (ngoài phần làm mờ sẵn của Mapillary) và khóa danh sách chia tập.

4. Đảm bảo chất lượng dữ liệu

4.1. Tiêu chí dữ liệu tốt cho bài toán này

Bảng 7 nêu sáu tiêu chí chất lượng và cách kiểm tra từng tiêu chí.

Bảng 7: Tiêu chí chất lượng và cách kiểm tra

Tiêu chí	Cách kiểm tra	Loại kiểm tra
Nhãn đúng định nghĩa và nhất quán giữa người gán	Gán đôi val/test, gán chéo 15% train, Cohen κ [12] với ngưỡng 0,6 đặt ra trong đề cương; phân xử mọi ảnh bất đồng	Thủ công và tự động
Tập đánh giá theo phân phối tự nhiên	Val/test chỉ gồm ảnh bộ chính; ảnh được chọn theo điểm chỉ đưa vào train; ghi tầng lấy mẫu vào manifest	Theo thiết kế
Không rò rỉ giữa các tập	Chia theo đường; loại các vị trí cách val/test dưới 40 m khi bổ sung ảnh; kiểm tra khoảng cách và ảnh gần trùng giữa các tập (mục 6.4)	Tự động và kiểm tra trực quan
Truy được nguồn gốc	Mỗi ảnh có một dòng trong manifest: mã ảnh gốc, tọa độ, ngày chụp, tài khoản chụp, giấy phép, đường, tập, tầng lấy mẫu	Tự động
Ảnh quan sát được	Bộ lọc ảnh đêm; nhãn l kèm lý do; thống kê độ sáng, độ nét (mục 6.5)	Tự động và thủ công
Đủ mẫu của lớp hiếm	Đếm ảnh Bị chặn ở từng tập, kèm khoảng tin cậy (mục 6.2)	Tự động

4.2. Kiểm tra thủ công: đồng thuận và phân xử

Mục này đánh giá mức nhất quán giữa người gán (bảng 8) và mô tả quy trình phân xử các ảnh bất đồng.

Bảng 8: Đồng thuận giữa hai người gán trên bộ chính (Cohen κ)

Nhóm ảnh	Cặp gán	Số ảnh	Khớp nhau	κ 3 nhãn	κ chỉ 0/1
Test	Học – Loan	674	79%	0,60	0,68
Val	Minh – Khải	486	80%	0,64	0,55
Train gán chéo	10 cặp	276	78%	0,61	0,56

Ghi chú: κ chỉ 0/1 được tính trên các ảnh mà cả hai người đều chọn 0 hoặc 1 (test 418 ảnh, val 211 ảnh).

- Cả ba nhóm trong bảng 8 đều đạt ngưỡng 0,6 đặt ra trong đề cương; pilot (theo hướng dẫn v0) chỉ đạt Fleiss κ 0,57. Khoảng tin cậy của các giá trị κ **chưa được tính**.
- Trong 1.436 ảnh được gán đôi có 303 ảnh bất đồng: 193 ảnh 0/l, 51 ảnh 1/l, 59 ảnh 0/1. Như vậy phần lớn bất đồng liên quan tới việc ảnh có đủ thông tin để đánh giá hay không.
- **Phân xử 303 ảnh** được thực hiện qua hai bước. (1) Trợ lý AI Claude (Anthropic) xem từng ảnh mà không thấy phiếu của người gán và đề xuất nhãn kèm lý do; sau đó xem lại riêng 21 ảnh có đề xuất khác cả hai phiếu, lần này có hiển thị phiếu, và sửa 10 ảnh. (2) Khải, người phân xử, duyệt cả 303 đề xuất, giữ nguyên 275 và sửa 28 (9,2%). Nhãn cuối là nhãn do Khải quyết định. Cả 28 nhãn được sửa đều trùng với phiếu của một trong hai người gán ban đầu.
- **7 nhãn cuối khác cả hai phiếu.** Ở 7 ảnh, người phân xử giữ đề xuất của Claude dù đề xuất này khác cả hai phiếu: 3 ảnh test, 2 ảnh val và 2 ảnh train (ví dụ: hai phiếu là 0 và l, nhãn cuối là 1).
- **Phân xử chưa hoàn toàn độc lập.** Đề cương dự kiến người phân xử độc lập, nhưng Khải là một trong hai người gán ở 123/303 ảnh bất đồng, gồm *cả 99 ảnh bất đồng của val* (val do Minh và Khải gán) và 24 ảnh train. Trong 123 ảnh này, nhãn cuối trùng với phiếu của Khải ở 37 ảnh (đề xuất của Claude trùng ở 32 ảnh); trong 14 nhãn Khải sửa, 9 nhãn được đổi về phiếu của chính Khải. Vì vậy, nhãn val cần được diễn giải có tính đến hạn chế này.
- **Pilot.** Cả 150 ảnh được xem lại theo hướng dẫn v1 theo cùng quy trình: Claude đề xuất, Phúc duyệt và sửa 3 ảnh. So với phiếu v0, 25 ảnh có nhãn cuối khác nhãn đa số; 5 ảnh khác hòa phiếu ở v0 nên không có nhãn đa số.

Ảnh bổ sung. Mỗi ảnh chỉ có một người gán nên không tính được κ. Ảnh được chia ngẫu nhiên cho người gán, nhưng tỉ lệ Bị chặn của từng người chênh lệch rõ (Học 0,43, Loan 0,19, tính trên nhãn trước kiểm tra chéo; kiểm định χ^2 trên bảng người gán $\times$ nhãn, $p = 4 \cdot 10^{-15}$). Giá trị p này giả định các ảnh độc lập và chưa xét sự phụ thuộc theo đường, nên chỉ mang tính tham khảo; để xác nhận khác biệt giữa người gán, cần cho nhiều người cùng gán một mẫu ảnh độc lập. Một thành viên đã kiểm tra chéo độc lập 203 ảnh thuộc danh sách 264 ảnh bị nghi ngờ: 186 ảnh (92%) trùng nhãn gốc và 17 nhãn được đổi. Do 203 ảnh này được chọn vì bị nghi ngờ,

chúng *không đại diện* cho 2.000 ảnh; vì vậy mức nhiễu nhãn của ảnh bổ sung **chưa đo được**.

Bảng 9 tổng hợp nguồn gốc của nhãn cuối.

Bảng 9: Nguồn của nhãn cuối

Nhãn cuối đến từ	Ảnh	Ghi chú
Hai người gán trùng nhau	1.133	Val, test và phần train gán chéo của bộ chính
Một người gán (train bộ chính)	1.563	
Phân xử: giữ nhãn đề xuất	275	Khải giữ nhãn Claude đề xuất
Phân xử: sửa nhãn đề xuất	28	Khải sửa; trùng phiếu của một người gán
Xem lại pilot: giữ nhãn đề xuất	147	Phúc giữ nhãn Claude đề xuất
Xem lại pilot: sửa nhãn đề xuất	3	Phúc sửa
Một người gán (ảnh bổ sung)	1.983	186 ảnh trong đó đã được kiểm tra chéo và trùng nhãn gốc
Kiểm tra chéo (ảnh bổ sung)	17	Nhãn được đổi theo người kiểm tra chéo

4.3. Kiểm tra tự động

- Trong quy trình thu thập và gán nhãn: bước thu thập từ chối các đường đã thuộc tập khác và các đường trùng tên với đường val/test; bước cập nhật giao diện gán nhãn kiểm tra cả 5 dự án gán nhãn đều dùng đúng giao diện v1; bước đo đồng thuận kiểm tra đủ số lượt gán và phát hiện các lượt lưu trùng.
- Trong báo cáo này: kiểm tra khóa, tập, đường, tọa độ, ngoại lệ, ảnh trùng và gần trùng, khoảng cách giữa các tập; kết quả được trình bày ở mục 6.4.

5. Lưu trữ và quản lý dữ liệu

Bảng 10: Tổ chức thư mục dữ liệu

Thư mục / file	Nội dung	Trong git
`configs/streets_v1.yaml`	17 đường của bộ chính và tập của từng đường	Có
`configs/streets_train_extra.yaml`	75 đường của đợt bổ sung	Có
`data/manifest/`	Mỗi ảnh một dòng: nguồn gốc, tọa độ, ngày chụp, đường, tập, tầng lấy mẫu; bảng phân công gán nhãn	Có
`data/labels/main_labels_v1.csv`	Nhãn cuối của bộ chính và pilot (3.149 dòng)	Có
`data/labels/train_extra_labels_v2.csv`	Nhãn cuối của ảnh bổ sung (2.000 dòng)	Có
`data/labels/*_report/`	Từng lượt gán, báo cáo đồng thuận, bảng phân xử	Có
`data/labels/raw/`	Bản xuất gốc từ Label Studio (có email tài khoản)	Không
`data/streets/`	Bảng xếp hạng đường, điểm của bộ chọn ảnh, kết quả phân tích thăm dò	CSV: có
`data/raw/`	OSM, metadata Mapillary, ảnh 360°, embedding	Không
`data/crops/`	Ảnh cắt 640×640, tách thư mục cho bộ chính, pilot và ảnh bổ sung	Không
`docs/data_report/`	Báo cáo này, hình và bảng số liệu EDA	Có

- **Khóa chính** là mã ảnh 8 ký tự. Bảng nhãn và manifest được ghép với nhau theo khóa này; manifest ghi đường dẫn tới ảnh cắt.
- **Ảnh không được đưa lên git** (bảng 10) vì dung lượng và giấy phép; ảnh có thể được dựng lại từ manifest (mã ảnh gốc và góc quay) bằng script của nhóm. Ảnh dựng lại khác bản trên server do nén JPEG lại (lệch trung bình 1,35–1,5 mức xám, đo trên 5 ảnh).
- **Phiên bản.** Tên file bảng nhãn có số phiên bản; bản cũ (v1 của nhãn ảnh bổ sung, trước kiểm tra chéo) được giữ lại. Phiếu gốc của từng người vẫn lưu trên Label Studio; nhãn cuối chỉ lưu trong repo.
- **Thông tin xác thực** (token Mapillary, mật khẩu server) nằm trong file cấu hình riêng, không đưa lên git.

6. Phân tích khám phá dữ liệu (EDA)

Quy ước phân tích.

- Mọi thống kê được tách theo sáu nhóm: train, val, test của bộ chính (phân phối tự nhiên), pilot, tầng điểm cao và tầng ngẫu nhiên của ảnh bổ sung. Các kết quả gộp nhiều nhóm đều được ghi chú rõ.
- Nhãn val/test chỉ dùng để mô tả. Không có lựa chọn hay ngưỡng nào trong báo cáo được xác định dựa trên nhãn val/test.
- Khoảng tin cậy 95% của tỉ lệ là khoảng Wilson [13], giả định các ảnh độc lập. Do ảnh cùng đường có xu hướng giống nhau, khoảng thực tế rộng hơn; vì vậy các so sánh quan trọng có thêm khoảng *bootstrap theo đường* (lấy mẫu lại theo nguyên tuyến đường), riêng với val (3 đường) và test (4 đường) chỉ có giá trị tham khảo.
- Mọi số liệu và hình trong mục này do ba script EDA của nhóm sinh ra, không nhập thủ công (phụ lục A).

6.1. Thống kê mô tả

Số mẫu, số thuộc tính, tỉ lệ thiếu

Bảng 11 thống kê số dòng, số cột và dữ liệu thiếu của từng bảng dữ liệu.

Bảng 11: Các bảng dữ liệu: số dòng, số cột, dữ liệu thiếu

Bảng	Dòng	Cột	Dữ liệu thiếu
Nhãn bộ chính và pilot	3.149	8	Chỉ cột lý do: thiếu ở 2.114 dòng, trong đó 1.833 dòng là nhãn 0/1 (không có lý do theo thiết kế) và **281 ảnh l không có lý do**
Nhãn ảnh bổ sung	2.000	11	Chỉ cột lý do: 1.403 dòng, trong đó 7 ảnh l không có lý do
Manifest bộ chính	2.999	21	Không thiếu ô nào
Manifest pilot	150	21	Không thiếu ô nào (không có cột nhóm vị trí)
Manifest ảnh bổ sung	2.000	25	Không thiếu ô nào
Từng lượt gán, bộ chính	4.435	13	Lý do, loại vật cản, ghi chú: thiếu theo thiết kế (không bắt buộc)
Từng lượt gán, ảnh bổ sung	2.000	13	Như trên

- **Thuộc tính.** Mỗi ảnh có 1 nhãn và khoảng 20 thuộc tính metadata, gồm 7 thuộc tính số (vĩ độ, kinh độ, độ sáng ảnh 360°, khoảng cách tới tim đường, hướng di chuyển của xe, góc cắt, và điểm của bộ chọn ảnh đối với ảnh bổ sung); các thuộc tính còn lại là thuộc tính phân loại hoặc định danh (đường, tập, tài khoản chụp, chuỗi ảnh, thời gian chụp, tầng lấy mẫu, nguồn nhãn). Đầu vào của mô hình chỉ là ảnh; metadata được dùng để chia tập, truy nguồn và kiểm tra.
- **Metadata không thiếu ô nào** trên toàn bộ 5.149 ảnh, vì ảnh thiếu tọa độ hoặc hướng di chuyển không gắn được vào đường nên không thể được chọn.
- **281 ảnh l của bộ chính và pilot không ghi lý do**, gồm 162 ảnh có nhãn sau phân xử, 63 ảnh pilot (được xem lại theo v1 nhưng không ghi lý do), 55 ảnh mà hai người cùng chọn l nhưng khác lý do, và 1 ảnh chỉ có một người gán. Vì vậy, thống kê lý do chỉ tính trên 1.035/1.253 ảnh l của bộ chính. Nhãn chính không bị ảnh hưởng.

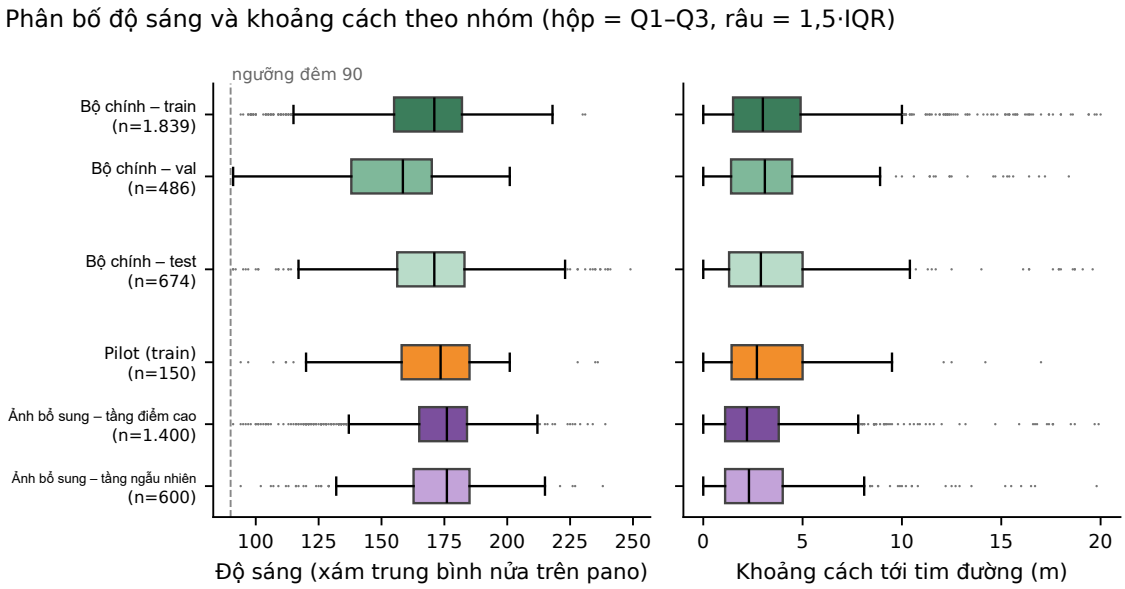
Thống kê cơ bản của các biến số

Bảng 12 và hình 1 mô tả hai biến số chính theo từng nhóm; bảng 13 mô tả các biến số còn lại.

Bảng 12: Thống kê mô tả hai biến số chính của metadata, theo nhóm

Nhóm	n	Trung bình	Trung vị	Phương sai	Nhỏ nhất	Lớn nhất	IQR
Độ sáng ảnh 360° (trung bình nửa trên, thang 0–255)							
Bộ chính, train	1.839	166,8	171,0	448,6	94	231	27,0
Bộ chính, val	486	154,5	158,5	468,9	91	201	32,0
Bộ chính, test	674	169,4	171,0	564,2	91	249	26,8
Pilot	150	169,2	173,5	573,5	94	236	27,0
Ảnh bổ sung, tầng điểm cao	1.400	172,0	176,0	366,8	91	239	19,0
Ảnh bổ sung, tầng ngẫu nhiên	600	172,7	176,0	377,9	94	238	22,3
Khoảng cách từ vị trí chụp tới tim đường (m)							
Bộ chính, train	1.839	3,70	3,0	9,67	0,0	20,0	3,40
Bộ chính, val	486	3,46	3,1	8,53	0,0	18,4	3,08
Bộ chính, test	674	3,54	2,9	9,48	0,0	19,6	3,70
Pilot	150	3,45	2,7	7,98	0,0	17,0	3,58
Ảnh bổ sung, tầng điểm cao	1.400	2,87	2,2	6,81	0,0	19,9	2,70
Ảnh bổ sung, tầng ngẫu nhiên	600	2,96	2,3	7,24	0,0	19,8	2,90

Ghi chú: IQR: khoảng tứ phân vị (hiệu giữa tứ phân vị thứ ba và tứ phân vị thứ nhất).



Hình 1: Phân bố độ sáng ảnh 360° và khoảng cách tới tim đường theo nhóm

Bảng 13: Thống kê mô tả các biến số còn lại của metadata

Nhóm	n	Trung bình	Trung vị	Phương sai	Nhỏ nhất	Lớn nhất	IQR
Vĩ độ (° Bắc)							
Bộ chính, gộp	2.999	10,7751	10,7757	$2{,}7 \cdot 10^{-4}$	10,7501	10,8149	0,0274
Ảnh bổ sung, gộp	2.000	10,7812	10,7860	$4{,}3 \cdot 10^{-4}$	10,7450	10,8150	0,0359
Kinh độ (° Đông)							
Bộ chính, gộp	2.999	106,6792	106,6813	$2{,}3 \cdot 10^{-4}$	106,6500	106,7059	0,0285
Ảnh bổ sung, gộp	2.000	106,6813	106,6813	$3{,}1 \cdot 10^{-4}$	106,6500	106,7234	0,0291
Hướng di chuyển của xe (°, 0 = hướng Bắc)							
Bộ chính, gộp	2.999	166,5	164,7	10.589,6	0,0	360,0	193,3
Ảnh bổ sung, gộp	2.000	178,0	167,5	10.050,7	0,1	359,6	180,3
Điểm của bộ chọn ảnh (chỉ có ở ảnh bổ sung, thang 0–1)							
Tầng điểm cao	1.400	0,799	0,798	0,012	0,610	0,996	0,191
Tầng ngẫu nhiên	600	0,231	0,188	0,032	0,001	0,607	0,286
Thời gian gán một ảnh (giây, tính theo lượt gán)							
Bộ chính	4.435	51,5	3,7	2.285.741	0,5	77.451	6,9
Ảnh bổ sung	2.000	13,9	4,5	24.475	0,9	6.678	5,3

Ghi chú: Góc cắt không được đưa vào bảng vì là hằng số (60° về bên phải) với mọi ảnh.

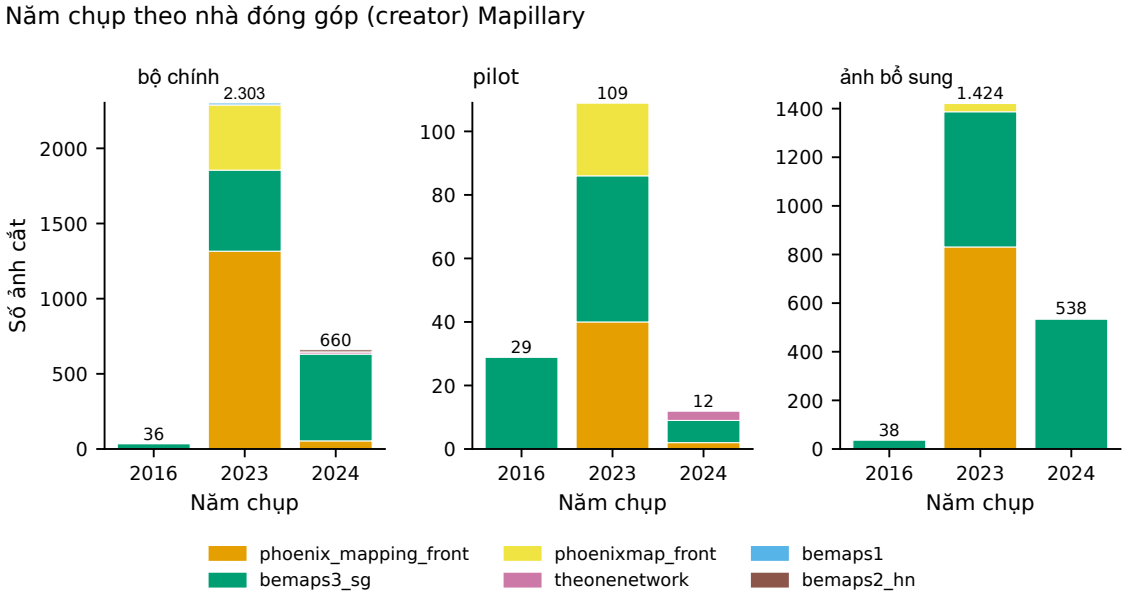
- **Độ sáng** (bảng 12, hình 1). Không ảnh nào có độ sáng dưới ngưỡng lọc ảnh đêm (nhỏ nhất là 91). Ảnh tập val tối hơn các nhóm khác (trung vị 158,5 so với 171); do val chỉ có 3 đường, đây có thể là đặc điểm riêng của ba đường này.
- **Khoảng cách tới tim đường** bị giới hạn trên ở 20 m theo quy tắc gắn đường. Ảnh bổ sung gần tim đường hơn (trung vị 2,2 m so với 3,0 m), phù hợp với việc 71% ảnh bổ sung đến từ đường nhỏ.
- **Tọa độ** (bảng 13) nằm trong khung nghiên cứu, trừ 2 ảnh bổ sung lệch ra ngoài dưới 4 m (mục 6.4). Ảnh bổ sung phân tán rộng hơn bộ chính (IQR của vĩ độ là 0,0359 so với 0,0274) vì đến từ 75 đường thay vì 17 đường.
- **Hướng di chuyển của xe** trải đều trên toàn dải 0–360° (IQR xấp xỉ 190°), không tập trung vào một hướng. Thuộc tính này chỉ được dùng để gắn ảnh vào đường và để cắt ảnh về phía bên phải xe.
- **Điểm của bộ chọn ảnh** (chỉ có ở ảnh bổ sung): tầng điểm cao có trung vị 0,80 (0,61–1,00),

tầng ngẫu nhiên có trung vị 0,19 (0,00–0,61).

- **Thời gian gán một ảnh** lệch phải rất mạnh: trung vị là 3,7 giây (bộ chính, 4.435 lượt) và 4,5 giây (ảnh bổ sung), trong khi giá trị lớn nhất lên tới 77.451 giây do một số tác vụ bị để mở. Vì vậy, trung vị là thước đo phù hợp hơn trung bình. Thời gian gán của pilot **chưa được đo** trong báo cáo này.

Phân bố theo thuộc tính phân loại

Hình 2 và bảng 14 trình bày phân bố ảnh theo tài khoản chụp, năm chụp và tháng chụp.



Hình 2: Số ảnh theo năm chụp và tài khoản chụp

Bảng 14: Số ảnh theo tháng chụp (theo dấu thời gian của Mapillary)

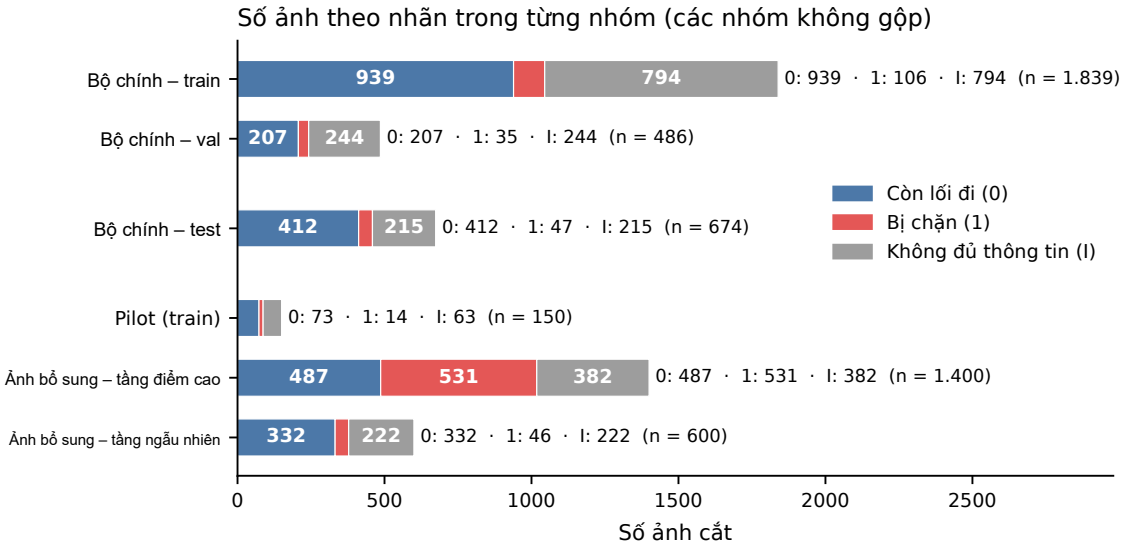
Tháng	1	2	3	4	5	6	7	8	9	10	11	12	Tổng
Bộ chính	299	114	0	552	677	234	0	244	54	321	303	201	2.999
Ảnh bổ sung	146	204	53	93	461	286	0	55	87	96	342	177	2.000

- **Tài khoản chụp** (hình 2). Hai tài khoản bemaps3_sg và phoenix_mapping_front chiếm 84% bộ chính (1.153 và 1.370 trên 2.999 ảnh) và 98% ảnh bổ sung. Do đó, dữ liệu đến từ rất ít loại thiết bị và cách gắn camera.
- **Năm chụp.** Ở bộ chính, năm 2023 có 2.303 ảnh, năm 2024 có 660 ảnh và năm 2016 có 36 ảnh. Toàn bộ 103 ảnh ghi năm 2016 (trên cả ba phần dữ liệu) đều thuộc tài khoản bemaps3_sg và cùng ghi ngày 01/01/2016; nhiều khả năng đây là ngày mặc định, nên năm 2016 **không đáng tin cậy**.

- **Tháng chụp** (bảng 14). Ảnh được chụp trong 10 tháng khác nhau (bộ chính) và 11 tháng khác nhau (ảnh bổ sung), không có ảnh nào vào tháng 7; ảnh bộ chính tập trung vào tháng 4–5 (41%). Tháng 1 bao gồm cả các ảnh mang ngày mặc định 01/01/2016.
- **Giờ chụp** trải khắp các khung giờ trong ngày nhưng không đáng tin cậy: ở bộ chính, 1.080/2.999 ảnh (36%) ghi giờ từ 18 giờ tới trước 6 giờ sáng (ở ảnh bổ sung là 762/2.000, tức 38%), trong khi mọi ảnh được giữ lại đều vượt ngưỡng độ sáng của bộ lọc ảnh đêm. Vì vậy, giờ chụp không được dùng để lọc ảnh (mục 3).
- **Số ảnh mỗi đường.** Bộ chính có 17 đường, mỗi đường 86–348 ảnh (trung vị 150); ảnh bổ sung có 75 đường, mỗi đường 6–157 ảnh (trung vị 21). Hai đường ven kênh Hoàng Sa và Trường Sa#0 đóng góp 274 ảnh bổ sung (14%). Hai đường này từng bị loại khỏi bộ chính vì vỉa hè chủ yếu nằm ở một phía và có ít người đi bộ (bước 4, bảng 3). Tuy nhiên, đợt bổ sung chỉ xếp hạng đường theo điểm của bộ chọn ảnh và không áp dụng lại tiêu chí này: hai đường đứng hạng 49 và 56 trong 75 đường, và do có chiều dài lớn nên đóng góp nhiều ảnh. Hai đường này chỉ thuộc train nên không ảnh hưởng tới val/test, nhưng làm tăng tỉ lệ cảnh ven kênh trong train.

6.2. Phân tích phân bố nhãn

Mục này xét mức mất cân bằng giữa các lớp, tỉ lệ từng lớp theo nhóm, thành phần nhãn của tập train sau khi bổ sung, và sự khác biệt theo đường, theo loại vật cản và theo người gán.



Hình 3: Số ảnh theo nhãn trong từng nhóm

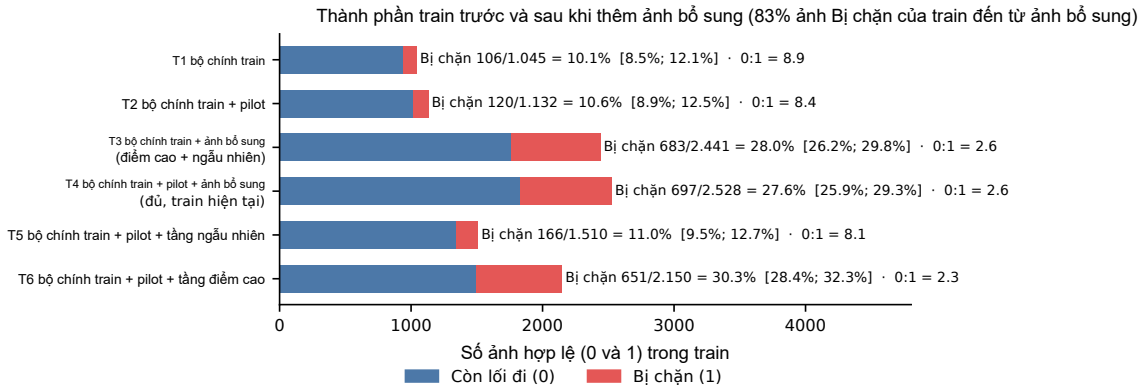
Bảng 15: Tỉ lệ Bị chặn và Không đủ thông tin theo nhóm, khoảng tin cậy 95%

Nhóm	Ảnh	Bị chặn / hợp lệ [Wilson]	Bootstrap theo đường	Tỉ lệ I	0 : 1
Bộ chính, train	1.839	106/1.045 = 10,1% [8,5; 12,1]	[7,9; 14,1]	43,2%	8,9
Bộ chính, val	486	35/242 = 14,5% [10,6; 19,4]	[8,2; 19,2]	50,2%	5,9
Bộ chính, test	674	47/459 = 10,2% [7,8; 13,4]	[5,7; 18,7]	31,9%	8,8
Bộ chính, gộp	2.999	188/1.746 = 10,8% [9,4; 12,3]	[8,7; 13,9]	41,8%	8,3
Pilot	150	14/87 = 16,1% [9,8; 25,2]	[10,0; 18,4]	42,0%	5,2
Ảnh bổ sung, tầng điểm cao	1.400	531/1.018 = 52,2% [49,1; 55,2]	[47,8; 56,6]	27,3%	0,9
Ảnh bổ sung, tầng ngẫu nhiên	600	46/378 = 12,2% [9,2; 15,9]	[8,9; 15,3]	37,0%	7,2

Ghi chú: Ảnh hợp lệ là ảnh có nhãn 0 hoặc 1. Bootstrap theo đường: 1.000 lần lấy mẫu lại.

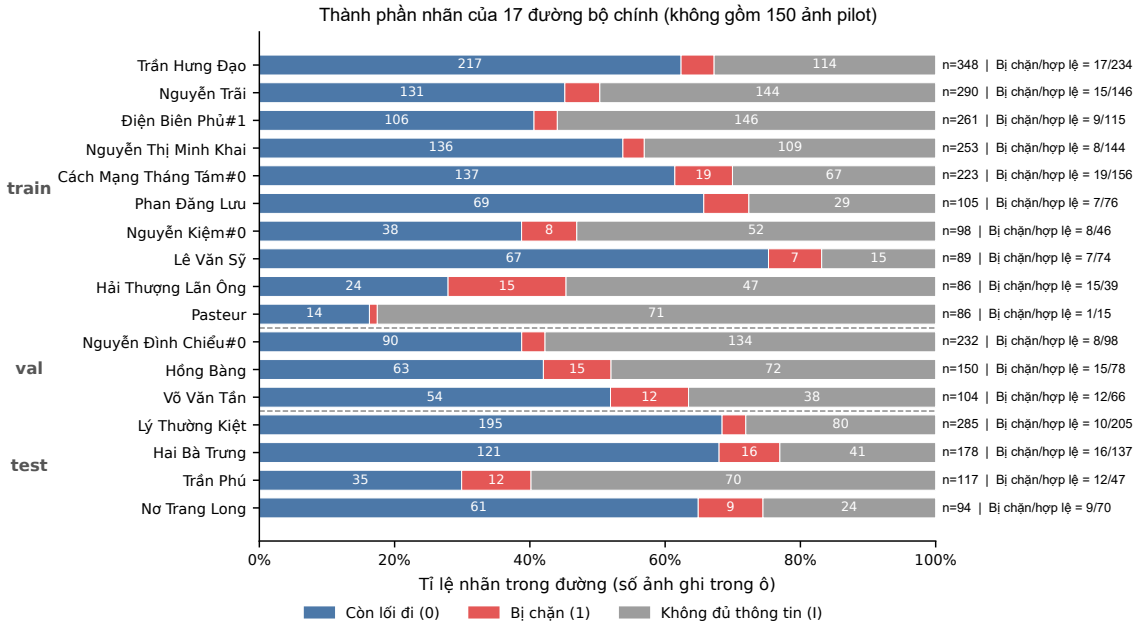
- **Dữ liệu tự nhiên mất cân bằng mạnh** (hình 3, bảng 15): trong các ảnh hợp lệ của bộ chính, Còn lối đi chiếm 89,2% và Bị chặn chiếm 10,8%, tức cứ khoảng 8 ảnh Còn lối đi mới có 1 ảnh Bị chặn. Tính trên mọi ảnh, kể cả ảnh I, tỉ lệ Bị chặn là 6,3% [5,5; 7,2].
- **Tỉ lệ ba lớp 0 / 1 / I trên mọi ảnh:** bộ chính gộp 52,0 / 6,3 / 41,8%; train 51,1 / 5,8 / 43,2%; val 42,6 / 7,2 / 50,2%; test 61,1 / 7,0 / 31,9%; pilot 48,7 / 9,3 / 42,0%; tầng điểm cao 34,8 / 37,9 / 27,3%; tầng ngẫu nhiên 55,3 / 7,7 / 37,0%. Trên toàn bộ dữ liệu: 47,6 / 15,1 / 37,3%.
- **Khoảng tin cậy của tỉ lệ Bị chặn ở ba tập chồng lên nhau** (tỉ lệ lần lượt là 10,1%, 14,5% và 10,2%). Tuy nhiên, điều này chưa đủ để kết luận các tỉ lệ là tương đương.
- **Test chỉ có 47 mẫu dương, val có 35 mẫu dương.** Độ rộng khoảng bootstrap theo đường của test gấp xấp xỉ 2,3 lần độ rộng khoảng Wilson ([5,7; 18,7] so với [7,8; 13,4], tức 13,0 so với 5,6 điểm phần trăm), nên kết quả đánh giá mô hình trên test sẽ có sai số lớn.
- **Ảnh I chiếm 32–50%** tùy tập. Đây là hạn chế cố hữu của nguồn ảnh chụp từ xe.
- **Tỉ lệ ở pilot và tầng điểm cao không phản ánh phân phối tự nhiên:** tỉ lệ Bị chặn của hai nhóm này (16,1% và 52,2%) là kết quả của cách lấy mẫu, không phải tỉ lệ thực tế ngoài đường.
- **Tầng ngẫu nhiên của ảnh bổ sung (12,2%)** có tỉ lệ gần với bộ chính dù được lấy từ các

đường khác; hai khoảng tin cậy chồng lên nhau.



Hình 4: Thành phần tập train trước và sau khi thêm pilot và ảnh bổ sung (chỉ tính ảnh hợp lệ)

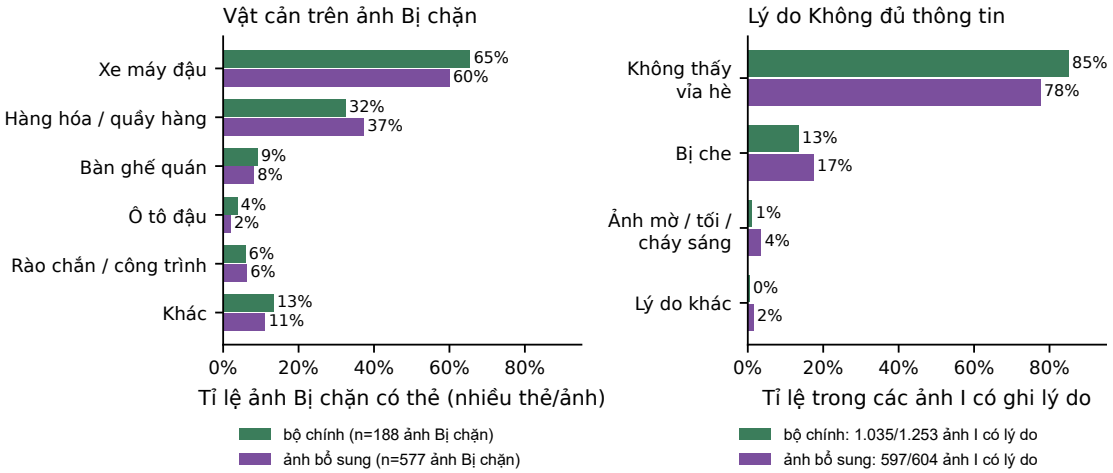
Tập train sau khi bổ sung (hình 4). Train hiện có 2.528 ảnh hợp lệ, trong đó 697 mẫu dương (27,6%, tỉ lệ 0:1 là 2,6), so với 1.132 ảnh hợp lệ và 120 mẫu dương (10,6%) trước khi bổ sung. 577 trong 697 mẫu dương (83%) đến từ ảnh bổ sung. Hệ quả là phân phối nhãn của train khác với val/test (27,6% so với khoảng 10–15%); khi huấn luyện cần tính tới độ lệch này, đồng thời nên báo cáo thêm kết quả khi chỉ huấn luyện trên phần dữ liệu tự nhiên.



Hình 5: Thành phần nhãn của 17 đường thuộc bộ chính (không gồm pilot)

Theo đường (hình 5). Tỉ lệ nhãn khác nhau đáng kể giữa các đường: tỉ lệ Bị chặn trên ảnh hợp lệ dao động từ 4,9% (Lý Thường Kiệt, 10/205) tới 38,5% (Hải Thượng Lãn Ông, 15/39); tỉ lệ I dao động từ 17% (Lê Văn Sỹ) tới 83% (Pasteur, đường một chiều). Ở ảnh bổ sung, trong 25 đường có ít nhất 20 ảnh hợp lệ, tỉ lệ Bị chặn dao động từ 11,1% (Bạch Đằng#0, 4/36) tới 76,2% (Ung Văn Khiêm, 16/21), trung vị 40,0%; các tỉ lệ này gộp hai tầng nên chịu ảnh hưởng của cách

chọn ảnh. Tuyến đường là thuộc tính có mức liên hệ với nhãn mạnh nhất (mục 6.3), vì vậy việc chia tập theo đường là cần thiết để tránh đánh giá quá lạc quan.

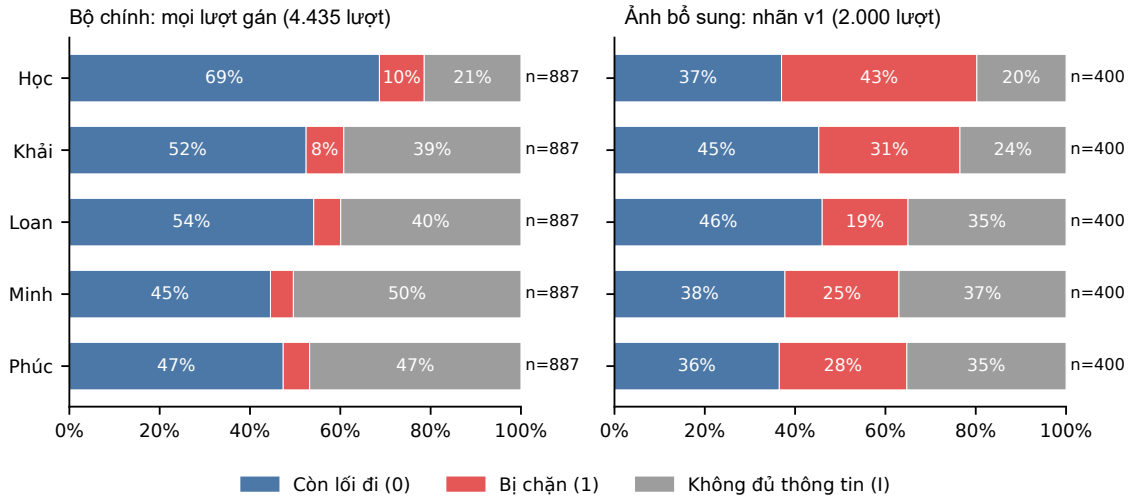


Hình 6: Loại vật cản trên ảnh Bị chặn và lý do gán nhãn Không đủ thông tin, bộ chính so với ảnh bổ sung

Đa dạng của vật cản và lý do gán nhãn I (hình 6).

- Trên ảnh Bị chặn, xe máy đậu là loại vật cản phổ biến nhất (bộ chính 123/188 ảnh, 65%; ảnh bổ sung 346/577 ảnh, 60%), tiếp theo là hàng hóa và quầy hàng (32% và 37%). Ô tô đậu hiếm gặp (4% và 2%). Một ảnh có thể có nhiều loại vật cản. Cơ cấu vật cản của hai phần dữ liệu khá tương đồng.
- Lý do gán I chủ yếu là không thấy vỉa hè (bộ chính 880/1.035 ảnh có ghi lý do, 85%; ảnh bổ sung 463/597 ảnh, 78%), tiếp theo là vỉa hè bị che khuất. Ảnh mờ, tối hoặc cháy sáng chỉ có 12 và 21 ảnh.
- Thẻ vật cản là thông tin phụ, không bắt buộc: 13 ảnh Bị chặn của bộ chính và 6 ảnh bổ sung không có thẻ nào. Thẻ vật cản của pilot **chưa được thống kê**.

Ghi chú: Thẻ vật cản của một ảnh là hợp của các thẻ từ những lượt gán nhãn 1 cho ảnh đó.



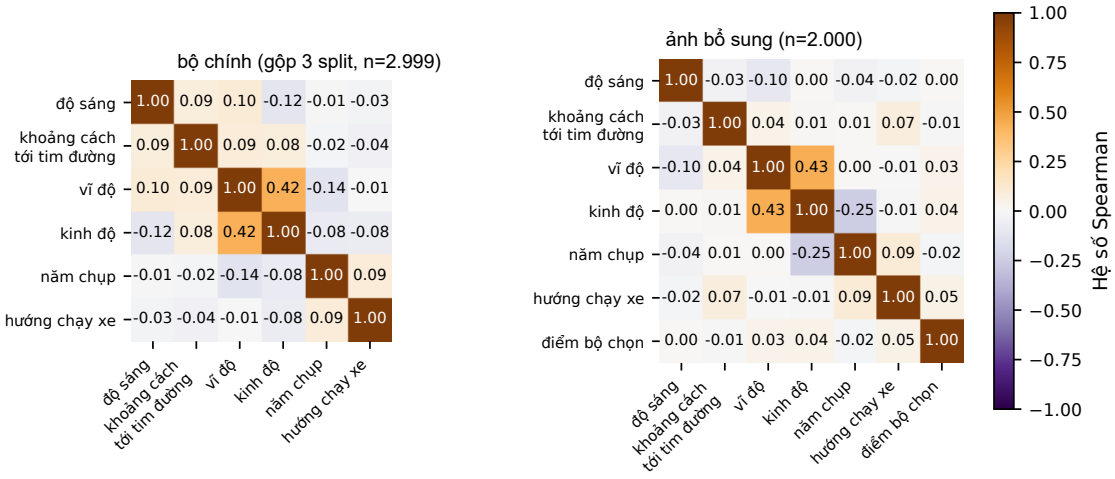
Hình 7: Tỉ lệ nhãn theo người gán; phần ảnh bổ sung dùng nhãn của từng người trước kiểm tra chéo

Theo người gán (hình 7). Ở ảnh bổ sung, ảnh được chia ngẫu nhiên cho người gán nên chênh lệch giữa người gán gợi ý sự khác biệt trong cách gán, nhưng cần cho nhiều người cùng gán một mẫu ảnh để xác nhận: tỉ lệ Bị chặn dao động từ 19% (Loan) tới 43% (Học). Ở bộ chính, mỗi người gán một phần ảnh khác nhau (hai người gán test, hai người gán val), nên tỉ lệ theo người gán bị lẫn với ảnh hưởng của tập và không so sánh trực tiếp được.

6.3. Phân tích mối quan hệ giữa các thuộc tính

Đầu vào của mô hình là ảnh, không phải metadata. Mục này trả lời hai câu hỏi: các thuộc tính metadata có trùng lặp thông tin với nhau không, và có thuộc tính nào liên hệ với nhãn tới mức cần đề phòng mô hình học lối tắt (shortcut learning) không. Với biến số, mức liên hệ với nhãn được đo bằng AUC (diện tích dưới đường cong ROC; 0,5 nghĩa là không phân biệt được hai lớp); với biến phân loại, mức liên hệ được đo bằng Cramér's V hiệu chỉnh độ chệch.

Tương quan hạng giữa các thuộc tính số của siêu dữ liệu



Hình 8: Tương quan hạng Spearman giữa các thuộc tính số của metadata

- **Tương quan** (hình 8). Cặp duy nhất có tương quan đáng kể là vĩ độ–kinh độ ($\rho = 0{,}42$ ở bộ chính, 0,43 ở ảnh bổ sung), do hình dạng khu vực nghiên cứu và hướng của các tuyến đường. Mọi cặp còn lại có $|\rho| \leq 0{,}14$ ở bộ chính và $\leq 0{,}25$ ở ảnh bổ sung.
- **Đa cộng tuyến.** Hệ số phóng đại phương sai (VIF) lớn nhất là 1,27 (vĩ độ) và 1,25 (kinh độ) ở bộ chính, do hai biến này tương quan với nhau; các biến khác đều dưới 1,1. Không thấy dấu hiệu đa cộng tuyến đáng kể giữa các biến được kiểm tra.

Bảng 16: Liên hệ giữa thuộc tính và nhãn Bị chặn so với Còn lối đi (ảnh hợp lệ)

Thuộc tính	Bộ chính, gộp (n = 1.746)	Ảnh bổ sung (n = 1.396)
Biến số: AUC (0,5 = không phân biệt), khoảng bootstrap theo đường		
Độ sáng ảnh 360°	0,53 [0,47; 0,59]	0,49 [0,45; 0,53]
Khoảng cách tới tim đường	0,54 [0,50; 0,58]	0,46 [0,43; 0,49]
Vĩ độ	0,45 [0,37; 0,52]	khoảng tin cậy chứa 0,5
Kinh độ	0,45 [0,35; 0,54]	khoảng tin cậy chứa 0,5
Điểm của bộ chọn ảnh	không có	0,78 [0,75; 0,81]
Biến phân loại: Cramér's V hiệu chỉnh độ chệch [14] (0 = không liên hệ)		
Tuyến đường	0,18	0,29
Loại đường	0,00 (chỉ 2 mức)	0,14 [0,06; 0,24]
Tài khoản chụp	0,00	0,03
Năm chụp	0,02	0,03

Ghi chú: Giá trị p của các kiểm định này được tính với giả định ảnh độc lập nên quá lạc quan; báo cáo chỉ dựa vào độ lớn hiệu ứng.

- **Tuyến đường là thuộc tính có mức liên hệ với nhãn mạnh nhất**, với cả Bị chặn (V = 0,18) lẫn l (V = 0,28 ở bộ chính). Đây là lý do chính để chia tập theo đường.
- **Loại đường** (theo phân loại của OSM) có liên hệ với nhãn ở ảnh bổ sung: trong tầng ngẫu nhiên, tỉ lệ Bị chặn trên ảnh hợp lệ là 13,7% ở đường nhánh (tertiary, 34/248) và 20% ở đường khu dân cư (residential, 4/20), so với 7,0% ở đường chính (primary, 3/43) và 7,5% ở đường cấp hai (secondary, 5/67). Do cỡ mẫu các nhóm nhỏ, khoảng tin cậy rộng. Bộ chính chỉ gồm đường lớn nên không kiểm tra được.
- **Độ sáng, khoảng cách, tọa độ, tài khoản chụp và năm chụp** gần như không phân biệt được nhãn: mọi khoảng tin cậy của bộ chính đều chứa 0,5.
- **Điểm của bộ chọn ảnh** liên hệ mạnh với nhãn ở ảnh bổ sung (AUC 0,78). Đây là hệ quả của cách chọn ảnh, và cũng là lý do điểm này không được dùng làm đặc trưng hay nhãn.

Riêng trong train của bộ chính, kinh độ có AUC 0,37 [0,28; 0,47]: ảnh Bị chặn lệch về phía tây. Vì train chỉ có 10 đường, đây nhiều khả năng là khác biệt giữa các đường, không phải một quy luật địa lý.

6.4. Kiểm tra chất lượng dữ liệu

Mục này trình bày các kiểm tra về tính hợp lệ, ngoại lệ, trùng lặp và rò rỉ giữa các tập. Trong mục này, *kiểm tra trực quan* là quan sát trên các bảng ảnh tổng hợp (contact sheet), không phải phép đo.

Tính hợp lệ và nhất quán

Script EDA dạng bảng thực hiện 71 phép kiểm tra tự động: 62 phép đạt và 9 phép không đạt (bảng 17). Không có dữ liệu nào bị chỉnh sửa trong quá trình kiểm tra.

Bảng 17: Kết quả kiểm tra tính hợp lệ và nhất quán

Kiểm tra	Kết quả	Chi tiết và cách xử lý
Mã ảnh là duy nhất trong và giữa ba bảng nhãn	Đạt	5.149 mã khác nhau
Nhãn khớp 1:1 với manifest	Đạt	Cả ba phần dữ liệu
Tập và đường khớp giữa nhãn, manifest và cấu hình	Đạt	
Không đường nào thuộc hai tập; không vị trí 25 m nào thuộc hai tập	Đạt	Ảnh bổ sung không dùng chung đường với bộ chính
Không ảnh 360° nào được dùng hai lần	Đạt	Trong từng phần và giữa ba phần
Nhãn thuộc {0, 1, I}; cắt phía phải; góc 60°; giấy phép hợp lệ	Đạt	
Mọi ảnh được giữ lại có độ sáng trên ngưỡng lọc ảnh đêm	Đạt	Nhỏ nhất là 91; ảnh bị loại có độ sáng 27–90. Phép kiểm tra chặt "mọi ảnh bị loại đều dưới 90" không đạt vì 1 ảnh trong kho ứng viên bổ sung ghi đúng 90 (giá trị đã làm tròn)
Ảnh I có ghi lý do	Không đạt	281 + 7 ảnh, thiếu do cấu trúc quy trình (mục 6.1). Giữ nguyên
Thẻ vật cản chỉ xuất hiện khi lượt gán chọn 1	Không đạt	285/4.435 lượt (bộ chính) và 119/2.000 lượt (ảnh bổ sung) có thẻ nhưng nhãn là 0 hoặc I. Thống kê vật cản chỉ dùng các lượt chọn 1
Tọa độ nằm trong khung nghiên cứu	Không đạt	2 ảnh bổ sung nằm ngoài khung dưới 4 m (do làm tròn biên khung). Giữ nguyên
Hướng di chuyển nằm trong $[0, 360)$	Không đạt	1 ảnh ghi 360,0 (tương đương 0). Không ảnh hưởng tới phân tích
Ngày chụp không phải ngày mặc định	Không đạt	103 ảnh ghi ngày 01/01/2016. Năm chụp không được dùng để lọc hay chia tập
Ảnh pilot không trùng vị trí với ảnh bộ chính	Không đạt	5 ảnh pilot cách ảnh bộ chính dưới 5 m (gần nhất 2,9 m). Cả hai phía đều thuộc train nên không gây rò rỉ giữa các tập

Ngoại lệ và dữ liệu bất thường

- **Metadata.** Theo quy tắc $1{,}5\times$IQR [15], bộ chính có 81 ảnh ngoại lệ về độ sáng ảnh 360° (63 thấp, 18 cao) và 113 ảnh có khoảng cách tới tim đường lớn; ở ảnh bổ sung, các con số tương ứng là 113 và 71 ảnh. Đây là phần đuôi của các phân bố lệch, không phải lỗi nhập liệu; mọi giá trị đều nằm trong miền hợp lệ (độ sáng 91–249, khoảng cách 0–20 m).
- **Ảnh cắt.** Trên 5.149 ảnh có 87 ảnh ngoại lệ về độ sáng (7 ảnh quá tối, 80 ảnh quá sáng), 36 ảnh ngoại lệ về độ tương phản và 115 ảnh có độ nét rất thấp (trên thang log). Tổng cộng 308 ảnh vượt ít nhất một ngưỡng ngoại lệ.
- **Ảnh cháy sáng** (trên 20% điểm ảnh bão hòa): 128 ảnh. Tỉ lệ ở test (33 ảnh, 4,9%) và val (25 ảnh, 5,1%) cao hơn ở train (36 ảnh, 2,0%); 27/33 ảnh cháy sáng của test thuộc đường Hai Bà Trưng.
- **Kiểm tra trực quan các ảnh ngoại lệ:** ảnh tối nhất phần lớn chụp trong bóng râm, dưới gầm cầu vượt hoặc khi trời âm u, không phải ảnh đêm; ảnh sáng nhất bị phơi sáng quá mức nhưng nhiều ảnh vẫn quan sát được vỉa hè; ảnh mờ nhất phần lớn là cảnh tối hoặc bị nhòe do chuyển động.
- **Cách xử lý:** không loại ảnh ngoại lệ nào. Các ảnh có chất lượng kém tới mức không đánh giá được đã được người gán xếp vào nhãn l; phần còn lại phản ánh điều kiện chụp thực tế mà mô hình cần xử lý được.

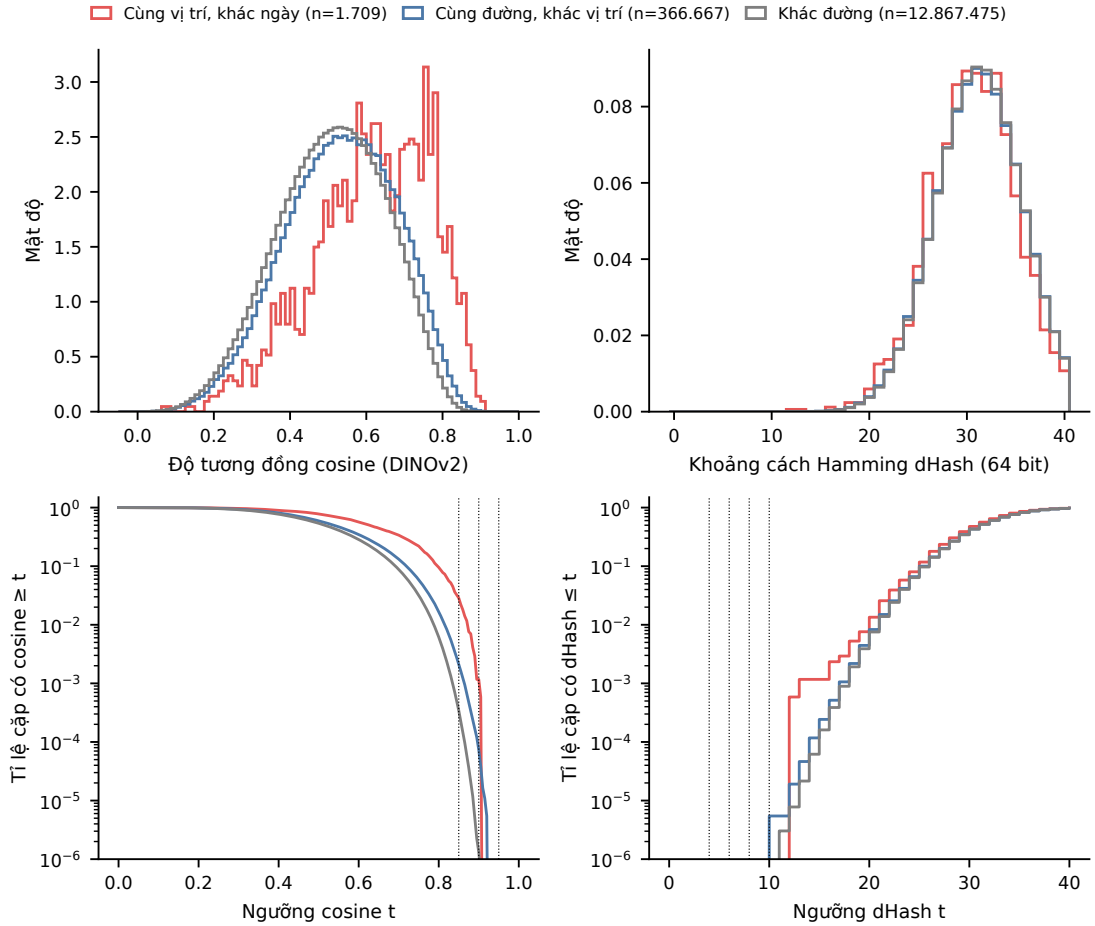
Kiểm tra bộ lọc ảnh đêm (việc còn tồn đọng từ trước). 58 ảnh 360° bị loại của bộ chính và 58 ảnh được giữ lại có độ sáng thấp nhất đã được kiểm tra trực quan. Khoảng 48/58 ảnh bị loại đúng là ảnh đêm; 9 ảnh có vẻ được chụp ban ngày dưới tán cây dày và 1 ảnh chụp lúc chạng vạng (độ sáng 68–89). Trong 58 ảnh được giữ lại đã xem, chưa thấy ảnh đêm nào, khoảng 3 ảnh được chụp lúc chạng vạng; kết quả này chưa đủ để khẳng định cho toàn bộ ảnh được giữ lại. Khoảng 10 ảnh bị loại nhầm (9 ảnh ban ngày, 1 ảnh chạng vạng), tương ứng khoảng 0,3% của 3.057 ảnh đầu vào. 38 ảnh bị loại trong kho ứng viên bổ sung **chưa được xem lại**.

Ghi chú: Các bảng ảnh tổng hợp dùng nội bộ có chứa ảnh val/test nên không được đưa vào báo cáo.

Trùng lặp và gần trùng

- **Trùng lặp tuyệt đối: không có.** Không có hai file nào trùng mã băm MD5, không có hai ảnh nào trùng điểm ảnh sau khi giải nén, và không ảnh 360° nào xuất hiện hai lần (n = 5.149).
- **Bản sao gần như y hệt: không có.** Không có cặp ảnh nào có khoảng cách dHash ≤ 4 (mã băm 64 bit). Cặp gần nhất giữa các tập có dHash bằng 6; kiểm tra trực quan cho thấy đây là hai địa điểm khác nhau có cùng một mảng trời sáng.

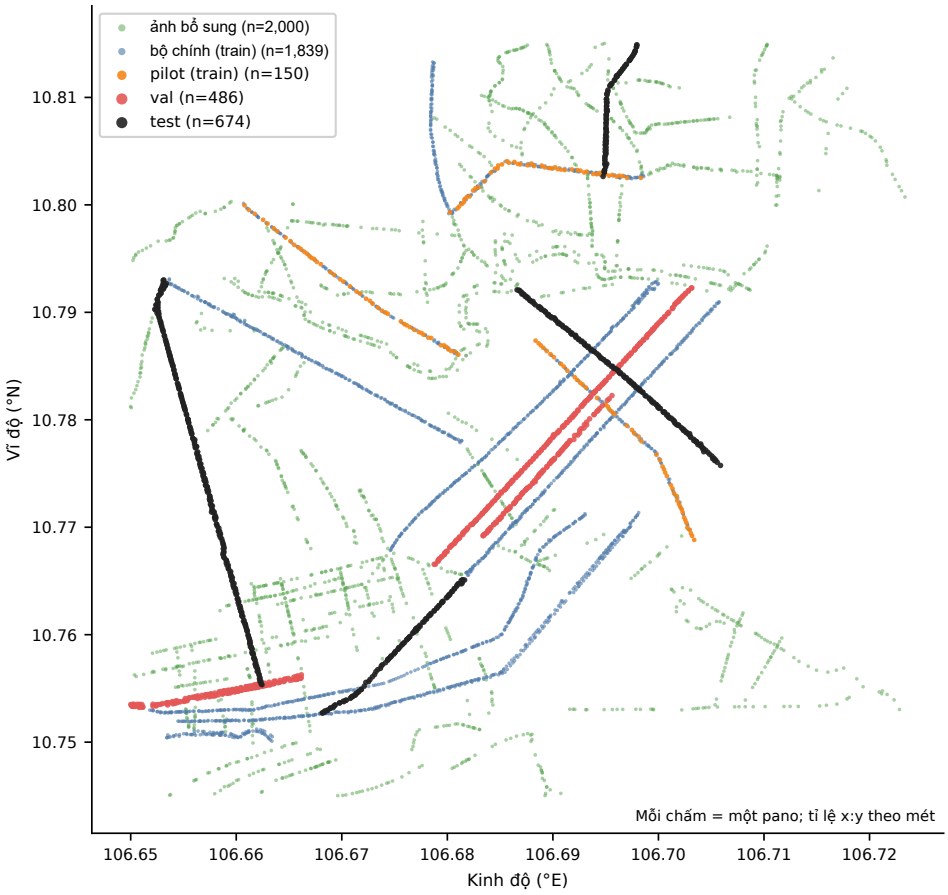
- **Cùng vị trí, khác ngày.** Có 1.709 vị trí có hai ảnh chụp ở hai ngày khác nhau (bộ chính 1.363, ảnh bổ sung 346), và hai ảnh của mỗi vị trí luôn thuộc cùng một tập. Theo phép đo, các cặp này *không* giống nhau về nội dung: dHash nhỏ nhất là 12 (trung vị 31, tương đương các cặp ảnh khác đường); độ tương đồng cosine giữa các vector đặc trưng DINOv2 có trung vị 0,63 và lớn nhất 0,905. Do hai ngày chụp có xe cộ, hàng quán và ánh sáng khác nhau, việc giữ cả hai ảnh là hợp lý.
- **Hệ quả về phương pháp:** cả dHash lẫn độ tương đồng cosine đều không phân biệt được "cùng một địa điểm" với "cảnh tương tự" (hình 9); chỉ khoảng cách địa lý làm được việc này. Vì vậy, báo cáo không đặt ngưỡng gần trùng dựa trên nội dung ảnh.



Hình 9: Phân bố độ tương đồng giữa các cặp ảnh: cùng vị trí khác ngày, cùng đường khác vị trí, khác đường

Rò rỉ giữa các tập

Rò rỉ giữa các tập được đánh giá theo hai cách: theo nội dung ảnh và theo vị trí địa lý (hình 10).



Hình 10: Vị trí của mọi ảnh theo tập. Các đường val/test cắt đường train tại giao lộ

Theo nội dung ảnh. Với mỗi ảnh val/test, ảnh giống nhất ở phía train (bộ chính, pilot, ảnh bổ sung) được tìm theo độ tương đồng cosine.

- Độ tương đồng với ảnh train gần nhất: val có trung vị 0,78, lớn nhất 0,909; test có trung vị 0,79, lớn nhất 0,904. Phân bố này trùng với mức tham chiếu giữa các đường train với nhau (trung vị 0,81, lớn nhất 0,933); nói cách khác, mức tương đồng giữa val/test và train không cao hơn mức tương đồng giữa hai đường train bất kỳ.
- Có 7 ảnh val/test có độ tương đồng cosine $\geq 0{,}90$ với một ảnh train, nhưng cả 7 cặp đều cách nhau 778–3.585 m. Kiểm tra trực quan 20 cặp giống nhau nhất cho thấy đều là hai địa điểm khác nhau có cùng kiểu cảnh (dãy nhà phố, người đi xe máy ở tiền cảnh).

Theo vị trí địa lý. Việc chia theo đường không ngăn được trường hợp đường val/test *cắt* đường train tại giao lộ. Bảng 18 thống kê số ảnh val/test nằm gần ảnh phía train.

Bảng 18: Số ảnh val/test nằm gần một ảnh phía train

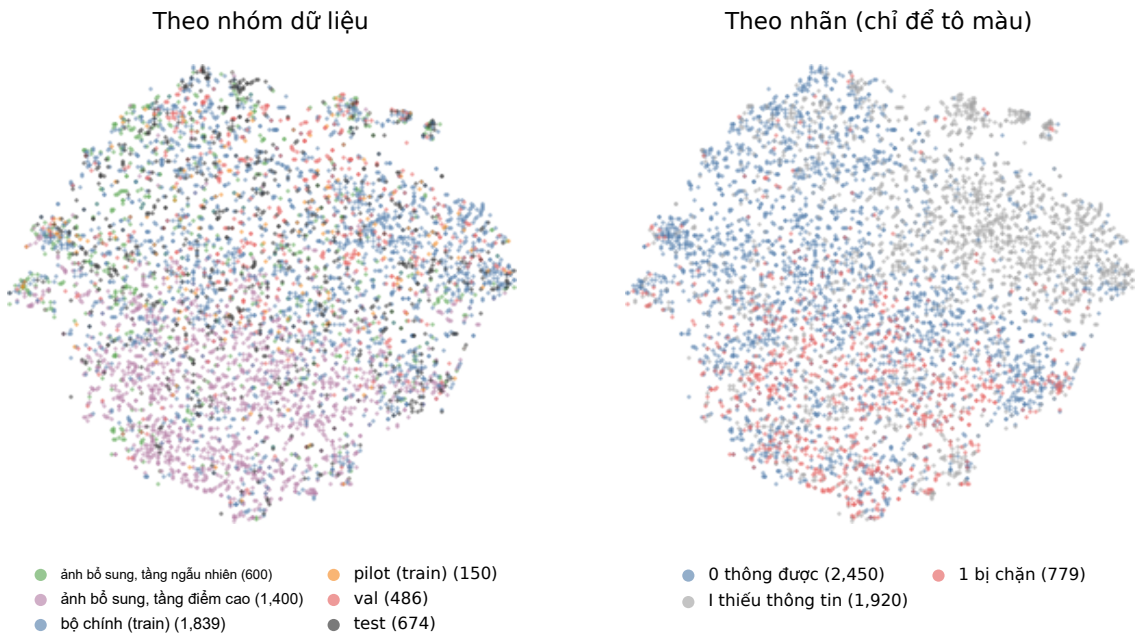
Cặp	Gần nhất (m)	< 15 m	< 25 m	< 40 m	< 100 m
Val (486) – train bộ chính	1,5	6	6	14	47
Val – pilot	17,9	0	1	5	17
Val – ảnh bổ sung	41,6	0	0	0	71
Test (674) – train bộ chính	7,1	8	18	34	88
Test – pilot	20,9	0	2	4	7
Test – ảnh bổ sung	34,3	0	0	3	116

- **52 trên 1.160 ảnh val/test (4,5%) nằm cách một ảnh train dưới 40 m**, liên quan tới 47 ảnh phía train và 13 cặp đường giao nhau (ví dụ Hồng Bàng – Nguyễn Trãi, Lý Thường Kiệt – Cách Mạng Tháng Tám, Hai Bà Trưng – Điện Biên Phủ).
- Kiểm tra trực quan 20 cặp gần nhau nhất (1–14 m): phần lớn nhìn về hai hướng khác nhau, nhưng một số cặp thấy cùng một góc phố (cùng cột điện, biển quảng cáo, hàng rào). Phép đo theo nội dung không phát hiện được các cặp này: độ tương đồng cosine lớn nhất của chúng chỉ là 0,82.
- **Ảnh bổ sung tuân thủ quy tắc 40 m**, trừ 1 ảnh cách ảnh test 34,3 m (do quy tắc được áp dụng cho tâm của ô 25 m, không áp dụng cho từng ảnh).
- 53 trên 551 chuỗi ảnh Mapillary chứa ảnh của cả phía train lẫn val/test (cùng một lượt xe chạy qua nhiều đường). Đây không phải rò rỉ nội dung, nhưng cho thấy cùng một thiết bị và điều kiện chụp xuất hiện ở cả hai phía.

Kế hoạch xử lý (chưa thực hiện, cần nhóm quyết định trước khi khóa chia tập): loại khỏi train các ảnh cách ảnh val/test dưới 40 m, tương tự quy tắc đã áp dụng cho ảnh bổ sung. Quy tắc này chỉ dùng tọa độ, không dùng nhãn val/test, và loại tối đa 47 ảnh train. Phương án thay thế là giữ nguyên dữ liệu và báo cáo kết quả test kèm một lượt đánh giá loại bỏ 52 ảnh gần giao lộ.

Mức khác biệt giữa ảnh bổ sung và bộ chính

Một bộ phân loại tuyến tính trên vector đặc trưng DINOv2, không dùng nhãn vật cản, được huấn luyện để phân biệt hai nhóm ảnh; AUC bằng 0,5 nghĩa là không phân biệt được. Việc đánh giá dùng xác thực chéo (cross-validation) chia theo đường. Bảng 19 trình bày kết quả; hình 11 minh họa phân bố các vector đặc trưng bằng t-SNE.



Hình 11: Hình chiếu t-SNE [16] của embedding DINOv2 cho 5.149 ảnh, tô màu theo nhóm và theo nhãn (nhãn chỉ dùng để tô màu)

Bảng 19: Mức phân biệt được giữa các nhóm ảnh (AUC của bộ phân loại miền)

So sánh	AUC	Diễn giải
Train bộ chính – ảnh bổ sung, tầng điểm cao	0,95	Khác biệt rõ
Train bộ chính – ảnh bổ sung, tầng ngẫu nhiên	0,70	Khác biệt vừa phải
Ảnh bổ sung – val + test	0,83	Khác biệt rõ
Train bộ chính – val + test	0,47	Không phân biệt được
Đối chứng: chia đôi ngẫu nhiên các đường train	0,51	Mức nền

Ghi chú: Trung bình qua các fold; độ lệch chuẩn giữa các fold 0,02–0,08.

- **Chưa phát hiện khác biệt miền ảnh giữa train bộ chính và val/test bằng bộ phân loại đã dùng** (AUC gần 0,5); tuy nhiên, kết quả này chưa chứng minh hai phân phối giống nhau. Với chỉ 17 đường, phép đo không đủ nhạy để phát hiện các khác biệt nhỏ.
- **Giá trị gộp 0,47 che khuất các giá trị dao động mạnh khi tách riêng:** train bộ chính so với val là 0,56, so với test là 0,36, so với pilot là 0,35 (trung bình qua các fold; độ lệch chuẩn giữa các fold tới 0,12). AUC dưới 0,5 ở đây không phải tín hiệu ngược chiều mà cho thấy phép đo không ổn định khi mỗi phía chỉ có vài đường.
- **Ảnh bổ sung thuộc một miền khác**, kể cả tầng ngẫu nhiên (0,70): các ảnh này đến từ những đường nhỏ gần chợ, trong khi val/test là các đường lớn. Tầng điểm cao còn đồng nhất hơn các nhóm khác (độ tương đồng cosine trung bình trong nhóm 0,60 so với 0,49–0,51). Đây là sự đánh đổi của việc bổ sung dữ liệu: có thêm 577 mẫu dương nhưng từ một

dải cảnh hẹp hơn val/test.

- **Giá trị 0,95 của tầng điểm cao bị ước lượng cao một phần**: tầng này được chọn bằng hồi quy logistic trên chính các vector đặc trưng DINOv2 mà bộ phân loại miền sử dụng, nên một phần khả năng phân biệt đến từ chính cách chọn ảnh. Nhận xét này cũng áp dụng cho độ tương đồng cosine trong nhóm và hình t-SNE. Giá trị phản ánh khách quan hơn mức khác biệt về cảnh là của tầng ngẫu nhiên (0,70).
- Trên hình 11, ảnh Bị chặn và ảnh tầng điểm cao tập trung về cùng một vùng, còn ảnh I tập trung ở một vùng khác. Hình t-SNE chỉ dùng để minh họa, không dùng để rút ra kết luận.

Trước khi khóa tập, nhóm cần quyết định phương án xử lý theo khoảng cách địa lý, lưu manifest với phiên bản cố định và chạy lại các thống kê liên quan. Danh sách đường test được giữ nguyên, không thay đổi dựa trên số mẫu dương đã quan sát.

6.5. EDA cho dữ liệu ảnh

Mục này mô tả định dạng, độ phân giải và chất lượng ảnh theo từng nhóm, đồng thời xét mối liên hệ giữa chất lượng ảnh và nhãn. Hình 12 và hình 13 minh họa ảnh của từng nhãn và từng tầng.



Hình 12: Ví dụ ảnh theo nhãn, lấy ngẫu nhiên từ train của bộ chính. © Mapillary contributors, CC BY-SA 4.0



Hình 13: Ví dụ ảnh bổ sung theo tầng lấy mẫu; mỗi tầng gồm 6 ảnh lấy ngẫu nhiên nên tỉ lệ nhãn trong hình không đại diện cho tầng; ô góc trái ghi nhãn của ảnh. © Mapillary contributors, CC BY-SA 4.0

Định dạng và độ phân giải

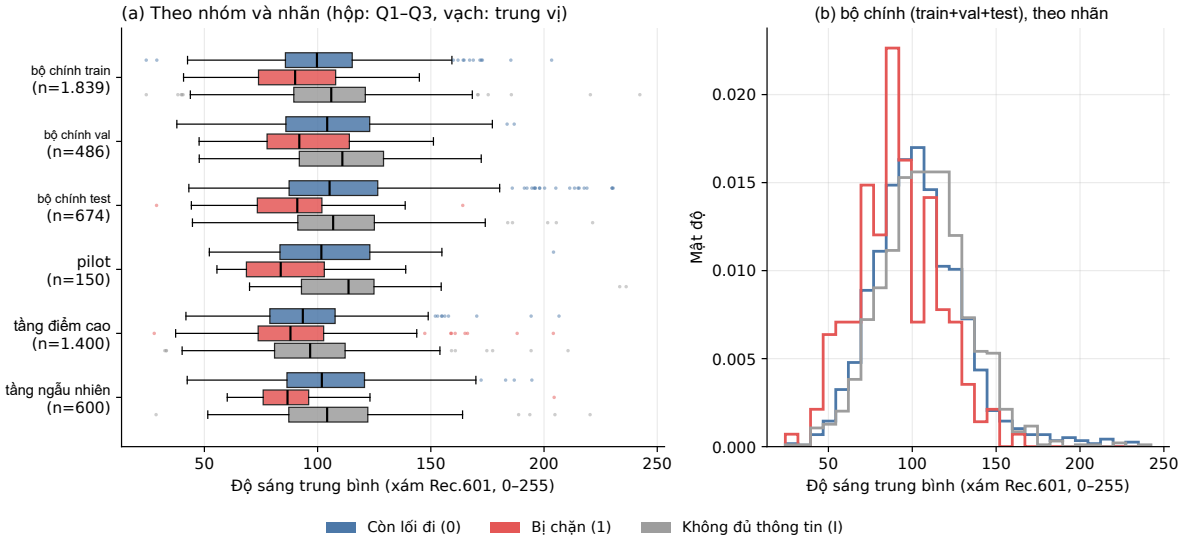
Toàn bộ 5.149 ảnh đều đọc được, ở định dạng JPEG RGB 640×640 điểm ảnh, chất lượng nén ước lượng 90. Dung lượng mỗi ảnh từ 38,5 đến 167,7 KB, trung vị 99,3 KB. Độ phân giải đồng nhất theo thiết kế; do ảnh gốc là ảnh $360°$ đã thu nhỏ còn 2.048 điểm ảnh, các chi tiết nhỏ ở xa bị mất.

Chất lượng ảnh

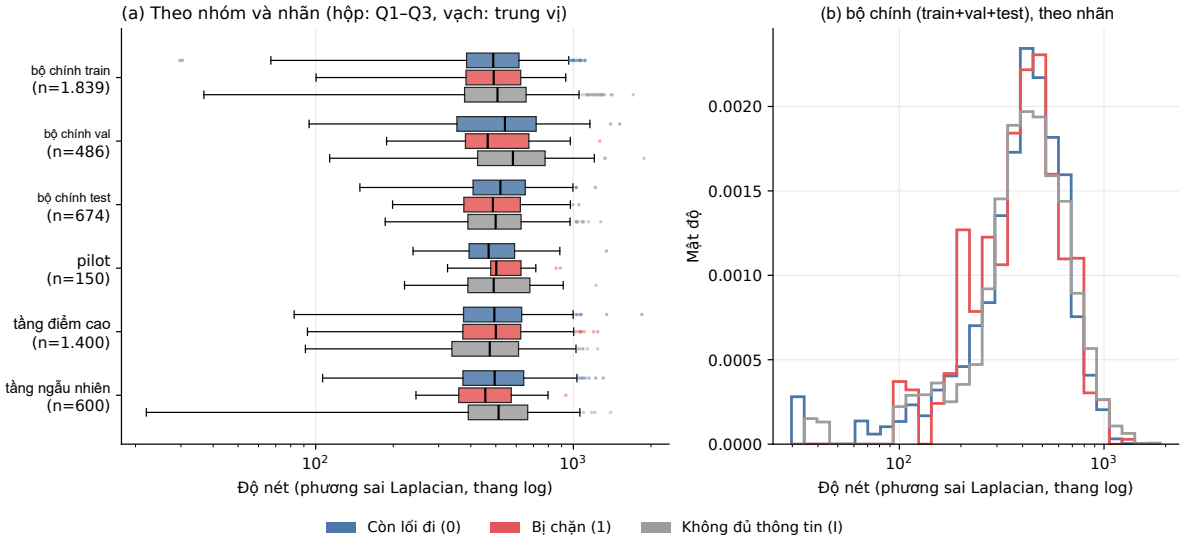
Các đại lượng được đo trên từng ảnh cắt gồm: độ sáng trung bình (thang xám Rec.601, 0–255), độ tương phản (độ lệch chuẩn của thang xám), tỉ lệ điểm ảnh rất tối (< 30) và cháy sáng (> 245), độ nét (phương sai của toán tử Laplacian) và độ sặc sỡ màu [17].

Bảng 20: Thống kê chất lượng ảnh theo nhóm (trung vị; trong ngoặc là IQR)

Nhóm	n	Độ sáng	Tương phản	Độ nét	Sặc sỡ màu
Bộ chính, train	1.839	101,9 (31,3)	59,4 (14,1)	494 (254)	25,1 (13,3)
Bộ chính, val	486	106,7 (36,9)	62,7 (14,1)	560 (354)	26,7 (13,7)
Bộ chính, test	674	104,7 (36,9)	59,3 (14,2)	511 (245)	25,9 (14,0)
Pilot	150	106,6 (38,0)	59,3 (14,0)	487 (244)	24,5 (13,1)
Ảnh bổ sung, tầng điểm cao	1.400	91,8 (30,5)	60,1 (13,7)	492 (260)	27,8 (14,3)
Ảnh bổ sung, tầng ngẫu nhiên	600	100,8 (35,2)	58,1 (12,4)	497 (268)	25,7 (13,7)
Cả 5.149 ảnh: nhỏ nhất – lớn nhất		24,3 – 242,3	17,4 – 96,6	22 – 1.881	4,8 – 104,3



Hình 14: Độ sáng của ảnh cắt theo nhóm và theo nhãn



Hình 15: Độ nét của ảnh cắt (thang log) theo nhóm và theo nhãn

- **Các nhóm tự nhiên có chất lượng ảnh tương đồng** (bảng 20, hình 14 và 15). Train, val, test, pilot và tầng ngẫu nhiên có trung vị độ sáng 101–107 và độ nét 487–560. Ảnh val có độ tương phản cao hơn train một chút (AUC 0,58 $[0{,}54;\ 0{,}61]$).
- **Ảnh Bị chặn tối hơn ảnh Còn lối đi.** Ở bộ chính, trung vị độ sáng là 90,9 so với 101,6; AUC 0,37 $[0{,}32;\ 0{,}41]$ (bootstrap theo 17 đường); tỉ lệ điểm ảnh rất tối là 18% so với 12%. Một cách giải thích hợp lý là vật cản thường nằm dưới mái hiên và bóng cây, nhưng giả thuyết này **chưa được kiểm chứng**. Đây là rủi ro học lối tắt: mô hình có thể dựa một phần vào độ tối của ảnh, nên cần kiểm tra khi phân tích lỗi mô hình.
- **Tầng điểm cao tối hơn bộ chính** (trung vị 91,8 so với 101,9), một phần vì tầng này có nhiều ảnh Bị chặn.
- **Ảnh I có độ tương phản cao hơn và nhiều vùng cháy sáng hơn** ảnh 0 (AUC 0,67 và 0,65 ở bộ chính), phù hợp với việc các ảnh này thường chứa nhiều bầu trời và lòng đường.
- **Độ nét không phân biệt được Bị chặn với Còn lối đi** (AUC 0,46–0,59 ở mọi nhóm, mọi khoảng tin cậy đều chứa 0,5). Ở các so sánh có nhãn I, hai khoảng tin cậy không chứa 0,5 nhưng hiệu ứng nhỏ: ở val, I so với 1 có AUC 0,61 $[0{,}53;\ 0{,}71]$; ở tầng điểm cao, I so với 0 có AUC 0,46 $[0{,}42;\ 0{,}49]$.
- **Độ sáng ảnh** $360°$ **(dùng để lọc ảnh đêm) chỉ liên hệ yếu với độ sáng ảnh cắt** (Spearman 0,18 $[0{,}09;\ 0{,}27]$ ở bộ chính; 0,31 nếu chỉ tính nửa trên ảnh cắt), vì hai đại lượng này đo hai vùng ảnh khác nhau. Do đó, bộ lọc ảnh đêm không bảo đảm ảnh cắt đủ sáng.

Đối chiếu lý do gán nhãn I với phép đo chất lượng ảnh

Có 33 ảnh I mang lý do "Ảnh mờ / tối / cháy sáng" (bộ chính 12, ảnh bổ sung 21). Các ảnh này có độ nét thấp rõ rệt: trung vị độ nét nằm ở phân vị 3,5 của bộ chính và phân vị 13 của

ảnh bổ sung. Về độ sáng, nhóm này gồm cả ảnh tối lẫn ảnh cháy sáng (36% nằm dưới phân vị 10, 18% nằm trên phân vị 90). Do cỡ mẫu nhỏ, kết quả này chỉ mang tính mô tả.

7. Tổng kết và các hạn chế

7.1. Các kết quả đã đo được

Bảng 21 tổng hợp các kết quả chính, mỗi kết quả kèm cỡ mẫu và khoảng tin cậy.

Bảng 21: Các kết quả chính, kèm cỡ mẫu và khoảng tin cậy

Câu hỏi	Kết quả	Phạm vi đo
Bộ dữ liệu có bao nhiêu ảnh và bao nhiêu ảnh hợp lệ?	5.149 ảnh có nhãn cuối; 3.229 ảnh hợp lệ (2.450 ảnh 0, 779 ảnh 1); 1.920 ảnh l	Toàn bộ dữ liệu
Lớp Bị chặn hiếm tới mức nào trong ảnh tự nhiên?	10,8% số ảnh hợp lệ [Wilson 9,4; 12,3], [bootstrap theo đường 8,7; 13,9]	1.746 ảnh hợp lệ, 17 đường
Test và val có đủ mẫu dương không?	Test có 47 ảnh (10,2% [7,8; 13,4]); val có 35 ảnh (14,5% [10,6; 19,4])	459 và 242 ảnh hợp lệ
Tập train thay đổi thế nào sau khi bổ sung?	697 ảnh Bị chặn trên 2.528 ảnh hợp lệ (27,6% [25,9; 29,3]); 83% mẫu dương đến từ ảnh bổ sung	Train
Người gán có nhất quán không?	Cohen κ 3 nhãn: test 0,60; val 0,64; train gán chéo 0,61. 303 ảnh bất đồng do Khải phân xử, sửa 28 nhãn đề xuất	674, 486, 276 ảnh gán đôi
Bộ chọn ảnh có hiệu quả trên đường mới không?	Tỉ lệ Bị chặn trên mọi ảnh: tầng điểm cao 37,9% [35,4; 40,5], tầng ngẫu nhiên 7,7% [5,8; 10,1]	1.400 và 600 ảnh
Có ảnh trùng lặp không?	Không có ảnh trùng lặp tuyệt đối; không có cặp nào có dHash ≤ 4	5.149 ảnh, mọi cặp
Có rò rỉ giữa các tập không?	Không có đường, vị trí hay ảnh gốc dùng chung. 52/1.160 ảnh val/test (4,5%) cách ảnh train dưới 40 m tại giao lộ	Mọi ảnh, theo tọa độ
Chất lượng ảnh có khác nhau giữa các tập không?	Các chỉ số mô tả nhìn chung tương đồng giữa train, val và test của bộ chính. Ảnh Bị chặn tối hơn ảnh Còn lối đi: AUC 0,37 [0,32; 0,41]	2.999 ảnh, 17 đường

Câu hỏi	Kết quả	Phạm vi đo
Ảnh bổ sung có giống bộ chính không?	Không: bộ phân loại miền đạt AUC 0,70 ở tầng ngẫu nhiên và 0,95 ở tầng điểm cao (giá trị sau bị ước lượng cao một phần do dùng chung embedding với bộ chọn ảnh)	1.839 so với 1.400 và 600 ảnh
Metadata có liên hệ với nhãn không?	Tuyến đường có liên hệ (Cramér's V 0,18); loại đường có V = 0,00 ở bộ chính, còn liên hệ ở ảnh bổ sung được trình bày riêng; chưa thấy liên hệ rõ với độ sáng ảnh 360°, tọa độ, tài khoản chụp và năm chụp	1.746 ảnh hợp lệ

7.2. Các nội dung chưa đo hoặc chưa thực hiện

Bảng 22 liệt kê các việc còn tồn đọng và ảnh hưởng của từng việc tới các kết luận ở trên.

Bảng 22: Các việc chưa thực hiện và ảnh hưởng tới báo cáo

Nội dung	Trạng thái và ảnh hưởng
Ảnh nhóm tự chụp (ít nhất 100 ảnh theo đề cương)	Chưa có. Toàn bộ dữ liệu hiện là ảnh Mapillary
Rà soát nội dung nhạy cảm trong ảnh	Chưa thực hiện. Hiện chỉ dựa vào phần làm mờ sẵn của Mapillary; trên các bảng ảnh kiểm tra vẫn thấy một số người và biển số còn rõ
Khóa danh sách chia tập	Chưa khóa. Nhóm giữ nguyên các đường test đã định; việc test chỉ có 47 mẫu dương là một hạn chế của đánh giá. Còn chờ quyết định về 47 ảnh train gần giao lộ với val/test
Mức nhiễu nhãn của ảnh bổ sung	Chưa đo được. Mỗi ảnh chỉ có một người gán; 203 ảnh được kiểm tra chéo được chọn vì bị nghi ngờ nên không đại diện. Tỉ lệ Bị chặn giữa người gán chênh lệch rõ (19% tới 43%)
Phân xử độc lập (theo đề cương)	Chưa đạt hoàn toàn. Khải là người gán ở 123/303 ảnh bất đồng, gồm cả 99 ảnh bất đồng của val; 7 nhãn cuối khác cả hai phiếu
Khoảng tin cậy của κ	Chưa tính

Nội dung	Trạng thái và ảnh hưởng
1.563 ảnh train của bộ chính chỉ có một người gán	Chưa được rà soát lại; phần gán chéo 15% có κ 0,61
Vỉa hè bên trái của đường một chiều	Ít được quan sát vì chỉ cắt ảnh bên phải xe. Đây là giới hạn của nguồn dữ liệu
Gộp ảnh bổ sung vào bảng nhãn chung	Chưa gộp; hai bảng nhãn đang được lưu riêng. Hai ô kiểm tra chéo (263, 264) còn chờ xác nhận và đang giữ nhãn gốc
Giải thích vì sao ảnh Bị chặn tối hơn	Chưa kiểm chứng; hiện mới dừng ở mức mô tả. Cần kiểm tra khi phân tích lỗi mô hình
Xem lại các ảnh bị bộ lọc ảnh đêm loại trong kho ứng viên bổ sung (38 ảnh)	Chưa xem lại. Ảnh bị loại của bộ chính (58 ảnh) đã được xem lại
So sánh ảnh dựng lại với bản gốc trên server	Chỉ có kết quả đo cũ trên 5 ảnh (lệch 1,35–1,5 mức xám). 671 ảnh val/test dùng trong EDA ảnh là bản dựng lại
Thời gian gán và thẻ vật cản của pilot	Chưa được đưa vào thống kê
Chuẩn hóa điểm ảnh, tăng cường dữ liệu	Thuộc giai đoạn huấn luyện, chưa thực hiện

7.3. Hệ quả đối với bước xây dựng mô hình

- **Đánh giá.** Nên dùng các chỉ số phù hợp với dữ liệu mất cân bằng, như diện tích dưới đường cong Precision–Recall (PR-AUC) và điểm F1 của lớp Bị chặn, đồng thời báo cáo khoảng tin cậy bằng cách lấy mẫu lại theo đường. Với 47 mẫu dương ở test, khả năng phân biệt các chênh lệch nhỏ giữa các mô hình bị hạn chế.
- **Huấn luyện.** Phân phối nhãn và kiểu cảnh của train (sau khi bổ sung) khác với val/test. Nên chạy thêm một lượt huấn luyện chỉ với phần dữ liệu tự nhiên, và cân nhắc dùng trọng số lớp hoặc lấy mẫu lại.
- **Học lối tắt.** Cần kiểm tra xem mô hình có dựa vào độ tối của ảnh hay không.
- **Rò rỉ dữ liệu.** Cần quyết định cách xử lý các ảnh train gần giao lộ với val/test trước khi khóa chia tập.

Tài liệu tham khảo

[1] Manh Dung Dao and Thanh Huy Cao. Vietnamese Sidewalk Violation VQA: A question-answering dataset for sidewalk encroachment detection. SE365 course project, University of Information Technology, VNU-HCM, 2026. Dataset card; truy cập 18/10/2026.

[2] Mapillary. An introduction to Mapillary, 2024. Mapillary documentation; truy cập 18/10/2026.

[3] OpenStreetMap contributors. OpenStreetMap, 2026. openstreetmap.org, dữ liệu theo giấy phép ODbL; truy vấn qua Overpass API ngày 22/10/2026.

[4] Maxim Tkachenko, Mikhail Malyuk, Andrey Holmanyuk, and Nikolai Liubimov. Label Studio: Data labeling software, 2020–2022. Phần mềm mã nguồn mở, github.com/heartexlabs/label-studio.

[5] Joseph L. Fleiss. Measuring nominal scale agreement among many raters. *Psychological Bulletin*, 76(5):378–382, 1971.

[6] Josh Attenberg and Foster Provost. Why label when you can search? Alternatives to active learning for applying human resources to build classification models under extreme class imbalance. In *Proceedings of the 16th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2010. doi:10.1145/1835804.1835859.

[7] Maxime Oquab, Timothée Darcet, Théo Moutakanni, et al. DINOv2: Learning robust visual features without supervision, 2023. arXiv:2304.07193.

[8] Sebastian Farquhar, Yarin Gal, and Tom Rainforth. On statistical bias in active learning: How and when to fix it. In *International Conference on Learning Representations (ICLR)*, 2021. arXiv:2101.11665.

[9] Alec Radford, Jong Wook Kim, Chris Hallacy, et al. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, 2021. arXiv:2103.00020.

[10] Enze Xie, Wenhai Wang, Zhiding Yu, Anima Anandkumar, Jose M. Alvarez, and Ping Luo. SegFormer: Simple and efficient design for semantic segmentation with transformers. In *Advances in Neural Information Processing Systems 34 (NeurIPS)*, 2021. arXiv:2105.15203.

[11] Neal Krawetz. Kind of like that, 2013. The Hacker Factor Blog, bài viết mô tả dHash.

[12] Jacob Cohen. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1):37–46, 1960.

[13] Edwin B. Wilson. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212, 1927.

[14] Wicher Bergsma. A bias-correction for Cramér's V and Tschuprow's T. *Journal of the Korean Statistical Society*, 42(3):323–328, 2013.

[15] John W. Tukey. *Exploratory Data Analysis*. Addison-Wesley, 1977.

[16] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9:2579–2605, 2008.

[17] David Hasler and Sabine Süsstrunk. Measuring colorfulness in natural images. In *Human Vision and Electronic Imaging VIII, Proc. SPIE 5007*, pages 87–95, 2003.

A. Truy nguồn số liệu và cách tái lập

Mọi con số trong báo cáo được tính bằng script của nhóm từ dữ liệu lưu trong repo (mục 5); không có số liệu nào được nhập thủ công. Bảng 23 cho biết mỗi nhóm số liệu được tạo ra ở bước nào.

Bảng 23: Nguồn gốc của các nhóm số liệu trong báo cáo

Số liệu	Được tạo ra bởi
Số ảnh Mapillary, số đường OSM, tỉ lệ gắn đường, số ảnh đêm bị loại (mục 2.2)	Các bước thu thập; kết quả của từng bước được ghi vào nhật ký thu thập và bảng trạng thái thu thập
So sánh ảnh bên trái và bên phải, tham số cắt ảnh	Hai phép đo thăm dò về độ phủ vỉa hè theo phía chụp và theo góc cắt
Đồng thuận, phân xử, nguồn nhãn (mục 4)	Bước đo đồng thuận và dựng nhãn cuối từ phiếu gán và bảng phân xử
Bộ chọn ảnh, chọn đường, chọn 2.000 ảnh bổ sung (mục 2.4)	Phép so sánh các bộ chọn ảnh (để riêng từng tuyến đường), lượt quét 150 đường và bước chọn ảnh bổ sung
Kết quả gán nhãn ảnh bổ sung, kiểm tra chéo	Bước tổng hợp nhãn ảnh bổ sung từ phiếu gán và bảng kiểm tra chéo
Bảng 1, 9, 11–16, 17; các hình về nhãn và metadata	Script EDA dữ liệu dạng bảng: đếm nhãn, khoảng tin cậy, thống kê mô tả, liên hệ với nhãn và 71 phép kiểm tra nhất quán; script này chỉ đọc bảng nhãn và manifest
Bảng 20; các hình về chất lượng ảnh và ảnh ví dụ	Script EDA ảnh: đo từng ảnh cắt (độ sáng, độ tương phản, tỉ lệ điểm ảnh tối và cháy sáng, độ nét, độ sặc sỡ màu)
Bảng 18, 19; các hình về trùng lặp, vị trí và t-SNE	Script EDA trùng lặp và rò rỉ: mã băm, dHash, embedding DINOv2, khoảng cách địa lý giữa các tập, bộ phân loại miền

Tái lập kết quả. Ảnh không được lưu trong git. Có hai cách lấy ảnh: dùng bản ảnh cắt trên server gán nhãn, hoặc dựng lại từ manifest (mã ảnh gốc và góc quay) bằng script dựng lại ảnh của nhóm, với điều kiện có token Mapillary. Bản dựng lại khác bản trên server do nén JPEG lại, nên cần ghi rõ nguồn ảnh đã dùng; 671 ảnh val/test trong phần EDA ảnh của báo cáo này là bản dựng lại. Tiếp theo, cài đặt các thư viện trong danh sách phụ thuộc của repo, ghi lại phiên bản Python và thư viện thực sự sử dụng, rồi chạy lần lượt ba script EDA (dạng bảng, ảnh, trùng lặp). Script dạng bảng chỉ cần các bảng dữ liệu; hai script còn lại cần kho ảnh cắt, và script trùng

lặp nên được chạy trên GPU. Báo cáo được biên dịch bằng XeLaTeX và BibTeX.

Phân công và việc sử dụng công cụ AI. Ba script EDA do ba tác tử AI (Claude Sonnet) viết theo yêu cầu của một tác tử điều phối (Claude). Tác tử điều phối đã tính lại độc lập các số liệu chính (đếm nhãn, khoảng Wilson, thống kê metadata, phép đo ảnh trên 300 ảnh mẫu, mã băm MD5, khoảng cách giữa các tập, độ tương đồng embedding) và xem các bảng ảnh kiểm tra trước khi đưa kết quả vào báo cáo. Các kết quả kiểm tra trực quan trong báo cáo là quan sát của AI trên các bảng ảnh tổng hợp, không phải nhãn và không phải phép đo. Nhãn của bộ dữ liệu do người gán và người phân xử quyết định: Claude chỉ đề xuất nhãn cho 303 ảnh bất đồng của bộ chính (do Khải duyệt) và 150 ảnh pilot (do Phúc duyệt); 7 nhãn cuối của bộ chính là các đề xuất khác cả hai phiếu và được người phân xử giữ lại (mục 4).

Ảnh minh họa trong báo cáo. Hình 12 và 13 chỉ dùng ảnh train. Các bảng ảnh kiểm tra nội bộ có chứa ảnh val/test nên không được đưa vào báo cáo và không được đưa lên git. Nguồn ảnh: © Mapillary contributors, CC BY-SA 4.0.