ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN



MÔN HỌC: Nhập môn Học máy (CSC14005)

BÁO CÁO VỀ DỮ LIỆU

PHÂN LOẠI TÌNH TRẠNG CHẶN LỐI ĐI TRÊN VỈA HÈ TP.HCM TỪ ẢNH ĐƯỜNG PHỐ

Giảng viên: TS. Bùi Tiến Lên

Lớp: 24KHMT02

Thời gian: Học kỳ I, năm học 2026 - 2027

Nhóm: 11

Sinh viên:

Họ và tên	MSSV
Lê Nguyễn Quốc Học	24127044
Bùi Thị Bích Loan	24127072
Nguyễn Hữu Gia Minh	24127078
Nguyễn Lê Hoàng Khải	24127408
Trần Hoàng Phúc	24127505

Mục lục

1 Giới thiệu bài toán **1**
1.1 Bài toán học máy . . . 1
1.2 Bộ dữ liệu trong một bảng . . . 1

2 Phương pháp và nguồn thu thập dữ liệu **2**
2.1 Nguồn dữ liệu . . . 3
2.2 Quy trình thu thập từng bước. . . . 4
2.3 Gán nhãn . . . 5
2.4 Bơm thêm ảnh "Bị chặn" cho train. . . . 6
2.5 Công cụ và định dạng lưu trữ . . . 7

3 Quy trình làm sạch và tiền xử lý dữ liệu **7**

4 Đảm bảo chất lượng dữ liệu **9**
4.1 Tiêu chí dữ liệu tốt cho bài toán này . . . 9
4.2 Kiểm tra thủ công: đồng thuận và phân xử . . . 10
4.3 Kiểm tra tự động . . . 11

5 Lưu trữ và quản lý dữ liệu **12**

6 Phân tích khám phá dữ liệu (EDA) **13**
6.1 Thống kê mô tả . . . 13
6.2 Phân tích phân bố nhãn. . . . 17
6.3 Phân tích mối quan hệ giữa các thuộc tính . . . 20
6.4 Kiểm tra chất lượng dữ liệu . . . 22
6.5 EDA cho dữ liệu ảnh . . . 29

7 Tổng kết: đã đo gì, chưa làm gì **32**
7.1 Những gì đã đo . . . 33
7.2 Những gì chưa đo hoặc chưa làm . . . 34
7.3 Hệ quả cho bước xây dựng model . . . 34

A Truy nguồn số liệu và cách chạy lại **37**

Danh sách bảng

1 Ba phần của bộ dữ liệu và nhãn cuối (đơn vị: ảnh) . . . 2
2 Trả lời các câu hỏi về nguồn dữ liệu của khung báo cáo. . . . 3
3 Các bước thu thập bộ chính và pilot . . . 4
4 Ai gán ảnh nào . . . 6
5 Công cụ sử dụng và định dạng lưu trữ . . . 7
6 Các bước làm sạch và tiền xử lý, theo khung báo cáo . . . 8
7 Tiêu chí chất lượng và cách kiểm tra. . . . 9
8 Đồng thuận giữa hai người gán trên bộ chính (Cohen κ) . . . 10

9 Nguồn của nhãn cuối . . . 11
10 Tổ chức thư mục dữ liệu . . . 12
11 Các bảng dữ liệu: số dòng, số cột, dữ liệu thiếu . . . 13
12 Thống kê mô tả hai biến số chính của metadata, theo nhóm . . . 14
13 Tỉ lệ "Bị chặn" và "Không đủ thông tin" theo nhóm, khoảng tin cậy 95% . . . 17
14 Liên hệ giữa thuộc tính và nhãn "Bị chặn" so với "Còn lối đi" (ảnh dùng được) . . . 21
15 Kết quả kiểm tra tính hợp lệ và nhất quán . . . 23
16 Số ảnh val/test nằm gần một ảnh phía train . . . 27
17 Mức phân biệt được giữa các nhóm ảnh (AUC của bộ phân loại miền) . . . 28
18 Thống kê chất lượng ảnh theo nhóm (trung vị; trong ngoặc là IQR) . . . 30
19 Các kết quả chính, kèm cỡ mẫu và khoảng tin cậy . . . 33
20 Việc chưa làm và ảnh hưởng tới báo cáo . . . 34
21 Script sinh số liệu và hình của báo cáo . . . 37
22 Nguồn của các số liệu không do script EDA sinh ra . . . 38

Danh sách hình

1 Phân bố độ sáng ảnh 360° và khoảng cách tới tim đường theo nhóm . . . 15
2 Số ảnh theo năm chụp và tài khoản chụp . . . 16
3 Số ảnh theo nhãn trong từng nhóm . . . 17
4 Thành phần tập train trước và sau khi thêm pilot và ảnh bơm (chỉ ảnh dùng được) 18
5 Thành phần nhãn của 17 đường bộ chính (không gồm pilot) . . . 19
6 Loại vật cản trên ảnh "Bị chặn" và lý do "Không đủ thông tin", bộ chính so với ảnh bơm . . . 19
7 Tỉ lệ nhãn theo người gán . . . 20
8 Tương quan hạng Spearman giữa các thuộc tính số của metadata . . . 21
9 Phân bố độ tương đồng giữa các cặp ảnh: cùng vị trí khác ngày, cùng đường khác vị trí, khác đường . . . 25
10 Vị trí mọi ảnh theo tập. Các đường val/test cắt đường train tại giao lộ . . . 26
11 Hình chiếu t-SNE của embedding DINOv2 cho 5.149 ảnh, tô theo nhóm và theo nhãn. . . . 28
12 Ví dụ ảnh theo nhãn, lấy ngẫu nhiên từ train của bộ chính. © Mapillary contributors, CC BY-SA 4.0 . . . 29
13 Ví dụ ảnh bơm theo tầng lấy mẫu; ô góc trái là nhãn. © Mapillary contributors, CC BY-SA 4.0 . . . 29
14 Độ sáng của ảnh cắt theo nhóm và theo nhãn . . . 31
15 Độ nét của ảnh cắt (thang log) theo nhóm và theo nhãn . . . 31

1. Giới thiệu bài toán

1.1. Bài toán học máy

Vỉa hè có thể tồn tại nhưng không dùng được làm lối đi khi xe đậu, hàng hóa, bàn ghế hoặc rào chắn cắt đứt lối đi liên tục. Đồ án xây dựng một bộ phân loại ảnh để sàng lọc tình trạng này trên ảnh đường phố của TP.HCM.

- **Đầu vào:** một ảnh 640×640 nhìn một phía vỉa hè, cắt từ ảnh $360°$ chụp trên xe.
- **Đầu ra:** phân loại nhị phân. 0 – Còn lối đi: người đi bộ đi tiếp được dọc vỉa hè gần. 1 – Bị chặn: người đi bộ phải bước xuống lòng đường.
- **Ảnh không đủ bằng chứng** (không thấy vỉa hè gần, bị che, ảnh hỏng) được ghi nhãn riêng I – Không đủ thông tin và loại khỏi model. Nhãn này vẫn được thống kê vì nó quyết định bao nhiêu ảnh dùng được.
- **Câu hỏi nghiên cứu:** model nào phân loại tốt nhất trên *các tuyến đường không có trong tập train*. Vì vậy dữ liệu được chia theo cả tuyến đường, và mọi kiểm tra trong báo cáo này đều chú ý tới rò rỉ giữa các tập.

Câu hỏi mà người gán nhãn trả lời cho mỗi ảnh là: *người đi bộ có phải bước xuống lòng đường để đi tiếp dọc vỉa hè gần không?*

1.2. Bộ dữ liệu trong một bảng

Bộ dữ liệu gồm ba phần, được thu thập theo ba cách lấy mẫu khác nhau. Báo cáo luôn tách ba phần này, vì chỉ phần thứ nhất theo phân phối tự nhiên của ảnh trên đường.

Bảng 1: Ba phần của bộ dữ liệu và nhãn cuối (đơn vị: ảnh)

Phần	Cách lấy mẫu	Ảnh	0	1	I
Bộ chính (main), train	Tự nhiên: mọi vị trí cách nhau 25 m trên 10 đường	1.839	939	106	794
Bộ chính, val	Tự nhiên, 3 đường	486	207	35	244
Bộ chính, test	Tự nhiên, 4 đường	674	412	47	215
Pilot (pilot), train	Theo tầng điểm của một model thử, 3 đường train	150	73	14	63
Ảnh bơm (train_extra), train	70% theo điểm bộ chọn ảnh, 30% ngẫu nhiên, 75 đường mới	2.000	819	577	604
Tổng		**5.149**	**2.450**	**779**	**1.920**

Nguồn: `data/labels/main_labels_v1.csv`, `data/labels/train_extra_labels_v2.csv`; đếm lại bằng `src/eda/28_eda_tabular.py`.

Ba điểm cần nhớ khi đọc phần còn lại:

- **Val và test chỉ gồm ảnh tự nhiên.** Ảnh pilot và ảnh bơm chỉ vào train. Nhãn val/test trong báo cáo này chỉ dùng để thống kê mô tả, không dùng để chọn hay chỉnh bất cứ thứ gì.
- **Lớp Bị chặn hiếm trong ảnh tự nhiên:** 188 trên 1.746 ảnh dùng được của bộ chính (10,8%). Đây là lý do có đợt bơm ảnh cho train.
- **Khoảng 40% ảnh là Không đủ thông tin**, do ảnh chụp từ xe thường không thấy rõ vỉa hè gần.

2. Phương pháp và nguồn thu thập dữ liệu

2.1. Nguồn dữ liệu

Bảng 2: Trả lời các câu hỏi về nguồn dữ liệu của khung báo cáo

Câu hỏi	Trả lời
Dựa trên dataset có sẵn?	Không. Nhóm tự dựng bộ dữ liệu từ ảnh gốc. Bộ gần nhất là Vietnamese Sidewalk Violation VQA [2], nhưng bộ đó không có tọa độ và thời gian chụp nên không chia được theo tuyến đường; nhóm không dùng ảnh hay nhãn của bộ đó.
Từ API?	Có. Ảnh 360° và metadata lấy qua Mapillary Graph API [3]; mạng lưới đường và điểm ngữ cảnh (chợ, trường) lấy từ OpenStreetMap [4] qua Overpass API.
Web scraping?	Không.
Khảo sát, biểu mẫu?	Không. Nhãn do 5 thành viên nhóm gán trên Label Studio [5] (mục 2.3).
Giấy phép	Ảnh Mapillary theo CC BY-SA 4.0, ghi công © Mapillary contributors, CC BY-SA 4.0. Phần làm mờ mặt người và biển số của Mapillary được giữ nguyên. Ảnh không đưa lên git.
Ảnh nhóm tự chụp	**Chưa có** (đề cương dự kiến ít nhất 100 ảnh).

Nguồn: `docs/feasibility_log.md`, `docs/collection_log.md`, `docs/unresolved_items.md` (mục 13).

Khu vực nghiên cứu là trung tâm TP.HCM (Quận 1, 3, 5, 10, Phú Nhuận, Bình Thạnh cũ), khung tọa độ 10,745–10,815° Bắc, 106,650–106,725° Đông. Trong khung này Mapillary có 652.159 ảnh 360° thuộc 1.234 chuỗi ảnh (quét ngày 22/10/2026), chủ yếu của ba tài khoản bemaps3_sg, phoenix_mapping_front và phoenixmap_front, chụp các năm 2016, 2023 và 2024.

2.2. Quy trình thu thập từng bước

Bảng 3: Các bước thu thập bộ chính và pilot

#	Việc	Kết quả
1	Lấy đường có tên và điểm ngữ cảnh từ OSM (`01_osm_streets.py`)	7.283 đoạn đường, 6.715 điểm
2	Quét metadata ảnh 360° theo ô 0,001° (`02_fetch_mapillary_meta.py`)	652.159 ảnh; 2 ô nhỏ ở góc khung bị lỗi
3	Gắn ảnh vào đường: cách đường ≤ 20 m và hướng đi lệch trục đường $\leq 30°$; bỏ hẻm (`03_rank_streets.py`)	81,3% số ảnh gắn được vào một đường
4	Xem trước 56 đường, mỗi đường 20 vị trí, để chọn đường (`04_street_preview.py`)	Loại 7 đường ven kênh, cầu, đường hầm; chọn 17 đường
5	Chia 17 đường thành train/val/test *trước khi* gán nhãn (`configs/streets_v1.yaml`)	10 đường train, 3 val, 4 test
6	Pilot: 150 ảnh trên 3 đường train, 5 người gán cùng một ảnh (`10_make_pilot_v2.py`)	Fleiss κ [6] 0,57; viết lại hướng dẫn gán (v1)
7	Thu thập bộ chính: vị trí cách nhau 25 m, tối đa 2 ảnh mỗi vị trí ở hai ngày khác nhau, trần 420 ảnh mỗi đường, bỏ vị trí của pilot (`11_collect_main.py`)	Chọn 3.057 ảnh, loại 58 ảnh đêm, còn 2.999 ảnh
8	Gán nhãn bộ chính, đo đồng thuận, phân xử (mục 2.3)	Nhãn cuối cho 3.149 ảnh
9	Bơm ảnh cho train từ 75 đường mới (mục 2.4)	2.000 ảnh, 577 ảnh Bị chặn

Nguồn: `docs/collection_log.md`; script trong `src/collection/` và `src/labeling/`.

Cắt ảnh. Mỗi ảnh 360° cho đúng một ảnh cắt: nhìn bên phải xe, chếch 60° so với hướng đi, chúc xuống 4°, góc nhìn 90°, kích thước 640×640, lưu JPEG chất lượng 90. Hai quyết định này dựa trên phép đo thăm dò, không dựa trên nhãn:

- *Chỉ lấy bên phải.* Trên 1.166 ảnh 360°, một phép đo tự động (khắt khe) thấy vỉa hè gần ở 38% ảnh phải và 7% ảnh trái. Ảnh trái phần lớn thấy lòng đường, dải phân cách hoặc vỉa hè bên kia. Hệ quả: vỉa hè bên trái của đường một chiều ít được quan sát.
- *Góc* 60°*, chúc* 4° cho tỉ lệ thấy vỉa hè gần cao nhất trong 6 tổ hợp đã thử (góc 60/75/90°, chúc 4/10°).

Nguồn: `src/analysis/08_side_analysis.py`, `src/analysis/09_crop_param_study.py`, `src/common.py` (right_crop); `docs/collection_log.md` mục 23/10/2026.

Chia tập theo tuyến đường. Mỗi đường nằm trọn trong một tập, nên model được đánh giá trên đường chưa từng thấy. Bốn đường test nằm ở bốn khu vực khác nhau. Danh sách đường và tập được chốt ngày 23/10/2026, trước khi có nhãn nào của bộ chính; trạng thái hiện tại là *đã chia, chưa khóa*, vì test chỉ có 47 ảnh Bị chặn và nhóm chưa quyết định có thêm đường test hay không.

2.3. Gán nhãn

Nhãn do người gán, theo hướng dẫn gán nhãn v1 (`labeling/guide/annotation_guide_v1_draft.md`, đã chốt nguyên văn). Mỗi ảnh đi qua ba câu hỏi theo thứ tự:

1. Ảnh xem được không? Ảnh mờ, tối hoặc cháy sáng thì chọn I.
2. Có thấy vỉa hè gần không? Phải có một đoạn mép vỉa hè nằm dưới vạch 3/5 chiều cao ảnh; nếu không (lòng đường, vỉa hè ở xa, giao lộ, đầu hẻm, bị che quá nửa) thì chọn I.
3. Còn lối đi liên tục không? Không đi thẳng qua được thì chọn 1. Người và xe đang chạy không tính là vật cản; vật cản chỉ tính tới khoảng giữa ảnh.

Ngoài nhãn chính, người gán ghi lý do khi chọn I (4 lý do), có thể đánh dấu loại vật cản (6 loại, không bắt buộc), ô Khó / không chắc và ghi chú. Giao diện: `labeling/label_studio/ls_label_config_v1.xml`.

Bảng 4: Ai gán ảnh nào

Phần	Ảnh	Cách gán
Test	674	Hai người (Học, Loan) gán độc lập mọi ảnh
Val	486	Hai người (Minh, Khải) gán độc lập mọi ảnh
Train, bộ chính	1.839	Mỗi ảnh một người; 276 ảnh (15%) được người thứ hai gán chéo
Pilot	150	5 người gán theo hướng dẫn v0; sau đó cả 150 ảnh được xem lại theo v1
Ảnh bơm	2.000	Mỗi ảnh một người (5 người, mỗi người 400 ảnh chia ngẫu nhiên); 203 ảnh có người thứ hai kiểm tra chéo

Nguồn: `docs/labeling_phase1.md` mục 2.2; `data/manifest/main_v1_assignment.csv`, `data/manifest/train_extra_v1_assignment.csv`.

Người gán không thấy tên đường, tập, điểm của model hay phiếu của người khác. Ảnh của các tập được trộn lẫn trong cùng một project. Tổng cộng bộ chính có $5 \times 887 = 4.435$ lượt gán, không thiếu lượt nào. Kết quả đồng thuận và phân xử ở mục 4.

2.4. Bơm thêm ảnh "Bị chặn" cho train

Sau đợt gán đầu, train chỉ có 120 ảnh Bị chặn (gồm 14 ảnh pilot). Nhóm bơm thêm ảnh *chỉ vào train*, theo hướng chủ động tìm mẫu dương của lớp hiếm [7]:

1. **Bộ chọn ảnh.** Logistic regression trên embedding DINOv2 ViT-B/14 [8], học từ 1.989 nhãn train (120 ảnh dương). Bộ này được chọn bằng một phép so sánh chỉ dùng nhãn train, kiểu giữ nguyên một đường ra ngoài: trong 20% ảnh điểm cao nhất có 22,0% ảnh Bị chặn, so với 13,9% của bộ chấm cũ (hiệu $+8,2$ điểm %, khoảng tin cậy 95% $[4,3;\ 11,7]$) và 5,8% nếu bốc ngẫu nhiên.
2. **Chọn đường.** Quét 150 đường chưa dùng (mỗi đường 30 ảnh), xếp hạng theo điểm trung bình, lấy 75 đường đầu. Đường trùng tên với đường val/test bị từ chối, kể cả đoạn khác của cùng đường.
3. **Chọn ảnh.** Kho ứng viên 5.035 ảnh. Chọn 2.000 ảnh: 1.400 ảnh điểm cao nhất (tầng `top_score`, điểm $\geq 0,61$) và 600 ảnh ngẫu nhiên trong phần còn lại (tầng `random`). Vị trí cách ảnh val/test dưới 40 m bị bỏ.
4. **Gán nhãn.** Như bộ chính, mỗi ảnh một người; người gán không biết tầng của ảnh.

Điểm của model *chỉ dùng để chọn ảnh cho người gán, không bao giờ là nhãn*. Vì ảnh bơm được chọn có chủ đích nên phân phối của chúng lệch khỏi tự nhiên [9]; tầng ngẫu nhiên 30% được giữ để đo lại hiệu quả của bộ chọn ảnh trên đường mới, và mọi thống kê trong báo cáo này tách `train_extra` khỏi bộ chính.

Nguồn: `docs/data_enrichment.md` mục 7–9; `src/analysis/21_selector_benchmark.py`, `src/analysis/24_street_scan.py`, `src/collection/23_collect_train_extra.py`; `data/streets/selector_benchmark.csv`.

2.5. Công cụ và định dạng lưu trữ

Bảng 5: Công cụ sử dụng và định dạng lưu trữ

Việc	Công cụ	Định dạng lưu
Mạng lưới đường, điểm ngữ cảnh	Overpass API, shapely	JSON (`data/raw/osm/`)
Metadata ảnh	Mapillary Graph API, requests, pandas	Parquet (`data/raw/metadata/`, `data/streets/`)
Ảnh 360° gốc	Mapillary (ảnh thu nhỏ 2.048 px)	JPEG (`data/raw/pano/`)
Cắt ảnh	py360convert, Pillow	JPEG 640×640 (`data/crops/`)
Danh sách ảnh (manifest)	pandas	CSV UTF-8, mỗi ảnh một dòng (`data/manifest/`)
Gán nhãn	Label Studio tự host trên AWS (Docker, Caddy)	Export JSON trên server; bảng nhãn CSV trong repo (`data/labels/`)
Đo đồng thuận, thống kê	pandas, scipy, scikit-learn	CSV, Markdown
Bộ chọn ảnh, đo vỉa hè (chỉ để chọn mẫu)	torch, transformers (DINOv2 [8], CLIP [10], SegFormer [11])	Embedding NPZ (`data/raw/embeddings/`)
Cấu hình đường và tập		YAML (`configs/`)
EDA của báo cáo này	pandas, scipy, matplotlib	CSV, JSON, PDF, JPEG (`docs/data_report/`)

Nguồn: `requirements.txt`, `README.md`, `infra/`.

3. Quy trình làm sạch và tiền xử lý dữ liệu

Nguyên tắc chung: *chỉ lọc bằng quy tắc, không lọc bằng model*, và không sửa dữ liệu gốc. Mỗi bước dưới đây ghi rõ đã làm gì và loại bao nhiêu.

Bảng 6: Các bước làm sạch và tiền xử lý, theo khung báo cáo

Nội dung	Cách làm	Kết quả
Nhiễu: ảnh đêm	Loại ảnh có độ sáng trung bình nửa trên của ảnh 360° dưới 90 (thang 0–255). Không lọc theo giờ chụp: giờ ghi trên Mapillary không đáng tin (ảnh ghi 18–0 giờ vẫn sáng như ban ngày).	Bộ chính: loại 58/3.057. Kho ảnh bơm: loại 38/5.074
Nhiễu: ảnh không thuộc đường	Chỉ giữ ảnh cách đường ≤ 20 m và đi dọc trục đường ($\leq 30°$); bỏ hẻm.	81,3% ảnh của khu vực gắn được vào đường
Nhiễu: ảnh không xét được	Không lọc tự động. Người gán ghi nhãn l kèm lý do; ảnh l bị loại khỏi model nhưng giữ trong bảng nhãn.	1.920/5.149 ảnh là l
Trùng lặp tuyệt đối	Mỗi ảnh 360° chỉ dùng một lần; so mã băm md5 của ảnh cắt.	Xem mục 6.4
Gần trùng	Lấy thưa: một vị trí mỗi 25 m, tối đa 2 ảnh mỗi vị trí và phải khác ngày chụp. Riêng kho ảnh bơm có thêm so dHash [12] giữa hai ngày của cùng vị trí.	Kho ảnh bơm: loại 1 cặp. Bộ chính: đo lần đầu trong báo cáo này (mục 6.4)
Dữ liệu thiếu	Metadata lấy từ API nên ảnh thiếu tọa độ hoặc hướng đi không gắn được vào đường và đã bị loại ở bước gắn đường. Nhãn: mọi lượt gán đều bắt buộc chọn nhãn.	Xem bảng 11
Chuẩn hóa, biến đổi	Chiếu ảnh 360° về ảnh phối cảnh 640×640 với cùng tham số cho mọi ảnh (mục 2.2). Chưa chuẩn hóa giá trị điểm ảnh: việc này thuộc bước train.	Mọi ảnh cùng kích thước và góc nhìn
Chuyển đổi kiểu	Nhãn Label Studio (chuỗi tiếng Việt) → mã 0/1/l. Mã ảnh 360° (số 64 bit) → mã ảnh 8 ký tự không lộ nguồn cho người gán. Thời gian chụp giữ dạng chuỗi ISO có múi giờ.	`19_main_agreement.py`, `26_train_extra_report.py`
Kiểm tra nhất quán	Script thu thập từ chối đường đã có trong tập khác; báo cáo này kiểm lại toàn bộ khóa, tập, đường, tọa độ.	Mục 6.4

Nguồn: `docs/collection_log.md`; `data/manifest/main_v1_collection_status.csv`; `data/streets/train_extra_v1_scores.csv`; `docs/data_enrichment.md` mục 9.

Chưa làm: rà soát nội dung nhạy cảm trong ảnh (ngoài phần làm mờ sẵn của Mapillary), và khóa danh sách chia tập.

4. Đảm bảo chất lượng dữ liệu

4.1. Tiêu chí dữ liệu tốt cho bài toán này

Bảng 7: Tiêu chí chất lượng và cách kiểm tra

Tiêu chí	Cách kiểm tra	Loại kiểm tra
Nhãn đúng định nghĩa và nhất quán giữa người gán	Gán đôi val/test, gán chéo 15% train, Cohen κ [13] với ngưỡng 0,6 đặt trong đề cương; phân xử mọi ảnh bất đồng	Thủ công + tự động
Tập đánh giá theo phân phối tự nhiên	Val/test chỉ gồm ảnh bộ chính; ảnh chọn theo điểm chỉ vào train; ghi tầng lấy mẫu vào manifest	Theo thiết kế
Không rò rỉ giữa các tập	Chia theo đường; bỏ vị trí cách val/test dưới 40 m khi bơm; kiểm tra khoảng cách và ảnh gần trùng giữa các tập (mục 6.4)	Tự động + xem ảnh
Truy được nguồn gốc	Mỗi ảnh một dòng manifest: mã ảnh gốc, tọa độ, ngày chụp, người chụp, giấy phép, đường, tập, tầng lấy mẫu	Tự động
Ảnh xem được	Bộ lọc đêm; nhãn l với lý do; thống kê độ sáng, độ nét (mục 6.5)	Tự động + thủ công
Đủ mẫu của lớp hiếm	Đếm ảnh Bị chặn từng tập, kèm khoảng tin cậy (mục 6.2)	Tự động

4.2. Kiểm tra thủ công: đồng thuận và phân xử

Bảng 8: Đồng thuận giữa hai người gán trên bộ chính (Cohen κ)

Nhóm ảnh	Cặp gán	Số ảnh	Khớp nhau	κ 3 nhãn	κ chỉ 0/1
Test	Học – Loan	674	79%	0,60	0,68
Val	Minh – Khải	486	80%	0,64	0,55
Train gán chéo	10 cặp	276	78%	0,61	0,56

Nguồn: `data/labels/main_report/main_report.md`; `src/labeling/19_main_agreement.py`. κ chỉ 0/1 tính trên các ảnh cả hai người đều chọn 0 hoặc 1 (test 418 ảnh, val 211 ảnh).

- Cả ba nhóm đạt ngưỡng 0,6 của đề cương; pilot (hướng dẫn v0) chỉ đạt Fleiss κ 0,57. Báo cáo không có khoảng tin cậy cho các giá trị κ này: **chưa đo**.
- Trong 1.436 ảnh gán đôi có 303 ảnh bất đồng: 193 ảnh 0/l, 51 ảnh 1/l, 59 ảnh 0/1. Tức phần lớn bất đồng là về việc ảnh có xét được hay không.
- **Phân xử 303 ảnh.** Trợ lý AI (Claude) xem mù từng ảnh và đề xuất nhãn kèm lý do; trưởng nhóm (Phúc) duyệt toàn bộ 303 ảnh và sửa 28 ảnh (9,2%). Nhãn cuối là nhãn người duyệt. Cả 28 nhãn sửa đều trùng phiếu của một trong hai người gán ban đầu.
- **Pilot.** Cả 150 ảnh được xem lại theo hướng dẫn v1 bằng cùng cách; Phúc sửa 3 ảnh. 29 ảnh có nhãn cuối khác đa số phiếu v0.

Nguồn: `docs/labeling_phase1.md` mục 3–5; `data/labels/main_report/adjudication_proposal.csv`; `data/labels/pilot_report/pilot_adjudication_proposal.csv`.

Ảnh bơm. Mỗi ảnh một người gán nên không có κ. Ảnh được chia ngẫu nhiên, nhưng tỉ lệ Bị chặn của từng người chênh nhau rõ (Học 0,43, Loan 0,19; kiểm định χ^2 trên bảng người gán $\times$ nhãn, $p = 4 \cdot 10^{-15}$). Một thành viên đã kiểm tra chéo độc lập 203 ảnh thuộc danh sách 264 ảnh bị nghi ngờ: trùng nhãn gốc ở 186 ảnh (92%), đổi 17 nhãn. 203 ảnh này được chọn vì bị nghi ngờ nên *không đại diện* cho 2.000 ảnh; mức nhiễu nhãn của phần bơm vì vậy **chưa đo được**.

Nguồn: `docs/data_enrichment.md` mục 9; `data/labels/train_extra_report/report.md` (tính trên nhãn v1); `data/labels/train_extra_cross_check.csv`.

Bảng 9: Nguồn của nhãn cuối

Nguồn (cột source)	Ảnh	Ý nghĩa
agreed	1.133	Bộ chính: hai người gán giống nhau
single (bộ chính)	1.563	Ảnh train chỉ một người gán
adjudicated_proposal	275	Bất đồng; người duyệt giữ nhãn đề xuất
adjudicated_phuc	28	Bất đồng; người duyệt sửa
pilot_review_proposal	147	Pilot; người duyệt giữ nhãn đề xuất
pilot_review_phuc	3	Pilot; người duyệt sửa
single (ảnh bơm)	1.983	Nhãn của một người gán (186 ảnh trong đó có kiểm tra chéo và trùng nhãn gốc)
cross_check (ảnh bơm)	17	Nhãn đổi theo người kiểm tra chéo

Nguồn: `data/labels/main_labels_v1.csv`, `data/labels/train_extra_labels_v2.csv`; đếm lại bằng `src/eda/28_eda_tabular.py`.

4.3. Kiểm tra tự động

- Trong pipeline: script thu thập từ chối đường đã thuộc tập khác và đường trùng tên với đường val/test; script đồng thuận kiểm tra đủ số lượt gán, lượt lưu trùng và giao diện đúng phiên bản.
- Trong báo cáo này: kiểm tra khóa, tập, đường, tọa độ, ngoại lệ, ảnh trùng và gần trùng, khoảng cách giữa các tập. Kết quả ở mục 6.4.

5. Lưu trữ và quản lý dữ liệu

Bảng 10: Tổ chức thư mục dữ liệu

Thư mục / file	Nội dung	Trong git
`configs/streets_v1.yaml`	17 đường của bộ chính và tập của từng đường	Có
`configs/streets_train_extra.yaml`	75 đường của đợt bơm	Có
`data/manifest/`	Mỗi ảnh một dòng: nguồn gốc, tọa độ, ngày chụp, đường, tập, tầng lấy mẫu; bảng phân công gán	Có
`data/labels/main_labels_v1.csv`	Nhãn cuối của bộ chính và pilot (3.149 dòng)	Có
`data/labels/train_extra_labels_v2.csv`	Nhãn cuối của ảnh bơm (2.000 dòng)	Có
`data/labels/*_report/`	Từng lượt gán, báo cáo đồng thuận, bảng phân xử	Có
`data/labels/raw/`	Export gốc của Label Studio (có email tài khoản)	Không
`data/streets/`	Bảng xếp hạng đường, điểm bộ chọn ảnh, kết quả phân tích thăm dò	CSV: có
`data/raw/`	OSM, metadata Mapillary, ảnh 360°, embedding	Không
`data/crops/`	Ảnh cắt 640×640 theo thư mục `main/`, `pilot_v2/`, `train_extra_v1/`	Không
`docs/data_report/`	Báo cáo này, hình và bảng số liệu EDA	Có

Nguồn: `README.md`, `.gitignore`.

- **Khóa chính** là mã ảnh item (8 ký tự). Bảng nhãn và manifest ghép với nhau theo khóa này; đường dẫn ảnh là `data/crops/<file>`.
- **Ảnh không vào git** vì dung lượng và giấy phép; ảnh dựng lại được từ manifest (mã ảnh gốc và góc yaw) bằng `src/eda/27_rebuild_missing_crops.py` hoặc các script thu thập. Ảnh dựng lại khác bản trên server gán nhãn do nén JPEG lại (lệch trung bình 1,35–1,5 mức xám, đo trên 5 ảnh).
- **Phiên bản.** Bảng nhãn có số phiên bản trong tên file; bản cũ được giữ (`train_extra_labels_v1.csv`). Phiếu gốc của từng người vẫn nằm nguyên trên Label Studio; nhãn cuối chỉ nằm trong repo.
- **Bí mật** (token Mapillary, mật khẩu server) nằm trong `.env`, không vào git.

6. Phân tích khám phá dữ liệu (EDA)

Cách đọc mục này.

- Mọi thống kê tách sáu nhóm: bộ chính train / val / test (tự nhiên), pilot, ảnh bơm tầng top_score và tầng random. Chỗ nào gộp thì ghi rõ là gộp.
- Nhãn val/test chỉ dùng để mô tả. Không có lựa chọn hay ngưỡng nào trong báo cáo được đặt theo nhãn val/test.
- Khoảng tin cậy 95% của tỉ lệ là khoảng Wilson [14], coi các ảnh là độc lập. Ảnh cùng đường giống nhau nên khoảng thật rộng hơn; ở các so sánh quan trọng báo cáo kèm khoảng *bootstrap theo đường* (lấy lại mẫu cả tuyến đường). Với val (3 đường) và test (4 đường), khoảng bootstrap theo đường chỉ để tham khảo.
- Toàn bộ số liệu sinh từ ba script trong `src/eda/`; bảng đầy đủ ở `docs/data_report/tables/`. Phụ lục A ghi nguồn của từng bảng và hình.

6.1. Thống kê mô tả

Số mẫu, số thuộc tính, tỉ lệ thiếu

Bảng 11: Các bảng dữ liệu: số dòng, số cột, dữ liệu thiếu

Bảng	Dòng	Cột	Dữ liệu thiếu
Nhãn bộ chính + pilot	3.149	8	Chỉ cột reason: thiếu ở 2.114 dòng. 1.833 dòng là nhãn 0/1 (không có lý do theo thiết kế); **281 ảnh l không có lý do**
Nhãn ảnh bơm	2.000	11	Chỉ cột reason: 1.403 dòng, trong đó 7 ảnh l không có lý do
Manifest bộ chính	2.999	21	Không thiếu ô nào
Manifest pilot	150	21	Không thiếu ô nào (không có cột position_group)
Manifest ảnh bơm	2.000	25	Không thiếu ô nào
Từng lượt gán, bộ chính	4.435	13	reason, obstacles, note: thiếu theo thiết kế (không bắt buộc)
Từng lượt gán, ảnh bơm	2.000	13	Như trên

Nguồn: `tables/inventory_tables.csv`, `tables/inventory_columns.csv` (`src/eda/28_eda_tabular.py`).

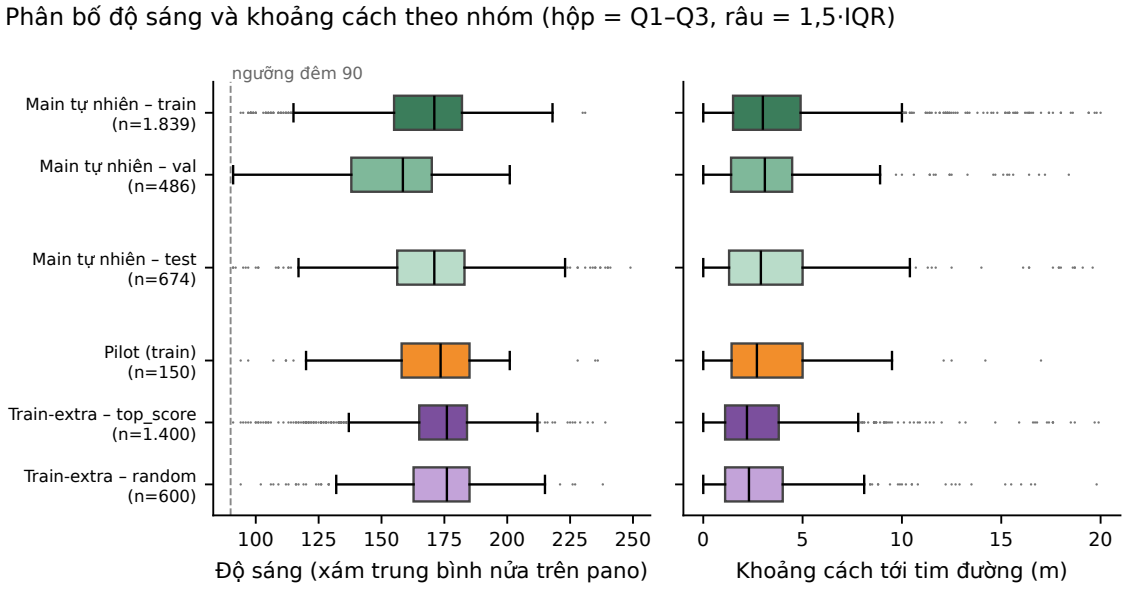
- **Thuộc tính.** Mỗi ảnh có 1 nhãn và khoảng 20 thuộc tính metadata: 7 thuộc tính số (vĩ độ, kinh độ, độ sáng ảnh 360°, khoảng cách tới tim đường, hướng chạy xe, góc cắt, điểm bộ chọn ảnh với ảnh bơm), còn lại là phân loại hoặc định danh (đường, tập, người chụp, chuỗi ảnh, thời gian chụp, tầng lấy mẫu, nguồn nhãn). Đầu vào của model chỉ là ảnh; metadata dùng để chia tập, truy nguồn và kiểm tra.
- **Metadata không thiếu ô nào** trên cả 5.149 ảnh. Lý do: ảnh thiếu tọa độ hoặc hướng đi không gắn được vào đường nên không thể được chọn.
- **281 ảnh l của bộ chính và pilot không ghi lý do:** 162 ảnh có nhãn sau phân xử, 63 ảnh pilot (xem lại theo v1, không ghi lý do), 55 ảnh hai người cùng chọn l nhưng khác lý do, 1 ảnh gán đơn. Vì vậy thống kê lý do chỉ tính trên 1.035/1.253 ảnh l của bộ chính. Nhãn chính không bị ảnh hưởng.

Thống kê cơ bản của các biến số

Bảng 12: Thống kê mô tả hai biến số chính của metadata, theo nhóm

Nhóm	n	TB	Trung vị	Phương sai	Min	Max	IQR
Độ sáng ảnh 360° (trung bình nửa trên, thang 0–255)							
Bộ chính, train	1.839	166,8	171,0	448,6	94	231	27,0
Bộ chính, val	486	154,5	158,5	468,9	91	201	32,0
Bộ chính, test	674	169,4	171,0	564,2	91	249	26,8
Pilot	150	169,2	173,5	573,5	94	236	27,0
Ảnh bơm, top_score	1.400	172,0	176,0	366,8	91	239	19,0
Ảnh bơm, random	600	172,7	176,0	377,9	94	238	22,3
Khoảng cách từ vị trí chụp tới tim đường (m)							
Bộ chính, train	1.839	3,70	3,0	9,67	0,0	20,0	3,40
Bộ chính, val	486	3,46	3,1	8,53	0,0	18,4	3,08
Bộ chính, test	674	3,54	2,9	9,48	0,0	19,6	3,70
Pilot	150	3,45	2,7	7,98	0,0	17,0	3,58
Ảnh bơm, top_score	1.400	2,87	2,2	6,81	0,0	19,9	2,70
Ảnh bơm, random	600	2,96	2,3	7,24	0,0	19,8	2,90

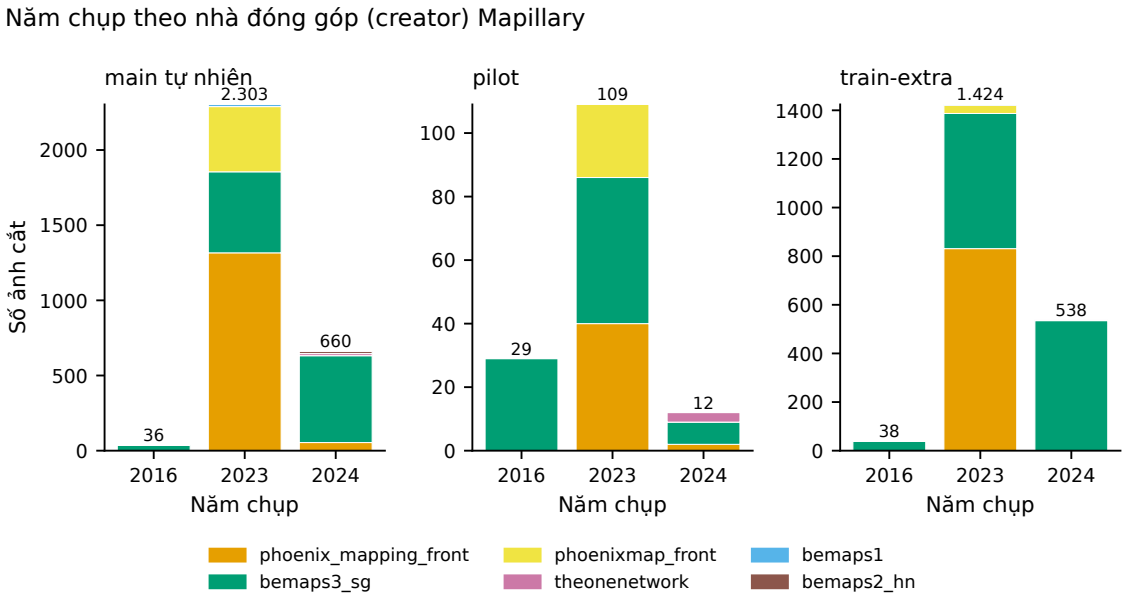
Nguồn: `tables/desc_numeric.csv`. Bảng đầy đủ có thêm vĩ độ, kinh độ, hướng chạy xe, điểm bộ chọn ảnh và thời gian gán.



Hình 1: Phân bố độ sáng ảnh 360° và khoảng cách tới tim đường theo nhóm

- **Độ sáng.** Không ảnh nào dưới ngưỡng lọc đêm (min 91). Val tối hơn các nhóm khác (trung vị 158,5 so với 171); val chỉ có 3 đường nên đây có thể là đặc điểm của ba đường đó.
- **Khoảng cách tới tim đường** bị chặn trên ở 20 m theo quy tắc gắn đường. Ảnh bơm gần tim đường hơn (trung vị 2,2 m so với 3,0 m), phù hợp với việc 71% ảnh bơm đến từ đường nhỏ.
- **Điểm bộ chọn ảnh** (chỉ ảnh bơm): tầng top_score trung vị 0,80 (0,61–1,00), tầng random trung vị 0,19 (0,00–0,61).
- **Thời gian gán một ảnh** lệch phải rất mạnh: trung vị 3,7 giây (bộ chính, 4.435 lượt) và 4,5 giây (ảnh bơm), nhưng giá trị lớn nhất là 77.451 giây vì có task bị để mở. Chỉ nên dùng trung vị. Thời gian gán của pilot: **chưa đo** trong báo cáo này.

Phân bố theo thuộc tính phân loại

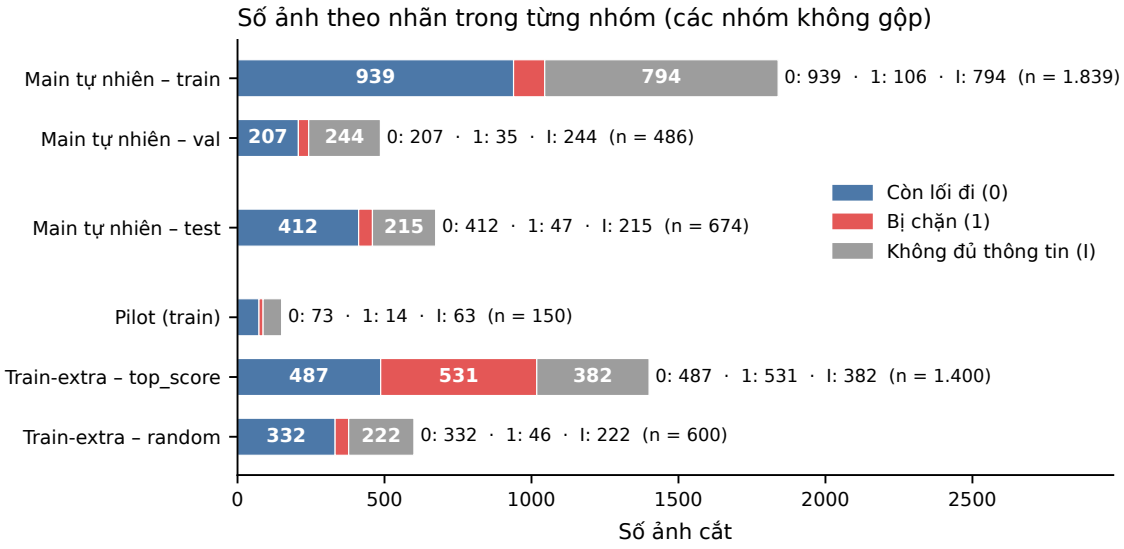


Hình 2: Số ảnh theo năm chụp và tài khoản chụp

- **Người chụp.** Hai tài khoản bemaps3_sg và phoenix_mapping_front chiếm 84% bộ chính (1.153 và 1.370 trên 2.999 ảnh) và 98% ảnh bơm. Dữ liệu vì vậy đến từ rất ít loại thiết bị và cách gắn camera.
- **Năm chụp.** Bộ chính: 2023 có 2.303 ảnh, 2024 có 660 ảnh, 2016 có 36 ảnh. Cả 103 ảnh ghi năm 2016 (của ba phần) đều thuộc bemaps3_sg và đều ghi đúng ngày 01/01/2016; nhiều khả năng đây là ngày giữ chỗ, nên năm 2016 **không đáng tin**.
- **Giờ chụp** không dùng được (mục 3); biểu đồ giờ ở `figures/tab_fig5b_stamped_hour_hist.pdf` chỉ để minh chứng.
- **Số ảnh mỗi đường.** Bộ chính: 17 đường, 86–348 ảnh, trung vị 150. Ảnh bơm: 75 đường, 6–157 ảnh, trung vị 21. Hai đường ven kênh Hoàng Sa và Trường Sa#0 chiếm 274 ảnh bơm (14%).

Nguồn: `tables/cat_distributions.csv`, `tables/tabular_numbers.json`.

6.2. Phân tích phân bố nhãn



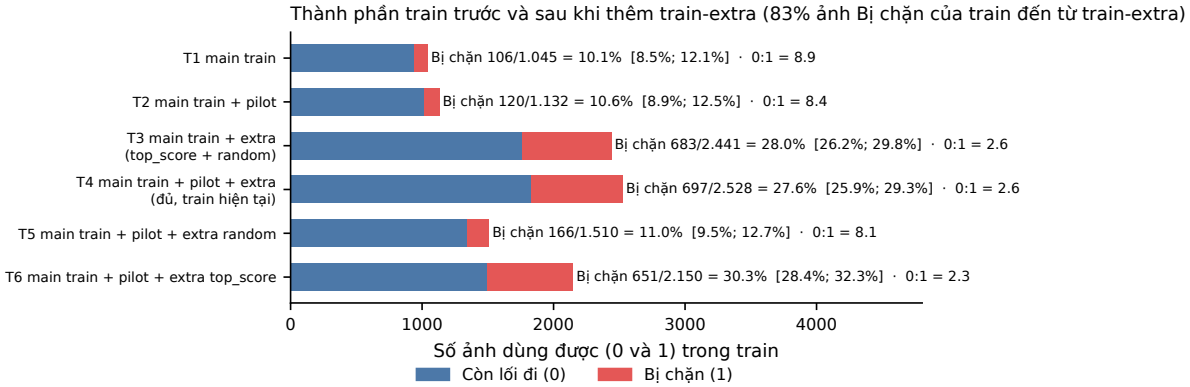
Hình 3: Số ảnh theo nhãn trong từng nhóm

Bảng 13: Tỉ lệ "Bị chặn" và "Không đủ thông tin" theo nhóm, khoảng tin cậy 95%

Nhóm	Ảnh	Bị chặn / dùng được [Wilson]	Bootstrap theo đường	Tỉ lệ I	0 : 1
Bộ chính, train	1.839	106/1.045 = 10,1% [8,5; 12,1]	[7,9; 14,1]	43,2%	8,9
Bộ chính, val	486	35/242 = 14,5% [10,6; 19,5]	[8,2; 19,2]	50,2%	5,9
Bộ chính, test	674	47/459 = 10,2% [7,8; 13,4]	[5,7; 18,7]	31,9%	8,8
Bộ chính, gộp	2.999	188/1.746 = 10,8% [9,4; 12,3]	[8,7; 13,9]	41,8%	8,3
Pilot	150	14/87 = 16,1% [9,8; 25,2]	[10,0; 18,4]	42,0%	5,2
Ảnh bơm, top_score	1.400	531/1.018 = 52,2% [49,1; 55,2]	[47,8; 56,6]	27,3%	0,9
Ảnh bơm, random	600	46/378 = 12,2% [9,3; 15,9]	[8,9; 15,3]	37,0%	7,2

Nguồn: `tables/label_counts_by_group.csv`. "Dùng được" là ảnh có nhãn 0 hoặc 1. Bootstrap theo đường: 1.000 lần.

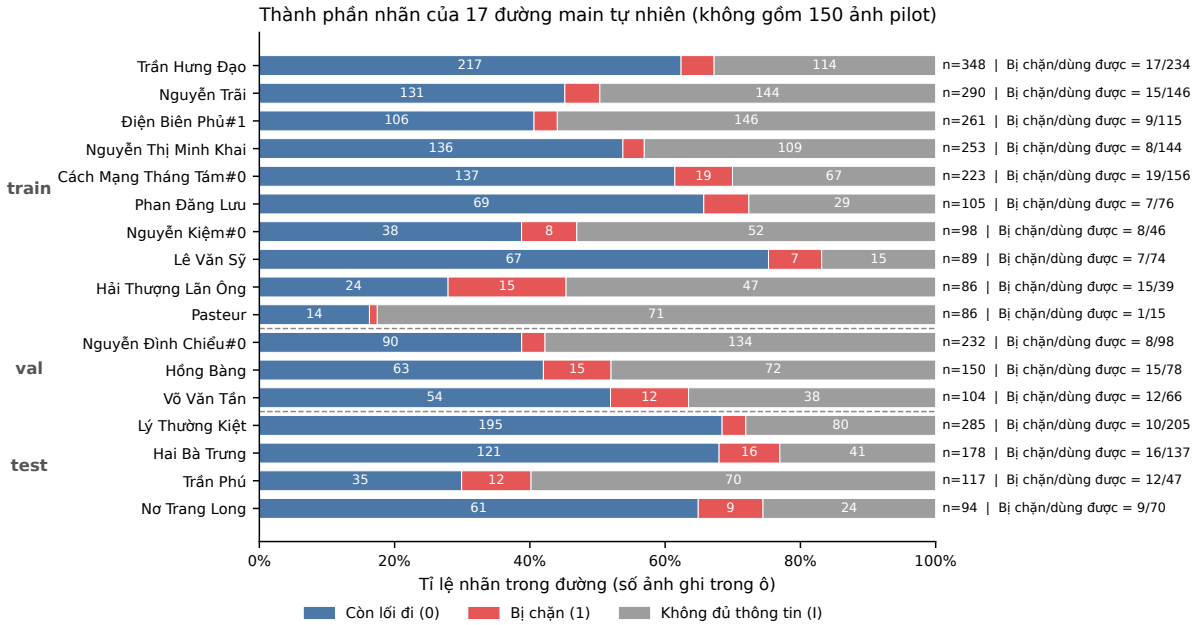
- **Dữ liệu tự nhiên mất cân bằng mạnh:** trong ảnh dùng được của bộ chính, cứ khoảng 8 ảnh Còn lối đi mới có 1 ảnh Bị chặn (10,8%). Tính trên mọi ảnh kể cả I, tỉ lệ Bị chặn là 6,3% [5,5; 7,2].
- **Ba tập có tỉ lệ Bị chặn tương đương nhau trong sai số** (10,1% / 14,5% / 10,2%; các khoảng chồng lên nhau).
- **Test chỉ có 47 ảnh Bị chặn, val 35 ảnh.** Khoảng bootstrap theo đường của test rộng gần gấp đôi khoảng Wilson ([5,7; 18,7] so với [7,8; 13,4]): kết quả đánh giá model trên test sẽ có sai số lớn.
- **Ảnh I chiếm 32–50%** tùy tập. Đây là chi phí cố định của nguồn ảnh chụp từ xe.
- **Pilot và tầng top_score không tự nhiên:** tỉ lệ Bị chặn của chúng (16,1% và 52,2%) là kết quả của cách lấy mẫu, không phải tỉ lệ ngoài đường.
- **Tầng random của ảnh bơm (12,2%)** gần với bộ chính dù lấy từ đường khác; cả hai khoảng chồng lên nhau.



Hình 4: Thành phần tập train trước và sau khi thêm pilot và ảnh bơm (chỉ ảnh dùng được)

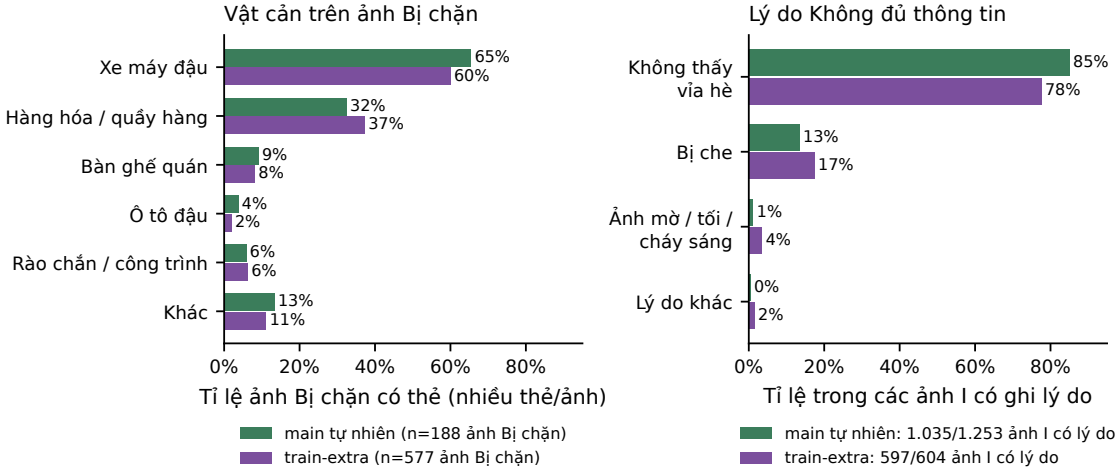
Tập train sau khi bơm. Train hiện có 2.528 ảnh dùng được, 697 ảnh Bị chặn (27,6%, tỉ lệ 0:1 là 2,6), so với 1.132 ảnh và 120 ảnh Bị chặn (10,6%) trước khi bơm. 577 trong 697 ảnh dương (83%) đến từ ảnh bơm. Hệ quả: phân phối nhãn của train khác val/test (27,6% so với khoảng 10–15%), nên khi train cần tính tới độ lệch này, và nên báo cáo thêm kết quả khi chỉ train trên phần tự nhiên.

Nguồn: `tables/train_composition.csv`.



Hình 5: Thành phần nhãn của 17 đường bộ chính (không gồm pilot)

Theo đường. Tỉ lệ nhãn khác nhau nhiều giữa các đường: tỉ lệ Bị chặn trên ảnh dùng được từ 7/74 (Lê Văn Sỹ) tới 15/39 (Hải Thượng Lãn Ông); tỉ lệ I từ 17% tới 83% (Pasteur, đường một chiều). Tuyến đường là thuộc tính liên hệ mạnh nhất với nhãn (mục 6.3), nên việc chia tập theo đường là cần thiết để không đánh giá quá lạc quan. Với 75 đường của ảnh bơm, xem `figures/tab_fig3b_extra_streets_blocked_share.pdf`.



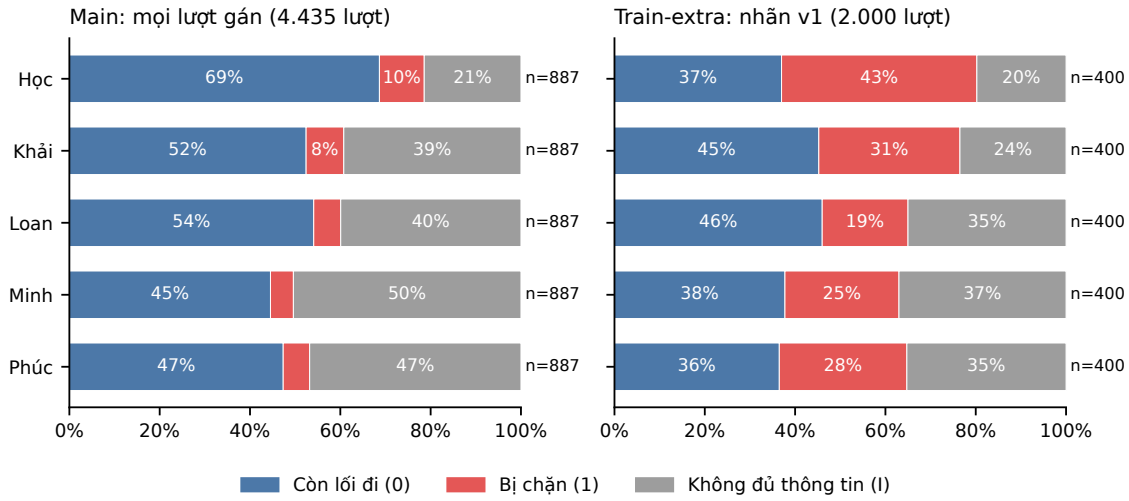
Hình 6: Loại vật cản trên ảnh "Bị chặn" và lý do "Không đủ thông tin", bộ chính so với ảnh bơm

Đa dạng của vật cản và lý do loại.

- Trên ảnh Bị chặn, xe máy đậu là vật cản phổ biến nhất (bộ chính 123/188 ảnh, 65%; ảnh bơm 346/577, 60%), sau đó là hàng hóa và quầy hàng (32% và 37%). Ô tô đậu hiếm (4% và 2%). Một ảnh có thể có nhiều loại. Hai phần có cơ cấu vật cản gần giống nhau.

- Lý do I chủ yếu là không thấy vỉa hè (bộ chính 880/1.035 ảnh có ghi lý do, 85%; ảnh bơm 463/597, 78%), tiếp theo là bị che. Ảnh mờ, tối hoặc cháy sáng chỉ 12 và 21 ảnh.
- Thẻ vật cản là thông tin phụ, không bắt buộc: 13 ảnh Bị chặn của bộ chính và 6 ảnh bơm không có thẻ nào. Thẻ vật cản của pilot: **chưa đo**.

Nguồn: `tables/obstacle_tags.csv`, `tables/reasons_I.csv`. Thẻ của một ảnh là hợp các thẻ từ những lượt gán nhãn 1 của ảnh đó.



Hình 7: Tỉ lệ nhãn theo người gán

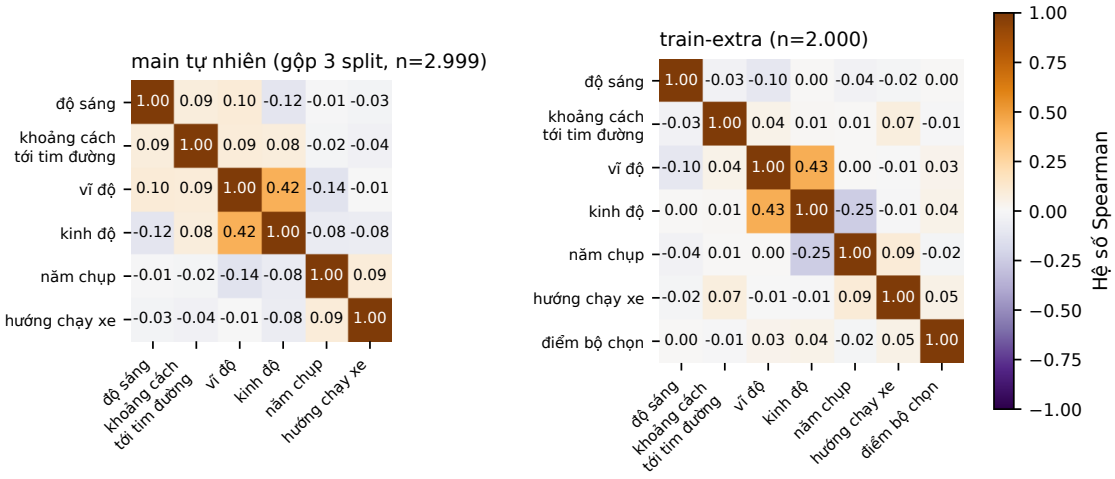
Theo người gán. Ở ảnh bơm, ảnh được chia ngẫu nhiên nên khác biệt giữa người gán là khác biệt về cách gán: tỉ lệ Bị chặn từ 19% (Loan) tới 43% (Học). Ở bộ chính, mỗi người gán một phần ảnh khác nhau (hai người gán test, hai người gán val) nên tỉ lệ theo người lẫn với tập, không so sánh trực tiếp được.

Nguồn: `tables/annotator_label_shares.csv`. Hình bên phải dùng nhãn v1 của từng người, trước kiểm tra chéo.

6.3. Phân tích mối quan hệ giữa các thuộc tính

Đầu vào của model là ảnh, không phải metadata. Mục này trả lời hai câu hỏi: các thuộc tính metadata có trùng lặp thông tin với nhau không, và có thuộc tính nào liên hệ với nhãn tới mức cần đề phòng model "học tắt" không.

Tương quan hạng giữa các thuộc tính số của siêu dữ liệu



Hình 8: Tương quan hạng Spearman giữa các thuộc tính số của metadata

- **Tương quan.** Cặp duy nhất đáng kể là vĩ độ–kinh độ ($\rho = 0{,}42$ ở bộ chính, 0,43 ở ảnh bơm), do hình dạng khu vực và hướng của các tuyến đường. Mọi cặp còn lại có $|\rho| \leq 0{,}14$ ở bộ chính và $\leq 0{,}25$ ở ảnh bơm.
- **Đa cộng tuyến.** Hệ số VIF lớn nhất là 1,27 (vĩ độ, bộ chính); các biến khác dưới 1,1. Không có đa cộng tuyến.

Bảng 14: Liên hệ giữa thuộc tính và nhãn "Bị chặn" so với "Còn lối đi" (ảnh dùng được)

Thuộc tính	Bộ chính, gộp (n = 1.746)	Ảnh bơm (n = 1.396)
Biến số: AUC (0,5 = không phân biệt), khoảng bootstrap theo đường		
Độ sáng ảnh 360°	0,53 [0,47; 0,59]	0,49 [0,45; 0,53]
Khoảng cách tới tim đường	0,54 [0,50; 0,58]	0,46 [0,43; 0,49]
Vĩ độ	0,45 [0,37; 0,52]	khoảng chứa 0,5
Kinh độ	0,45 [0,35; 0,54]	khoảng chứa 0,5
Điểm bộ chọn ảnh	không có	0,78 [0,75; 0,81]
Biến phân loại: Cramér's V đã hiệu chỉnh [15] (0 = không liên hệ)		
Tuyến đường	0,18	0,29
Loại đường	0,00 (chỉ 2 mức)	0,14 [0,06; 0,24]
Người chụp	0,00	0,03
Năm chụp	0,02	0,03

Nguồn: `tables/assoc_numeric.csv`, `tables/assoc_categorical.csv`. Các giá trị p trong file tính như thể ảnh độc lập nên quá lạc quan; báo cáo chỉ dùng độ lớn hiệu ứng.

- **Tuyến đường là thuộc tính liên hệ mạnh nhất với nhãn**, cả với Bị chặn (V = 0,18) lẫn với l (V = 0,28 ở bộ chính). Đây là lý do chính để chia tập theo đường.
- **Loại đường** có liên hệ ở ảnh bơm: trong tầng ngẫu nhiên, tỉ lệ Bị chặn trên ảnh dùng được là 13,7% ở đường tertiary (34/248) và 20% ở residential (4/20), so với 7,0% ở primary (3/43) và 7,5% ở secondary (5/67). Các nhóm nhỏ nên khoảng tin cậy rộng. Bộ chính chỉ có đường lớn nên không kiểm tra được.
- **Độ sáng, khoảng cách, tọa độ, người chụp, năm chụp** gần như không phân biệt được nhãn: mọi khoảng của bộ chính đều chứa 0,5.
- **Điểm bộ chọn ảnh** liên hệ mạnh với nhãn ở ảnh bơm (AUC 0,78). Đây là hệ quả của cách chọn, và là lý do điểm này không được dùng làm đặc trưng hay nhãn.

Riêng trong train của bộ chính, kinh độ có AUC 0,37 $[0{,}28;\ 0{,}47]$: ảnh Bị chặn nằm lệch về phía tây. Chỉ có 10 đường nên đây nhiều khả năng là khác biệt giữa các đường, không phải quy luật địa lý.

6.4. Kiểm tra chất lượng dữ liệu

Tính hợp lệ và nhất quán

Script `src/eda/28_eda_tabular.py` chạy 71 phép kiểm tra tự động; 62 đạt, 9 không đạt. Không có dữ liệu nào bị sửa.

Bảng 15: Kết quả kiểm tra tính hợp lệ và nhất quán

Kiểm tra	Kết quả	Chi tiết và cách xử lý
Mã ảnh duy nhất trong và giữa ba bảng nhãn	Đạt	5.149 mã khác nhau
Nhãn ghép 1–1 với manifest	Đạt	Cả ba phần
Tập và đường khớp giữa nhãn, manifest, cấu hình	Đạt	
Không đường nào ở hai tập; không vị trí 25 m nào ở hai tập	Đạt	Ảnh bơm không dùng chung đường với bộ chính
Không ảnh 360° nào dùng hai lần	Đạt	Trong và giữa ba phần
Nhãn thuộc {0, 1, I}; phía phải; góc 60°; giấy phép	Đạt	
Mọi ảnh giữ lại có độ sáng trên ngưỡng đêm	Đạt	Min 91. Ảnh bị loại: 27–90. Phép kiểm tra chặt "ảnh bị loại đều dưới 90" không đạt vì 1 ảnh của kho ảnh bơm ghi đúng 90 (giá trị đã làm tròn)
Ảnh I có ghi lý do	Không đạt	281 + 7 ảnh, thiếu theo cấu trúc (mục 6.1). Giữ nguyên
Thẻ vật cản chỉ có khi lượt gán chọn 1	Không đạt	285/4.435 lượt (bộ chính) và 119/2.000 lượt (ảnh bơm) có thẻ nhưng nhãn là 0 hoặc I. Thống kê vật cản chỉ dùng lượt chọn 1
Tọa độ trong khung nghiên cứu	Không đạt	2 ảnh bơm nằm ngoài khung dưới 4 m (do làm tròn mép khung). Giữ nguyên
Hướng chạy xe trong $[0, 360)$	Không đạt	1 ảnh ghi 360,0 (tương đương 0). Vô hại
Ngày chụp không phải ngày giữ chỗ	Không đạt	103 ảnh ghi 01/01/2016. Không dùng năm chụp để lọc hay chia tập
Ảnh pilot không trùng vị trí ảnh bộ chính	Không đạt	5 ảnh pilot cách ảnh bộ chính dưới 5 m (gần nhất 2,9 m). Cả hai đều thuộc train nên không phải rò rỉ giữa các tập

Nguồn: `tables/consistency_checks.csv`, `tables/bbox_violations.csv`.

Ngoại lệ và dữ liệu bất thường

- **Metadata.** Theo quy tắc $1{,}5\times$IQR [16], bộ chính có 81 ảnh ngoại lệ về độ sáng ảnh 360° (63 thấp, 18 cao) và 113 ảnh có khoảng cách tới tim đường lớn; ảnh bơm có 113 và 71 ảnh.

Đây là đuôi của phân bố lệch, không phải lỗi nhập liệu; mọi giá trị nằm trong miền hợp lệ (độ sáng 91–249, khoảng cách 0–20 m).

- **Ảnh cắt.** Trên 5.149 ảnh: 87 ảnh ngoại lệ về độ sáng (7 quá tối, 80 quá sáng), 36 về tương phản, 115 ảnh có độ nét rất thấp (thang log). Tổng cộng 308 ảnh nằm ngoài ít nhất một ngưỡng (`tables/image_outliers.csv`).
- **Ảnh cháy sáng** (trên 20% điểm ảnh bão hòa): 128 ảnh. Tỉ lệ ở test (33 ảnh, 4,9%) và val (25 ảnh, 5,1%) cao hơn train (36 ảnh, 2,0%); 27/33 ảnh của test thuộc đường Hai Bà Trưng.
- **Quan sát bằng mắt trên các tấm ảnh ngoại lệ** (không phải phép đo): ảnh tối nhất phần lớn là bóng râm, gầm cầu vượt, trời âm u, không phải ảnh đêm; ảnh sáng nhất bị phơi sáng quá mức nhưng nhiều ảnh vẫn thấy vỉa hè; ảnh mờ nhất phần lớn là cảnh tối hoặc nhòe do chuyển động.
- **Cách xử lý:** không loại ảnh ngoại lệ nào. Ảnh xấu tới mức không xét được đã được người gán đưa vào l; phần còn lại là điều kiện chụp thật mà model phải chịu được.

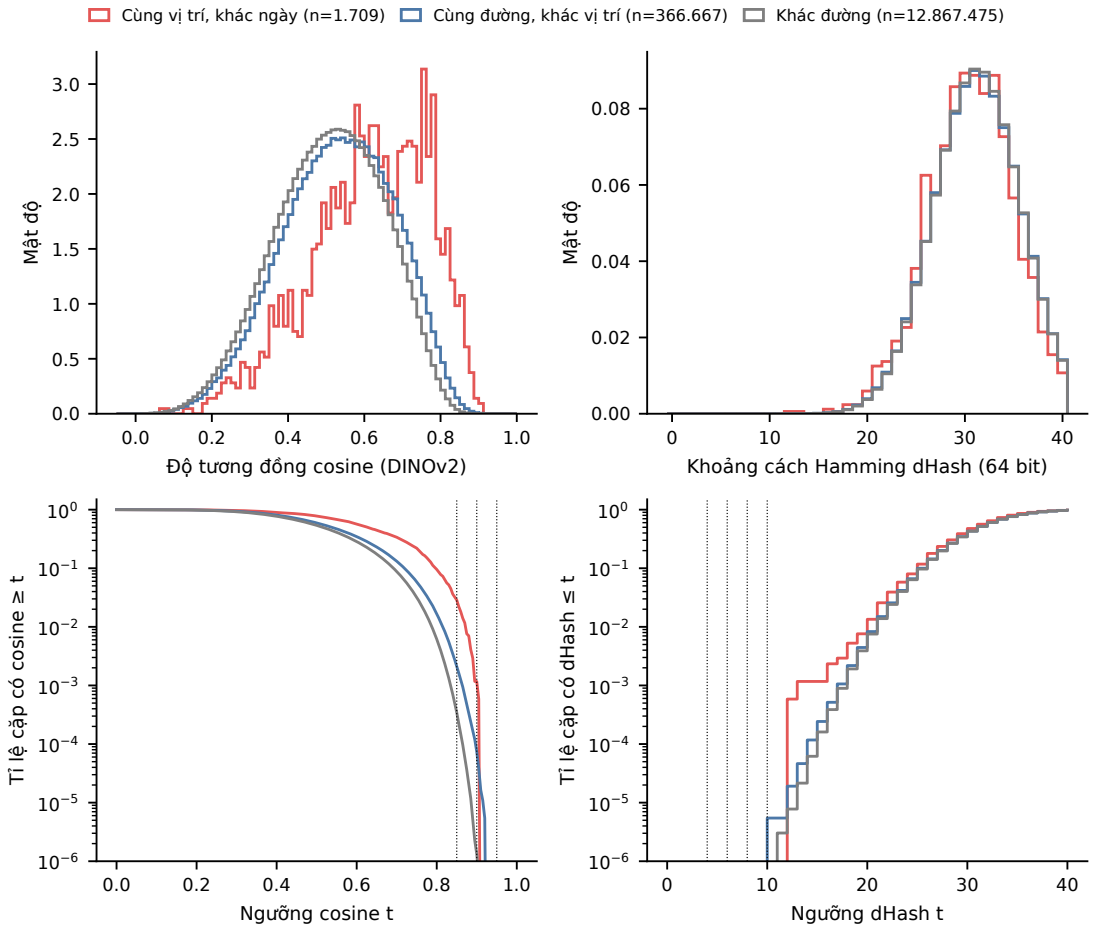
Kiểm tra bộ lọc đêm (việc còn mở từ trước). Xem lại 58 ảnh 360° bị loại của bộ chính và 58 ảnh giữ lại có độ sáng thấp nhất. Quan sát bằng mắt, không phải phép đo: khoảng 48/58 ảnh bị loại đúng là ảnh đêm; 9 ảnh trông là ban ngày dưới tán cây dày và 1 ảnh lúc chạng vạng (độ sáng 68–89). Trong 58 ảnh giữ lại không ảnh nào là ảnh đêm; khoảng 3 ảnh chụp lúc chạng vạng. Bộ lọc vì vậy không để lọt ảnh đêm, và loại nhầm khoảng 10 ảnh ban ngày trên 3.057 ảnh (0,3%). Kho ảnh bơm (38 ảnh bị loại): **chưa xem**.

Nguồn: `tables/image_night_check.csv`; tấm ảnh `figures/img_sheet_night_*.jpg` (không đưa lên git).

Trùng lặp và gần trùng

- **Trùng tuyệt đối: không có.** Không có hai file trùng mã băm md5, không có hai ảnh trùng điểm ảnh sau giải nén, không ảnh 360° nào xuất hiện hai lần (n = 5.149).
- **Bản sao gần như y hệt: không có.** Không cặp ảnh nào có khoảng cách dHash ≤ 4 trên 64 bit. Cặp gần nhất giữa các tập có dHash 6; xem bằng mắt thì là hai nơi khác nhau có cùng mảng trời sáng.
- **Cùng vị trí, khác ngày.** 1.709 vị trí có hai ảnh chụp ở hai ngày (bộ chính 1.363, ảnh bơm 346), luôn nằm trong cùng một tập. Các cặp này *không* giống nhau về nội dung theo phép đo: dHash nhỏ nhất là 12 (trung vị 31, bằng các cặp khác đường), độ tương đồng cosine của embedding DINOv2 có trung vị 0,63 và lớn nhất 0,905. Hai ngày chụp cho xe cộ, hàng quán và ánh sáng khác nhau, nên giữ cả hai ảnh là hợp lý.
- **Hệ quả về phương pháp:** cả dHash lẫn cosine đều không tách được "cùng một nơi" khỏi "cảnh tương tự" (hình 9); chỉ khoảng cách địa lý làm được việc này. Báo cáo vì vậy không

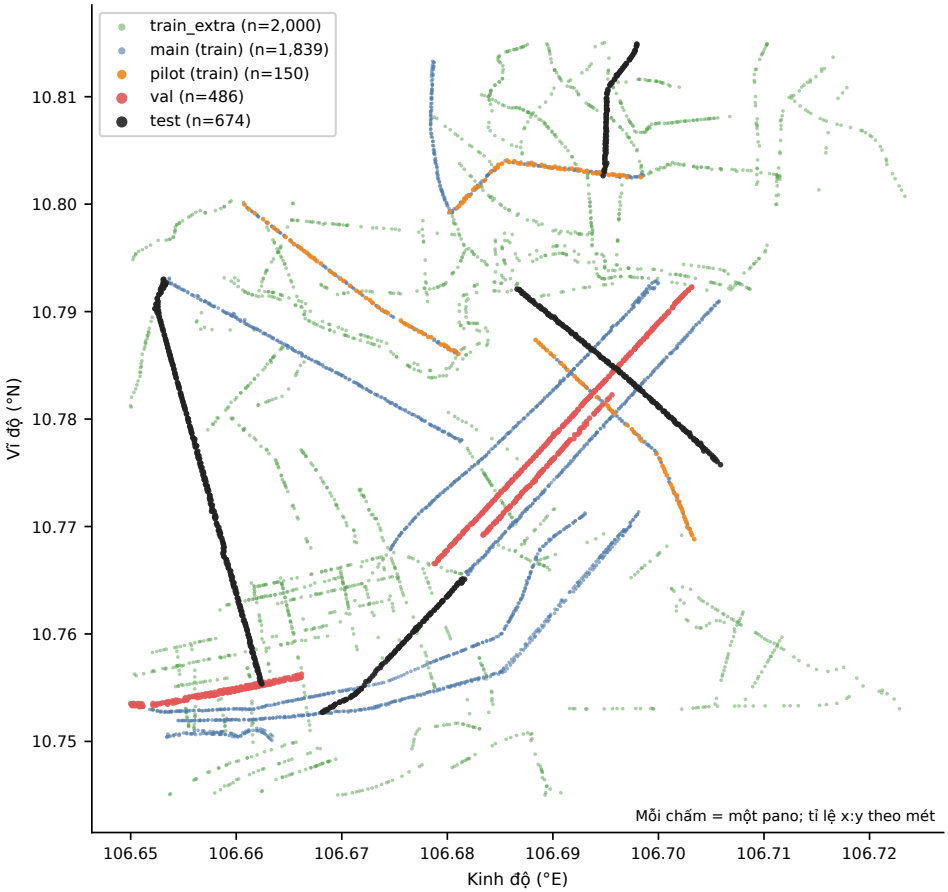
đặt một ngưỡng gần trùng theo nội dung.



Hình 9: Phân bố độ tương đồng giữa các cặp ảnh: cùng vị trí khác ngày, cùng đường khác vị trí, khác đường

Nguồn: `tables/duplicate_numbers.json`, `tables/dup_population_quantiles.csv`, `tables/dup_pair_counts_aggregated.csv` (`src/eda/30_eda_duplicates.py`).

Rò rỉ giữa các tập



Hình 10: Vị trí mọi ảnh theo tập. Các đường val/test cắt đường train tại giao lộ

Theo nội dung ảnh. Với mỗi ảnh val/test, tìm ảnh giống nhất ở phía train (bộ chính, pilot, ảnh bơm) theo cosine.

- Độ tương đồng với ảnh train gần nhất: val trung vị 0,78, lớn nhất 0,909; test trung vị 0,79, lớn nhất 0,904. Phân bố này trùng với mức tham chiếu giữa các đường train với nhau (trung vị 0,81, lớn nhất 0,933), tức ảnh val/test không giống train hơn mức mà hai đường khác nhau vốn giống nhau.
- Có 7 ảnh val/test có cosine $\geq 0{,}90$ với một ảnh train. Cả 7 cặp cách nhau 778–3.585 m. Xem bằng mắt 20 cặp giống nhất: đều là hai nơi khác nhau có cùng kiểu cảnh (dãy nhà phố, người đi xe máy ở tiền cảnh).

Theo vị trí địa lý. Chia theo đường không ngăn được việc đường val/test *cắt* đường train.

Bảng 16: Số ảnh val/test nằm gần một ảnh phía train

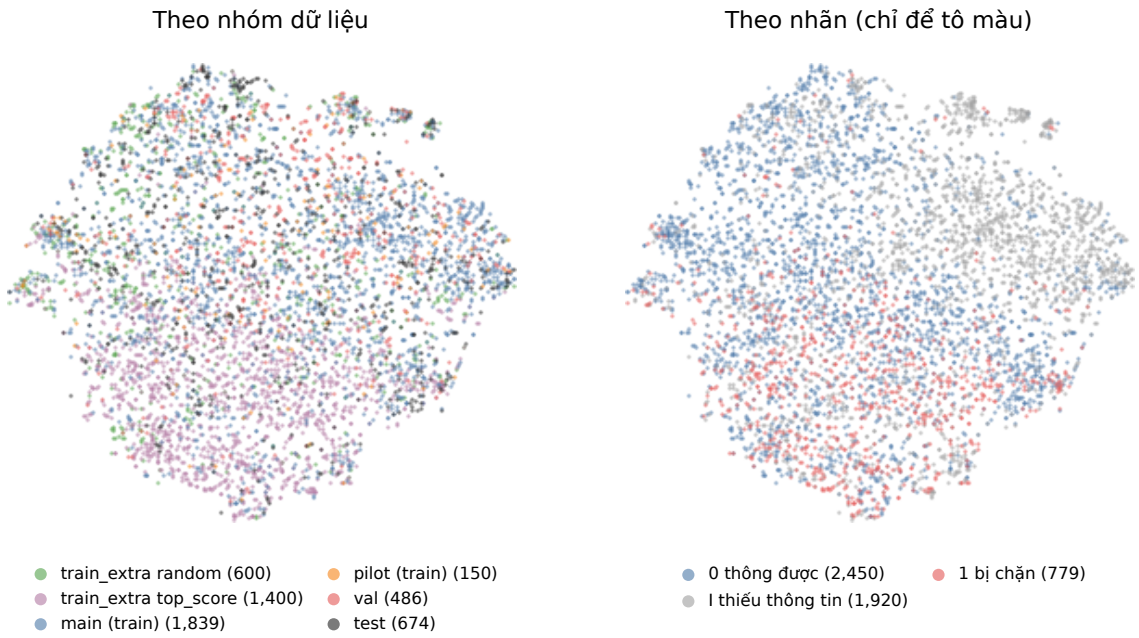
Cặp	Gần nhất (m)	< 15 m	< 25 m	< 40 m	< 100 m
Val (486) – train bộ chính	1,5	6	6	14	47
Val – pilot	17,9	0	1	5	17
Val – ảnh bơm	41,6	0	0	0	71
Test (674) – train bộ chính	7,1	8	18	34	88
Test – pilot	20,9	0	2	4	7
Test – ảnh bơm	34,3	0	0	3	116

Nguồn: `tables/dup_spatial_vt_to_train_side.csv`, `tables/dup_spatial_street_pairs_lt40m.csv`.

- **52 trên 1.160 ảnh val/test (4,5%) nằm cách một ảnh train dưới 40 m**, ứng với 47 ảnh phía train và 13 cặp đường giao nhau (ví dụ Hồng Bàng – Nguyễn Trãi, Lý Thường Kiệt – Cách Mạng Tháng Tám, Hai Bà Trưng – Điện Biên Phủ).
- Quan sát bằng mắt trên 20 cặp gần nhau nhất (1–14 m): phần lớn nhìn về hai hướng khác nhau, nhưng vài cặp thấy cùng một góc phố (cùng cột điện, biển quảng cáo, hàng rào). Phép đo nội dung không bắt được các cặp này: cosine lớn nhất của chúng chỉ là 0,82.
- **Ảnh bơm tuân thủ quy tắc 40 m**, trừ 1 ảnh cách ảnh test 34,3 m (quy tắc áp cho tâm của ô 25 m, không cho từng ảnh).
- 53 trên 551 chuỗi ảnh Mapillary chứa ảnh của cả phía train lẫn val/test (cùng một lượt xe chạy qua nhiều đường). Đây không phải rò rỉ nội dung, nhưng nghĩa là cùng thiết bị và điều kiện chụp có mặt ở cả hai phía.

Kế hoạch xử lý (chưa thực hiện, cần nhóm quyết định trước khi khóa chia tập): loại khỏi train các ảnh cách ảnh val/test dưới 40 m, giống quy tắc đã áp cho ảnh bơm. Quy tắc này chỉ dùng tọa độ, không dùng nhãn val/test, và bỏ nhiều nhất 47 ảnh train. Phương án khác là giữ nguyên và báo cáo kết quả test kèm một lượt đánh giá bỏ 52 ảnh gần giao lộ.

Ảnh bơm khác bộ chính tới đâu



Hình 11: Hình chiếu t-SNE [1] của embedding DINOv2 cho 5.149 ảnh, tô theo nhóm và theo nhãn (nhãn chỉ để tô màu)

Một bộ phân loại tuyến tính trên embedding DINOv2, không dùng nhãn, được giao phân biệt hai nhóm ảnh; AUC 0,5 nghĩa là không phân biệt được. Kiểm định chéo tách theo đường.

Bảng 17: Mức phân biệt được giữa các nhóm ảnh (AUC của bộ phân loại miền)

So sánh	AUC	Cách đọc
Train bộ chính – ảnh bơm, tầng top_score	0,95	Khác rõ
Train bộ chính – ảnh bơm, tầng random	0,70	Khác vừa
Ảnh bơm – val + test	0,83	Khác rõ
Train bộ chính – val + test	0,47	Không phân biệt được
Đối chứng: chia đôi ngẫu nhiên các đường train	0,51	Mức nền

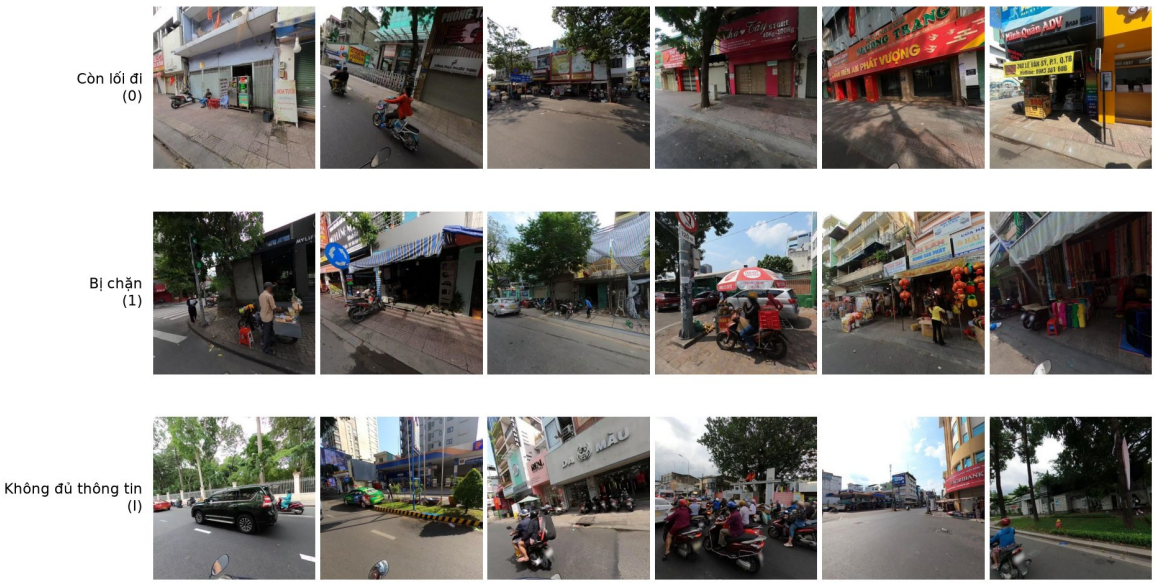
Nguồn: `tables/dup_domain_classifier_auc.csv`. Trung bình qua các fold; độ lệch chuẩn giữa các fold 0,02–0,08.

- **Train của bộ chính và val/test cùng phân phối ảnh** (AUC gần 0,5): cách chia theo đường không tạo ra lệch miền nhìn thấy được. Với chỉ 17 đường, phép đo này không đủ nhạy để bắt lệch nhỏ.
- **Ảnh bơm là một miền khác**, kể cả tầng ngẫu nhiên (0,70): chúng đến từ đường nhỏ gần chợ, còn val/test là đường lớn. Tầng top_score còn đồng nhất hơn các nhóm khác (cosine

trung bình trong nhóm 0,60 so với 0,49–0,51). Đây là cái giá của việc bơm: thêm 577 ảnh dương nhưng từ một kiểu cảnh hẹp hơn val/test.

- Trên hình 11, ảnh Bị chặn và tầng top_score dồn về cùng một vùng, ảnh I dồn về một vùng khác. t-SNE chỉ để minh họa, không dùng để kết luận.

6.5. EDA cho dữ liệu ảnh



© Mapillary contributors, CC BY-SA 4.0

Hình 12: Ví dụ ảnh theo nhãn, lấy ngẫu nhiên từ train của bộ chính. © Mapillary contributors, CC BY-SA 4.0



© Mapillary contributors, CC BY-SA 4.0

Hình 13: Ví dụ ảnh bơm theo tầng lấy mẫu; ô góc trái là nhãn. © Mapillary contributors, CC BY-SA 4.0

Định dạng và độ phân giải

Cả 5.149 ảnh đều mở được, là JPEG RGB 640×640, chất lượng nén ước lượng 90. Dung lượng 38,5–167,7 KB, trung vị 99,3 KB. Độ phân giải đồng nhất theo thiết kế; ảnh gốc là ảnh 360° thu nhỏ 2.048 px nên chi tiết nhỏ ở xa bị mất.

Nguồn: `tables/image_format_check.csv` (`src/eda/29_eda_images.py`).

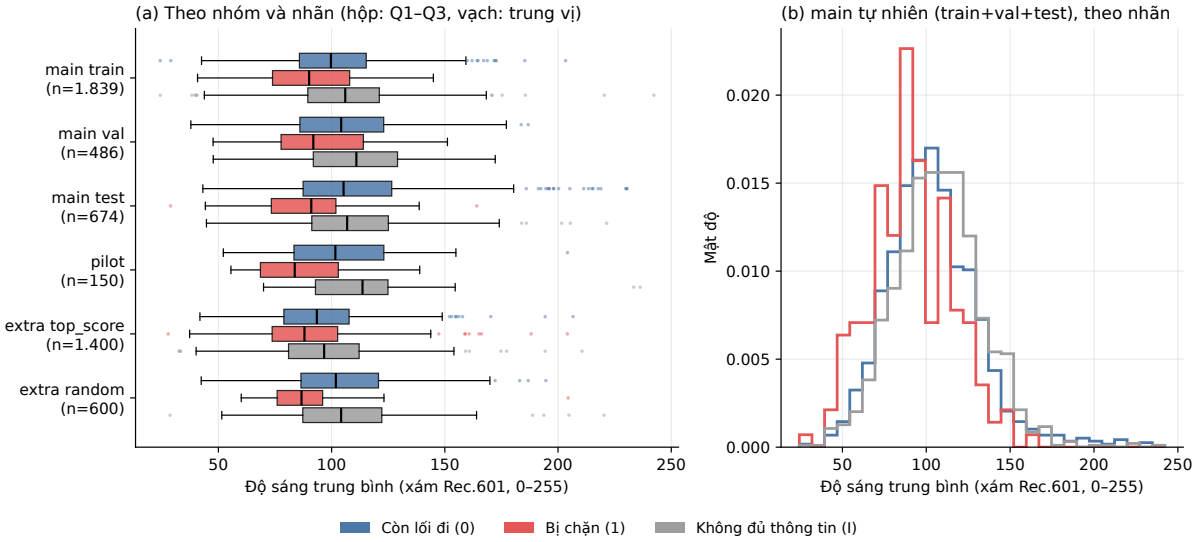
Chất lượng ảnh

Các đại lượng đo trên từng ảnh cắt: độ sáng trung bình (xám Rec.601, 0–255), tương phản (độ lệch chuẩn của xám), tỉ lệ điểm ảnh rất tối (< 30) và cháy sáng (> 245), độ nét (phương sai của Laplacian), độ sặc sỡ màu [17].

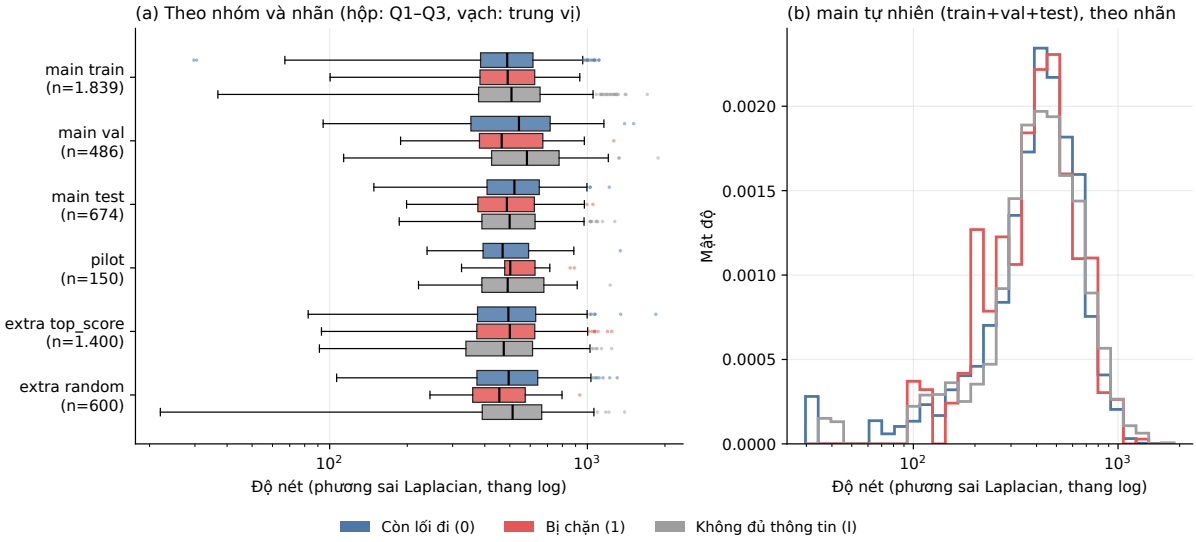
Bảng 18: Thống kê chất lượng ảnh theo nhóm (trung vị; trong ngoặc là IQR)

Nhóm	n	Độ sáng	Tương phản	Độ nét	Sặc sỡ màu
Bộ chính, train	1.839	101,9 (31,3)	59,4 (14,1)	494 (254)	25,1 (13,3)
Bộ chính, val	486	106,7 (36,9)	62,7 (14,1)	560 (354)	26,7 (13,7)
Bộ chính, test	674	104,7 (36,9)	59,3 (14,2)	511 (245)	25,9 (14,0)
Pilot	150	106,6 (38,0)	59,3 (14,0)	487 (244)	24,5 (13,1)
Ảnh bơm, top_score	1.400	91,8 (30,5)	60,1 (13,7)	492 (260)	27,8 (14,3)
Ảnh bơm, random	600	100,8 (35,2)	58,1 (12,4)	497 (268)	25,7 (13,7)
Cả 5.149 ảnh: min – max		24,3 – 242,3	17,4 – 96,6	22 – 1.881	4,8 – 104,3

Nguồn: `tables/image_summary_stats.csv` (có đủ trung bình, phương sai, min, max, Q1, Q3 cho 12 đại lượng, theo nhóm và nhãn).



Hình 14: Độ sáng của ảnh cắt theo nhóm và theo nhãn



Hình 15: Độ nét của ảnh cắt (thang log) theo nhóm và theo nhãn

- **Các nhóm tự nhiên giống nhau về chất lượng ảnh.** Train, val, test, pilot và tầng random có trung vị độ sáng 101–107 và độ nét 487–560. Val hơi tương phản hơn train (AUC 0,58 [0,54; 0,61]).
- **Ảnh Bị chặn tối hơn ảnh Còn lối đi.** Ở bộ chính, trung vị độ sáng là 90,9 so với 101,6; AUC 0,37 [0,32; 0,41] (bootstrap theo 17 đường); tỉ lệ điểm ảnh rất tối 18% so với 12%. Cách giải thích hợp lý là vật cản thường nằm dưới mái hiên và bóng cây, nhưng **chưa kiểm chứng**. Đây là rủi ro "học tắt": model có thể dựa một phần vào độ tối. Nên kiểm tra khi phân tích lỗi của model.
- **Tầng top_score tối hơn bộ chính** (trung vị 91,8 so với 101,9), một phần vì tầng này có nhiều ảnh Bị chặn.
- **Ảnh I tương phản cao hơn và nhiều vùng cháy sáng hơn** ảnh 0 (AUC 0,67 và 0,65 ở bộ

chính), phù hợp với việc các ảnh này thường thấy nhiều bầu trời và lòng đường.

- **Độ nét không phân biệt được nhãn** (AUC 0,46–0,59, mọi khoảng chứa 0,5).
- **Độ sáng ảnh** 360° **dùng để lọc đêm chỉ liên hệ yếu với độ sáng ảnh cắt** (Spearman 0,18 [0,09; 0,27] ở bộ chính; 0,31 nếu chỉ tính nửa trên ảnh cắt), vì hai đại lượng đo hai vùng khác nhau. Bộ lọc đêm vì vậy không bảo đảm ảnh cắt đủ sáng.

Nguồn: `tables/image_effect_sizes.csv`, `tables/image_spearman_brightness.csv`.

Lý do "Ảnh mờ / tối / cháy sáng" có khớp phép đo không

Có 33 ảnh l mang lý do này (bộ chính 12, ảnh bơm 21). Chúng có độ nét thấp rõ rệt: trung vị nằm ở phân vị 3,5 của bộ chính và phân vị 13 của ảnh bơm. Về độ sáng thì lẫn lộn cả ảnh tối và ảnh cháy sáng (36% nằm dưới phân vị 10, 18% nằm trên phân vị 90). Mẫu nhỏ nên chỉ là mô tả.

Nguồn: `tables/image_reason_blur_dark_summary.csv`.

7. Tổng kết: đã đo gì, chưa làm gì

7.1. Những gì đã đo

Bảng 19: Các kết quả chính, kèm cỡ mẫu và khoảng tin cậy

Câu hỏi	Kết quả	Đo trên
Bộ dữ liệu có bao nhiêu ảnh, bao nhiêu dùng được?	5.149 ảnh có nhãn cuối; 3.229 ảnh dùng được (2.450 0, 779 1); 1.920 ảnh l	Toàn bộ
Lớp Bị chặn hiếm tới đâu trong ảnh tự nhiên?	10,8% ảnh dùng được [Wilson 9,4; 12,3], [bootstrap theo đường 8,7; 13,9]	1.746 ảnh dùng được, 17 đường
Test và val có đủ ảnh dương không?	Test 47 ảnh (10,2% [7,8; 13,4]); val 35 ảnh (14,5% [10,6; 19,5])	459 và 242 ảnh dùng được
Train sau khi bơm?	697 ảnh Bị chặn trên 2.528 ảnh dùng được (27,6% [25,9; 29,3]); 83% ảnh dương là ảnh bơm	Train
Người gán có nhất quán không?	Cohen κ 3 nhãn: test 0,60; val 0,64; train gán chéo 0,61	674, 486, 276 ảnh gán đôi
Bộ chọn ảnh có hiệu quả trên đường mới không?	Bị chặn trên mọi ảnh: tầng điểm cao 37,9% [35,4; 40,5], tầng ngẫu nhiên 7,7% [5,8; 10,1]	1.400 và 600 ảnh
Có ảnh trùng không?	Không có ảnh trùng tuyệt đối; không có cặp nào dHash ≤ 4	5.149 ảnh, mọi cặp
Có rò rỉ giữa các tập không?	Không chung đường, vị trí hay ảnh gốc. 52/1.160 ảnh val/test (4,5%) cách ảnh train dưới 40 m tại giao lộ	Mọi ảnh, theo tọa độ
Chất lượng ảnh có khác giữa các tập không?	Không đáng kể giữa train, val, test của bộ chính. Ảnh Bị chặn tối hơn ảnh Còn lối đi: AUC 0,37 [0,32; 0,41]	2.999 ảnh, 17 đường
Ảnh bơm có giống bộ chính không?	Không: bộ phân loại miền đạt AUC 0,95 (tầng điểm cao) và 0,70 (tầng ngẫu nhiên)	1.839 so với 1.400 và 600 ảnh
Metadata có liên hệ với nhãn không?	Chỉ tuyến đường (Cramér's V 0,18) và loại đường; độ sáng, tọa độ, người chụp, năm chụp thì không	1.746 ảnh dùng được

7.2. Những gì chưa đo hoặc chưa làm

Bảng 20: Việc chưa làm và ảnh hưởng tới báo cáo

Việc	Trạng thái và ảnh hưởng
Ảnh nhóm tự chụp (ít nhất 100 ảnh theo đề cương)	Chưa có. Toàn bộ dữ liệu là ảnh Mapillary
Rà soát nội dung nhạy cảm trong ảnh	Chưa làm. Chỉ dựa vào phần làm mờ sẵn của Mapillary; trên các tấm ảnh kiểm tra vẫn thấy một số người và biển số còn rõ
Khóa danh sách chia tập	Chưa khóa. Chờ quyết định về đường test (47 ảnh dương) và về 47 ảnh train gần giao lộ với val/test
Mức nhiễu nhãn của ảnh bơm	Chưa đo được. Mỗi ảnh một người gán; 203 ảnh kiểm tra chéo được chọn vì bị nghi ngờ nên không đại diện. Người gán chênh nhau rõ (19% tới 43% Bị chặn)
Khoảng tin cậy của κ	Chưa đo
1.563 ảnh train của bộ chính chỉ một người gán	Chưa rà lại; phần gán chéo 15% có κ 0,61
Vỉa hè bên trái của đường một chiều	Ít được quan sát vì chỉ lấy ảnh bên phải xe. Giới hạn của nguồn dữ liệu
Ảnh bơm gộp vào bảng nhãn chung	Chưa gộp; hai bảng nhãn để riêng. Hai ô kiểm tra chéo (263, 264) còn chờ xác nhận, đang giữ nhãn gốc
Kiểm chứng vì sao ảnh Bị chặn tối hơn	Chưa làm; mới chỉ mô tả. Cần kiểm tra khi phân tích lỗi model
Xem lại ảnh bị bộ lọc đêm loại ở kho ảnh bơm (38 ảnh)	Chưa xem. Bộ chính đã xem (58 ảnh)
So sánh ảnh dựng lại với bản gốc trên server	Chỉ có số đo cũ trên 5 ảnh (lệch 1,35–1,5 mức xám). 671 ảnh val/test dùng trong EDA ảnh là bản dựng lại
Thời gian gán và thẻ vật cản của pilot	Chưa đưa vào thống kê
Chuẩn hóa điểm ảnh, tăng cường dữ liệu	Thuộc bước train, chưa làm

Nguồn: `docs/unresolved_items.md`; mục 6 của báo cáo này.

7.3. Hệ quả cho bước xây dựng model

- **Đánh giá.** Dùng chỉ số chịu được mất cân bằng (PR-AUC, F1 của lớp Bị chặn), và báo cáo khoảng tin cậy lấy lại mẫu theo đường. Với 47 ảnh dương ở test, khác biệt nhỏ giữa

các model sẽ không phân biệt được.

- **Train.** Phân phối nhãn và kiểu cảnh của train (sau khi bơm) khác val/test. Nên chạy thêm một lượt chỉ với phần tự nhiên, và cân nhắc trọng số lớp hoặc lấy mẫu lại.
- **Học tắt.** Kiểm tra xem model có dựa vào độ tối của ảnh hay không.
- **Rò rỉ.** Quyết định xử lý các ảnh train gần giao lộ với val/test trước khi khóa chia tập.

Tài liệu tham khảo

[1] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9:2579–2605, 2008.

[2] Manh Dung Dao and Thanh Huy Cao. Vietnamese Sidewalk Violation VQA: A question-answering dataset for sidewalk encroachment detection. SE365 course project, University of Information Technology, VNU-HCM, 2026. Dataset card; truy cập 18/10/2026.

[3] Mapillary. An introduction to Mapillary, 2024. Mapillary documentation; truy cập 18/10/2026.

[4] OpenStreetMap contributors. OpenStreetMap, 2026. openstreetmap.org, dữ liệu theo giấy phép ODbL; truy vấn qua Overpass API ngày 22/10/2026.

[5] Maxim Tkachenko, Mikhail Malyuk, Andrey Holmanyuk, and Nikolai Liubimov. Label Studio: Data labeling software, 2020–2022. Phần mềm mã nguồn mở, github.com/heartexlabs/label-studio.

[6] Joseph L. Fleiss. Measuring nominal scale agreement among many raters. *Psychological Bulletin*, 76(5):378–382, 1971.

[7] Josh Attenberg and Foster Provost. Why label when you can search? Alternatives to active learning for applying human resources to build classification models under extreme class imbalance. In *Proceedings of the 16th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2010. doi:10.1145/1835804.1835859.

[8] Maxime Oquab, Timothée Darcet, Théo Moutakanni, et al. DINOv2: Learning robust visual features without supervision, 2023. arXiv:2304.07193.

[9] Sebastian Farquhar, Yarin Gal, and Tom Rainforth. On statistical bias in active learning: How and when to fix it. In *International Conference on Learning Representations (ICLR)*, 2021. arXiv:2101.11665.

[10] Alec Radford, Jong Wook Kim, Chris Hallacy, et al. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, 2021. arXiv:2103.00020.

[11] Enze Xie, Wenhai Wang, Zhiding Yu, Anima Anandkumar, Jose M. Alvarez, and Ping Luo. SegFormer: Simple and efficient design for semantic segmentation with transformers. In *Advances in Neural Information Processing Systems 34 (NeurIPS)*, 2021. arXiv:2105.15203.

[12] Neal Krawetz. Kind of like that, 2013. The Hacker Factor Blog, bài viết mô tả dHash.

[13] Jacob Cohen. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1):37–46, 1960.

[14] Edwin B. Wilson. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212, 1927.

[15] Wicher Bergsma. A bias-correction for Cramér's V and Tschuprow's T. *Journal of the Korean Statistical Society*, 42(3):323–328, 2013.

[16] John W. Tukey. *Exploratory Data Analysis*. Addison-Wesley, 1977.

[17] David Hasler and Sabine Süsstrunk. Measuring colorfulness in natural images. In *Human Vision and Electronic Imaging VIII, Proc. SPIE 5007*, pages 87–95, 2003.

A. Truy nguồn số liệu và cách chạy lại

Mọi con số trong báo cáo đến từ một file trong repo hoặc từ một script chạy lại được. Đường dẫn `tables/` và `figures/` là tương đối so với `docs/data_report/`.

Bảng 21: Script sinh số liệu và hình của báo cáo

Script	Sinh ra
`src/eda/27_rebuild_missing_crops.py`	Dựng lại ảnh cắt còn thiếu trên máy từ manifest (671 ảnh val/test). Không đọc nhãn
`src/eda/28_eda_tabular.py`	Bảng 1, 9, 11–14, 15; hình `tab_*.pdf`; `tables/tabular_numbers.json` và các bảng thống kê nhãn, metadata, kiểm tra nhất quán
`src/eda/29_eda_images.py`	Bảng 18; hình `img_*`; `tables/image_stats.csv` (mỗi ảnh một dòng), `tables/image_numbers.json`
`src/eda/30_eda_duplicates.py`	Bảng 16, 17; hình `dup_*`; `tables/duplicate_numbers.json`

Bảng 22: Nguồn của các số liệu không do script EDA sinh ra

Số liệu	Nguồn
Số ảnh Mapillary, số đường OSM, tỉ lệ gắn đường, ảnh đêm bị loại	`docs/collection_log.md`; `data/manifest/main_v1_collection_status.csv`
So sánh ảnh trái và phải, tham số cắt ảnh	`src/analysis/08_side_analysis.py`, `09_crop_param_study.py`; `data/streets/side_coverage.csv`, `crop_param_study.csv`
Đồng thuận, phân xử, nguồn nhãn	`src/labeling/19_main_agreement.py`; `data/labels/main_report/main_report.md`; `docs/labeling_phase1.md`
Pilot	`src/labeling/07_pilot_agreement.py`; `data/labels/pilot_report/`
So sánh bộ chọn ảnh	`src/analysis/21_selector_benchmark.py`; `data/streets/selector_benchmark.csv`
Quét đường, kho ảnh bơm, chọn 2.000 ảnh	`src/analysis/24_street_scan.py`, `src/collection/23_collect_train_extra.py`; `data/streets/street_scan_v1.csv`, `train_extra_v1_scores.csv`
Kết quả gán ảnh bơm, kiểm tra chéo	`src/labeling/26_train_extra_report.py`; `data/labels/train_extra_report/report.md`; `data/labels/train_extra_cross_check.csv`

Chạy lại (từ thư mục gốc của repo, Python trong `.venv`; script 29 và 30 cần ảnh trong `data/crops/`, script 30 nên chạy trên GPU):

```
python src/eda/27_rebuild_missing_crops.py  # can MAPILLARY_TOKEN
python src/eda/28_eda_tabular.py
python src/eda/29_eda_images.py
python src/eda/30_eda_duplicates.py
cd docs/data_report && sh make.sh           # ra data_report.pdf
```

Việc ai làm. Ba script EDA do ba tác tử AI (Claude Sonnet) viết theo đề bài của tác tử điều phối (Claude); tác tử điều phối đã tính lại độc lập các số chính (đếm nhãn, khoảng Wilson, thống kê metadata, phép đo ảnh trên 300 ảnh mẫu, mã băm md5, khoảng cách giữa các tập, độ tương đồng embedding) và xem các tấm ảnh kiểm tra trước khi đưa vào báo cáo. Các câu "quan sát bằng mắt" là quan sát của AI trên tấm ảnh ghép, không phải nhãn và không phải phép đo.

Nhãn của bộ dữ liệu do người gán.

Ảnh trong báo cáo. Hình 12 và 13 chỉ dùng ảnh train. Các tấm ảnh kiểm tra nội bộ (`figures/*_sheet_*.jpg`) có ảnh val/test nên không đưa vào báo cáo và không đưa lên git. Ảnh: © Mapillary contributors, CC BY-SA 4.0.